

MARTIN-LUTHER-UNIVERSITÄT
HALLE-WITTENBERG

Bachelorarbeit

Konsistenzprüfung von Proteinvergleichen auf Basis der Primärsequenz und der 3D-Struktur

Dozenten:	Dr. rer. nat. Jan Grau
	Dr. rer. nat. Jördis-Ann Schüler

vorgelegt von:	Ahmad Wattar
	217234191

Studiengang:	Bioinformatik
Abschluss:	Bachelor of Science (B.Sc.)

Abgabetermin:	17. April 2024

Danksagung

Ich möchte mich ganz herzlich bei Herrn Dr. Jan Grau und Frau Dr. Jördis-Ann Schüler für ihre hervorragende Betreuung meiner Bachelorarbeit bedanken. Ihre Unterstützung, Zeit und Geduld bei der Beantwortung meiner Fragen haben maßgeblich zum Erfolg dieser Arbeit beigetragen.

Ein besonderer Dank gilt auch meinem Bruder Fadel, der mich während meines gesamten Studiums stets unterstützt und ermutigt hat. Ebenso möchte ich meiner Frau Joudy und meinen Eltern sowie Geschwistern und Freunden für ihre Unterstützung und Ermutigung danken.

Nicht zu vergessen sind auch Katrin Horn und Christian Kujat, die es mir ermöglicht haben, meinen Weg ins Studium zu finden, und mich während meiner Zeit im Studienkolleg unterstützt haben. Ihre Hilfe und Unterstützung haben mir geholfen, Hindernisse zu überwinden und meine Ziele zu erreichen.

Nochmals herzlichen Dank an alle, die mich auf meinem akademischen Weg begleitet und unterstützt haben.

Inhaltsverzeichnis

1 Einführung **1**

1.1 Hintergrund und Motivation . . . 1

1.2 Ziel der Arbeit . . . 1

2 Grundlagen der Proteinanalyse **3**

2.1 Strukturebenen der Proteine . . . 3

2.1.1 Bedeutung der Primärstruktur und Bildung der Polypeptidkette . . . 4

2.1.2 Sekundärstruktur: Alpha-Helices und Beta-Faltblätter . . . 5

2.2 Auswirkungen der Proteinstruktur auf die Funktion . . . 7

2.2.1 Proteindomänen . . . 8

2.3 Proteindatenbanken . . . 8

2.3.1 NCBI . . . 8

2.3.2 PDB . . . 8

2.3.3 Uniport . . . 9

2.4 Weitere Datenbanken . . . 9

2.4.1 Smart . . . 9

2.4.2 Interpro . . . 9

2.5 Grundlagen der Sequenzalignment . . . 9

2.5.1 Substitutionsmatrix . . . 11

2.6 Multiple Sequenzalignment (MSA) . . . 13

2.6.1 ClustalW . . . 14

2.6.2 T-Coffee . . . 17

2.6.3 MAFFT . . . 19

2.7 Bestimmung von 3D-Proteinstrukturen . . . 19

2.7.1 FASTA . . . 19

2.7.2 DSSP . . . 20

2.7.3 Alphafold . . . 21

2.8 Proteinmodellierung mit Molecular Operating Environment (MOE) . . . 22

2.8.1 RMSD . . . 23

3 Methodik und Datenerhebung **24**

3.1 Beschaffung von Primärsequenzen und PDB-Dateien . . . 24

3.2 Bildung von MSA und Distanzmatrixberechnung . . . 24

3.3 Parsing von PDB in das DSSP-Format . . . 32

3.4 Analyse von DSSP-Dateien . . . 32

4 Vergleich von Proteinstrukturen **38**
4.1 Primärsequenzvergleich . . . 38
4.2 Strukturvergleich auf 3D-Ebene mit MOE . . . 38
4.3 Integration von Sekundärstrukturinformationen . . . 39

5 Analyse der Proteinfamilien **39**
5.1 Proteinfamilie: probable disease resistance protein At1g58602 . . . 40
5.1.1 Q8W3K0/G1JSI4 . . . 40
5.1.2 7J6/A301 . . . 44
5.1.3 B9K5/B9D8 . . . 45
5.1.4 G1A9/ZEI4 . . . 46
5.1.5 N18/MJ8 . . . 47
5.1.6 WSc7/X4U5 . . . 50
5.2 Proteinfamilie:Free fatty acid receptor 2 . . . 51
5.3 Proteinfamilie: Hexokinase-1 . . . 52
5.3.1 P17710/P05708 . . . 52
5.4 Proteinfamilie: Vascular endothelial growth factor A . . . 54
5.5 Proteinfamilie: Potassium channel subfamily K member 1 . . . 57
5.5.1 Q5UE96/Q5RD07 . . . 57
5.5.2 Q8R454/Q9Z2T2 . . . 58
5.6 Helixbildende und Helixabbrechende Aminosäuren . . . 60

6 Schlussfolgerung und Zusammenfassung **64**

7 Literaturverzeichnis **65**

Abbildungsverzeichnis **69**

Listingsverzeichnis **70**

Abkürzungsverzeichnis **71**

A Verwendete Hilfsmittel **73**

B Selbstständigkeitserklärung **74**

1 Einführung

1.1 Hintergrund und Motivation

Proteine sind komplexe Moleküle, die aus Aminosäuren bestehen. Sie sind durch ihre Fähigkeit, eine Vielzahl von Aufgaben zu erfüllen, Bestandteile aller lebenden Organismen und dienen als Bausteine für Zellen, Gewebe und Organe. Die Struktur und Funktion eines Proteins können auf verschiedenen Ebenen betrachtet werden, um verschiedene Aspekte zu beleuchten. Die Funktionen sowie die Eigenschaften eines bestimmten Proteins lassen sich durch die dreidimensionale Struktur bestimmen, die durch die Abfolge und Anordnung seiner Aminosäuren bestimmt wird. Die schnellen Entwicklungen und Fortschritte in der biologischen Forschung haben eine enorme Menge an Proteindaten generiert, die in verschiedenen Formaten gespeichert werden, je nach den gewünschten Informationen über das Protein und dessen Verwendungszweck. Außerdem spielt es auch eine Rolle, anhand welcher der vier Proteinebenen diese Daten gespeichert oder generiert werden. Diese Ebenen sind die Primärstruktur, Sekundärstruktur, die Tertiärstruktur und die Quartärstruktur. Daher ist das Verständnis der Beziehung zwischen der Struktur und Funktion der Proteine von großer Bedeutung für zahlreiche Bereiche der Bioinformatik, von der pharmazeutischen Forschung bis hin zur Grundlagenforschung. Dies erfordert eine sorgfältige Analyse und Integration von Daten aus verschiedenen Proteinebenen, um ein umfassendes Bild der Proteinfunktionalität zu erhalten und sicherzustellen, dass die Strukturdaten konsistent sind (Hucho and Koechy, 2003).

1.2 Ziel der Arbeit

In dieser Arbeit wird die Frage untersucht, ob anhand von Sequenzalignments der Primärstrukturen bereits Unterschiede in der dreidimensionalen Struktur von miteinander verwandten Proteinen festgestellt werden können. Ein Schwerpunkt liegt dabei auf der Analyse von Unterschieden wie Aminosäureaustauschen, die signifikante Hinweise auf strukturelle Divergenzen liefern können. Ziel ist es, eine umfassende Grundlage für die Analyse der Strukturbildung von Proteinen zu schaffen und Einblicke in den Einfluss verschiedener Aminosäuren auf deren Struktur zu gewinnen. Des Weiteren wird der Vergleich der Sekundärstrukturen dieser Proteine mit ihrer tatsächlichen 3D-Struktur durchgeführt, um die Konsistenz der verschiedenen Ebenen zu untersuchen. Durch diesen Vergleich können potenzielle strukturelle Abweichungen oder Konservierungen zwischen den verschiedenen Ebenen identifiziert und besser verstanden werden. Zusätzlich wird die Rolle von Aminosäuren in Bezug auf die Bildung oder Unterbrechung von Helices in der 3D-Struktur untersucht, um ihren potenziellen Einfluss auf diese strukturellen Aspekte zu erfassen. Dieser ganzheitliche Ansatz ermöglicht eine vertiefte Betrachtung der Proteinstruktur sowie ihrer dynamischen Eigenschaften. Im ersten Teil dieser Arbeit wird eine kurze Einführung zum Thema präsentiert. Im zweiten Teil wird ein umfassender Überblick über die vier verschiedenen Proteinebenen gegeben, wobei insbesondere auf die Bedeutung der Primärstruktur und die Bildung der Polypeptidkette eingegangen wird. Anschließend wird auf die Sekundärstruktur

eingegangen, wobei die Bildung von Alpha-Helices und Beta-Faltblättern näher betrachtet wird. Des Weiteren wird im Zusammenhang mit den Aminosäureneigenschaften die Auswirkung der Proteinstruktur auf die Funktionen erläutert sowie die Bildung von Proteindomänen erklärt, gefolgt von einer Erklärung der verwendeten Proteindatenbanken. Dann wird kurz auf das Sequenzalignment und die Substitutionsmatrizen eingegangen, um dann auf das Multiple Sequenz Alignment (MSA) einzugehen, einschließlich einer Erläuterung zu den progressiven Algorithmen wie ClustalW, T-Coffee und MAFFT für die Erstellung eines MSA. Abschließend wird ein Schwerpunkt auf die Strukturdateiformate wie DSSP und FASTA sowie auf die Vorhersage von 3D-Proteinstrukturen mit AlphaFold und die Proteinmodellierung mit dem MOE zur Betrachtung von Proteinen in der dreidimensionalen Struktur gelegt. Im dritten Teil dieser Arbeit wird auf die Methodik sowie die Datenerhebung eingegangen. Dies umfasst die Beschaffung von Primärsequenzen und PDB-Dateien, die Bildung von MSAs und die Berechnung von Distanzmatrizen sowie das Parsen von PDB Dateien in das DSSP-Format und die Analyse der resultierenden DSSP-Dateien. Im vierten Abschnitt wird der Vergleich von Proteinstrukturen auf verschiedenen Ebenen behandelt. Zunächst wird der Primärsequenzvergleich erläutert, der mithilfe bioinformatischer Werkzeuge wie T-Coffee durchgeführt wird, wobei auch die Wichtigkeit betont wird, die 3D-Struktur zu berücksichtigen, um weitere Aspekte zu erfassen. Anschließend wird der Strukturvergleich auf 3D-Ebene mit dem MOE-Tool beschrieben. Dabei wird auch auf die Integration von Sekundärstruktur eingegangen. Im fünften Abschnitt werden verschiedene Proteinfamilien eingehend untersucht und analysiert, um Schlussfolgerungen und Erkenntnisse zu gewinnen. Dabei liegt der Fokus darauf, ein besseres Verständnis für die Strukturbildung von Proteinen zu erlangen und den Einfluss verschiedener Aminosäuren auf die Proteinstruktur zu beleuchten. Im sechsten Abschnitt erfolgt eine Zusammenfassung der erzielten Ergebnisse und der Zusammenhänge, die durch die Analyse aufgedeckt wurden.

2 Grundlagen der Proteinanalyse

2.1 Strukturebenen der Proteine

Die Strukturebenen der Proteine repräsentieren die verschiedenen Hierarchien von Proteinen und sind für ihre Funktionen entscheidend. Während die Primärstruktur nur die Abfolge der einzelnen Aminosäuren beschreibt, bezieht sich die Sekundärstruktur auf die Strukturelemente innerhalb der Polypeptidkette. Die Tertiärstruktur beschreibt die dreidimensionale Faltung der gesamten Polypeptidkette. Sie bestimmt also die endgültige Form sowie Funktion des Proteins. Die Quartärstruktur beschreibt „Protein-Symbiosen“, die räumliche Anordnung der Untereinheiten, wenn ein Protein aus mehreren Untereinheiten besteht, die gemeinsam eine funktionelle Einheit bilden. Die nachfolgende Abbildung 1 zeigt eine Primärsequenz eines der hier behandelten Proteine aus der Proteinfamilie VEGF (Horn, 2015).

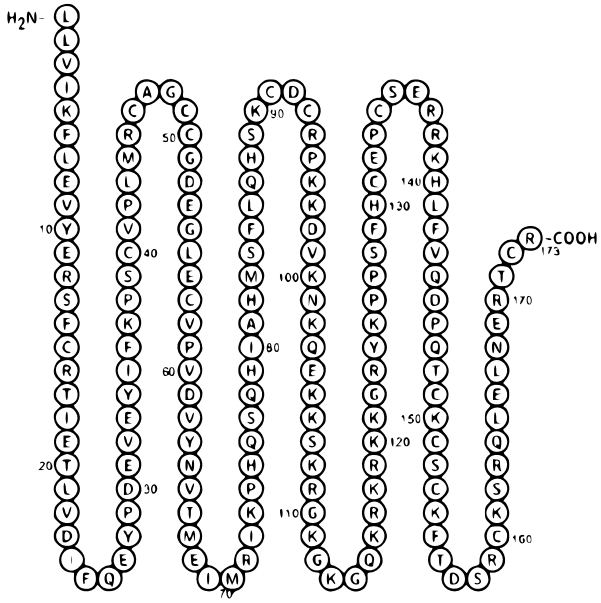


Abbildung 1: Primärstruktur eines Proteins. Einzelne Aminosäuren werden in dieser Abbildung als Kreise dargestellt. Die Proteinsequenz erstreckt sich vom N-Terminus (Beginn der Polypeptidkette) bis zum C-Terminus (hier Aminosäure 173). Erstellt mit (Omasits, 2024).

Jeder Kreis in der Abbildung entspricht einer Aminosäure. Diese Aminosäuren sind miteinander über chemische Bindungen verbunden. Am Anfang der Proteinsequenz befindet sich eine H2N-Aminogruppe, die den Beginn des Proteins markiert, und am Ende der Sequenz befindet sich eine Carboxylgruppe -COOH, die das Ende des Proteins kennzeichnet. Die Abfolge und Anordnung dieser Aminosäuren bestimmt die Struktur und Funktion des Proteins.

2.1.1 Bedeutung der Primärstruktur und Bildung der Polypeptidkette

Die Primärstruktur ist die grundlegendste Strukturebene eines Proteins. Sie besteht aus der linearen Abfolge von Aminosäuren, die miteinander durch Peptidbindungen verbunden sind. Es gibt insgesamt 20 verschiedene Aminosäuren, die für die Biosynthese von Proteinen verwendet werden (die sogenannten proteinogenen Aminosäuren). Sie bestehen aus zwei chemischen Verbindungen mit einer basischen Aminogruppe (-NH2) und einer sauren Carboxylgruppe (-COOH), einem Wasserstoffatom (H) und einem Rest (R-Gruppe), der für jede Aminosäure spezifisch ist und als Seitenkette bezeichnet wird. Das wird in der Abbildung 2 gezeigt.

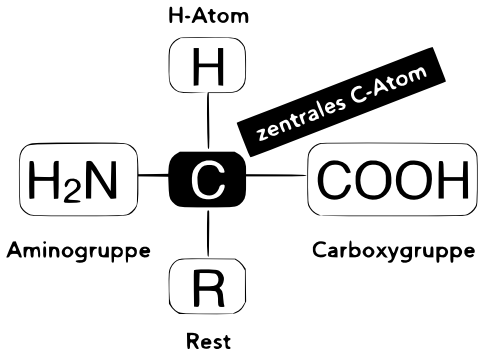


Abbildung 2: Grundgerüst einer Aminosäure. Es besteht aus einem zentralen Kohlenstoffatom (C), an das eine Aminogruppe (NH2), eine Carboxylgruppe (COOH), ein Wasserstoffatom (H) und eine variable R-Gruppe gebunden sind.(Helmich, 2023).

Die 20 proteinogenen Aminosäuren lassen sich in verschiedene Gruppen einteilen:

- Unpolare Aminosäuren: Diese haben unpolare Reste und sind Glycin, Alanin, Valin, Leucin, Isoleucin, Methionin, Phenylalanin, Tryptophan, Prolin und Cystein.
- Polar neutrale Aminosäuren: Diese haben polare Seitenketten, die weder sauer noch basisch reagieren, und sind Serin, Threonin, Tyrosin, Asparagin und Glutamin.
- Polar säure Aminosäuren: Sie haben saure Seitenketten und können Protonen abgeben. Diese sind Glutamat und Aspartat.
- Polar basische Aminosäuren: Sie haben basische Seitenketten und können Protonen aufnehmen. Diese sind Lysin, Arginin und Histidin.
- Aromatische Aminosäuren: Diese enthalten einen aromatischen Ring in ihrer Seitenkette und sind Phenylalanin, Tryptophan, Histidin und Tyrosin.
- Essentielle Aminosäuren: Diese müssen mit der Nahrung aufgenommen werden, da der Körper sie nicht selbst synthetisieren kann, und sind Valin, Leucin, Isoleucin, Phenylalanin, Tryptophan, Threonin, Lysin und Methionin.

In der Abbildung 3 wird gezeigt, dass die Aminosäure Prolin eine besondere Struktur hat. Sie besitzt keine freie Aminogruppe, wie alle anderen Aminosäuren in der Abbildung 2, und bildet einen Ring (Horn, 2015), (Whitford, 2013), (Schmidt, 2020).

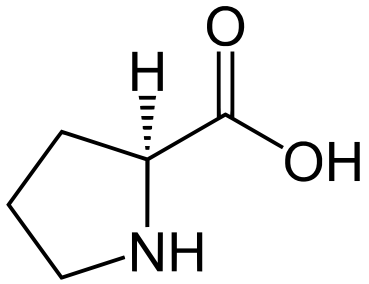


Abbildung 3: Strukturformel der Aminosäure Prolin. Die einzigartige Ringstruktur von Prolin, entstanden durch die Bindung des Seitenketten-Stickstoffs an das zentrale Kohlenstoffatom (Wik).

Die Primärstruktur eines Proteins legt nicht nur die lineare Abfolge der Aminosäuren fest, sondern beeinflusst auch die gesamte Struktur des Proteins, einschließlich seiner Sekundär-, Tertiär- und Quartärstruktur. Die spezifische Abfolge der Aminosäuren in der Primärstruktur bestimmt auch, wie sich das Protein faltet und somit seine einzigartige dreidimensionale Struktur. Diese Faltung ist für die Funktionalität des Proteins entscheidend (Horn, 2015).

Die Peptidbindung zwischen den Aminosäuren entsteht durch eine Kondensationsreaktion zwischen der Aminogruppe einer Aminosäure und der Carboxylgruppe einer anderen Aminosäure. Hier wird Wasser abgespalten. Das Ergebnis dieser Reaktion ist eine Peptidbindung, welche die beiden Aminosäuren miteinander verknüpft und eine Polypeptidkette bildet. Diese Reaktion wiederholt sich, um weitere Aminosäuren an der Peptidkette hinzuzufügen und somit die Polypeptidkette zu erweitern. Enthält die Kette nur zwei Aminosäuren, dann wird sie Dipeptid genannt, bei dreien spricht man von Tripeptiden. Eine Kette von zwei bis zehn Aminosäuren heißt Oligopeptide. Erst ab zehn Aminosäuren spricht man von einer Polypeptidkette. Die Zusammensetzung der verschiedenen Aminosäuren mit den verschiedenen Eigenschaften in der Polypeptidkette bestimmt, welche Sekundärstrukturen sich bilden können. Die Abbildung 4 zeigt die Entstehung eines Dipeptids zwischen zwei Molekülen der Aminosäure Ala unter Wasserabspaltung (Horn, 2015), (Schmidt, 2020).

2.1.2 Sekundärstruktur: Alpha-Helices und Beta-Faltblätter

Durch die Wechselwirkung bzw. die Entstehung von Wasserstoffbrückenbindungen zwischen der Carboxylgruppe und den Aminogruppen der Peptidbindungen wird die Sekundärstruktur gebildet. Die Bildung dieser Wasserstoffbrückenbindungen stabilisiert die Peptidketten und ermöglicht es ihnen, eine spezifische dreidimensionale Struktur anzunehmen. Die beiden gängigsten Sekundärstrukturen sind

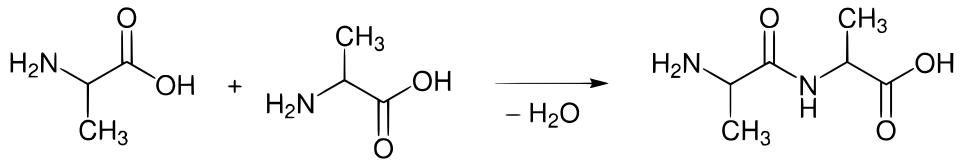


Abbildung 4: Struktur einer Peptidbindung aus zwei Aminosäuren. Diese Bindung entsteht durch die Kondensation von Carboxyl- und Aminogruppen unter Abspaltung von Wasser (Wik).

die Alpha-Helix und das Beta-Faltblatt. Die Sekundärstruktur spielt eine wichtige Rolle bei der Stabilisierung der Proteinfaltung und der Ausbildung komplexerer dreidimensionaler Strukturen. Sie trägt zur Stabilität und Funktionalität von Proteinen bei und ist ein wichtiger Bestandteil des Verständnisses ihrer Struktur-Funktions-Beziehung (Merkl, 2022).

Die Alpha-Helix ist eine schraubenförmig gewundene Anordnung einer Polypeptidkette, bei der statistisch gesehen etwa 3,6 Aminosäuren pro Windung benötigt werden. Dabei bildet jede Carboxylgruppe (CO-Gruppe) eine Bindung mit der Aminogruppe (NH-Gruppe) der vierten Aminosäure. Eine Ausnahme besteht bei der Aminosäure Prolin. Aufgrund ihres starren Rings passt sie nicht gut in die Helixstruktur und wird daher am Ende der Helix oder außerhalb davon gefunden, da sie diese Struktur nicht unterstützt (Horn, 2015),(Whitford, 2013).

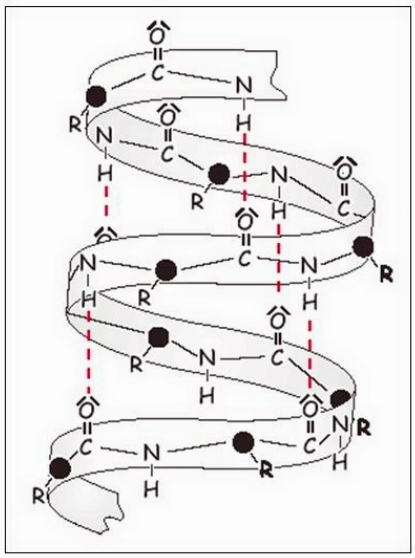


Abbildung 5: Struktur einer Alpha-Helix, bei der die Carboxylgruppe (CO-Gruppe) jeder Aminosäure eine Bindung mit der Aminogruppe (NH-Gruppe) der vierten Aminosäure bildet (Horn, 2015).

Das Beta-Faltblatt hat eine zickzackförmige Struktur und erhielt seinen Namen, weil es von Linus Pauling und Robert Corey nach der Alpha-Helix entdeckt wurde. Diese Struktur entsteht, weil die CO-NH-Gruppe der Peptidbindung starr in einer Ebene liegt, während die benachbarten Bindungen frei drehbar sind. Die Bildung von Wasserstoffbrückenbindungen zwischen den CO- und NH-Gruppen erfolgt im Beta-Faltblatt ähnlich wie bei der Alpha-Helix. Im Gegensatz zur Alpha-Helix können im Beta-Faltblatt jedoch sowohl Peptidfragmente aus einer einzelnen Kette als auch verschiedene Peptide zusammen verbunden sein. Dabei können die Stränge sowohl parallel als auch antiparallel zueinander angeordnet sein. Dies wird in der nachfolgenden Abbildung angezeigt (Horn, 2015).

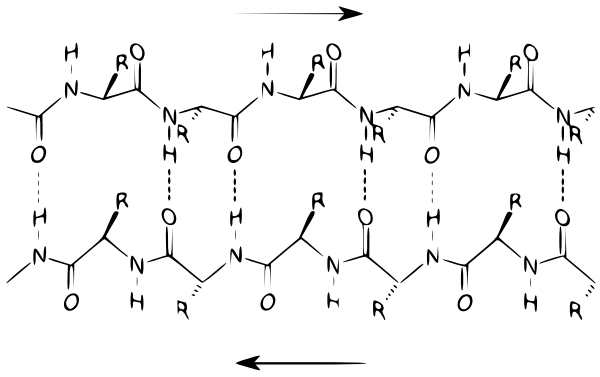


Abbildung 6: Struktur eines Beta-Faltblatts, das eine zickzackförmige Anordnung von Peptidsträngen aufweist. Diese Anordnung wird durch Wasserstoffbrückenbindungen zwischen CO- und NH-Gruppen stabilisiert (Wik).

Die Alpha-Helix und das Beta-Faltblatt sind die beiden wichtigsten Arten von Sekundärstrukturen. Neben diesen gibt es jedoch andere sekundäre Strukturen, die eine spezielle Rolle beim Richtungswechsel oder der Biegung von Alpha-Helices und Beta-Faltblättern spielen. Darüber hinaus gibt es weitere Sekundärstrukturen, die der Alpha-Helix ähneln, jedoch eine unterschiedliche Anzahl von Aminosäuren benötigen und daher eine leicht abweichende Form aufweisen (Horn, 2015).

2.2 Auswirkungen der Proteinstruktur auf die Funktion

Die Positionierung einzelner Aminosäuren im gefalteten Zustand eines Proteins hat einen entscheidenden Einfluss auf dessen Funktion und Wechselwirkung mit der Umgebung. In hydrophoben Umgebungen weisen Proteine häufig nichtpolare Seitenketten auf, während sie in wässrigen Umgebungen eher polare Seitenketten besitzen, die sich mit dem umgebenden Wasser integrieren. Aminosäuren wie Arginin und Lysin, die eine positive Ladung tragen, sind oft an der interagierenden Oberfläche von Proteinen zu finden, die mit negativ geladenen Molekülen interagieren. Im Gegensatz dazu befinden sich Asparaginsäure und Glutaminsäure, die negative Ladungen tragen, häufig auf der interagierenden Oberfläche von Proteinen, die mit positiv geladenen Molekülen interagieren. Die Flexibilität von Glycin und Alanin aufgrund ihrer geringen Größe ermöglicht es ihnen, leicht in enge Räume einzupassen.

In der Nähe von Biegungen in Polypeptidketten anzutreffen, bildet Prolin eine nützliche Knickstruktur in der Proteinstruktur, die dazu beiträgt, die Proteinstruktur um enge Ecken zu lenken (Choudhuri, 2014).

2.2.1 Proteindomänen

Eine Proteindomäne ist ein gefalteter Abschnitt einer längeren Polypeptidkette, der sich in der Regel unabhängig von den anderen Domänen des Proteins faltet. Diese Domäne ist oft für die Ausführung einer spezifischen Funktion dieses Proteins verantwortlich. Größere Proteine bestehen aus verschiedenen Domänen, wobei Polypeptidketten mit mehr als etwa 200 Aminosäureresten oft in zwei oder mehr unabhängige Domänen gefaltet sind (Christen et al., 2015).

2.3 Proteindatenbanken

Um ein Verständnis für die umfangreichen Proteindaten zu entwickeln und ihre Analyse durchzuführen, ist es von entscheidender Bedeutung, diese Daten zu sammeln und in einem Format zu speichern, das eine einfache Durchsuchung und Analyse ermöglicht. Bereits in den frühen 1960er Jahren wurden die 65 gesammelten Proteinsequenzen in einem Buch mit dem Namen „Atlas of Protein Sequence and Structure“ veröffentlicht. Seit dieser Zeit bis heute wurden zahlreiche Datenbanken für Proteindaten mit Millionen von Einträgen entwickelt, ebenso wie eine Vielzahl von Datenformaten für die Speicherung dieser Daten. Es wird zwischen zwei Arten von Datenbanken unterschieden. Primäre Datenbanken enthalten experimentelle Daten, die direkt aus Experimenten stammen, während sekundäre Datenbanken Informationen sammeln, die aus diesen experimentellen Daten abgeleitet wurden (Merkl, 2022), (Baxevanis et al., 2020).

2.3.1 NCBI

Das National Center for Biotechnology Information wurde 1988 gegründet. Es ist eine primäre Datenbank und stellt Sequenzdaten aus verschiedenen Ressourcen wie beispielsweise GenBank für DNA- und RNA-Sequenzen oder Entrez (ein Abfragesystem, das auf verschiedene NCBI-Datenbanken zugreift) zur Verfügung. Daher wird es auch als integrierte Datenbank bezeichnet. Das NCBI bietet ein Web-Interface, das unter `https://www.ncbi.nlm.nih.gov/` erreichbar ist. Über diese Plattform können Benutzer auf eine Vielzahl von Datenbanken und Ressourcen zugreifen, Daten anzeigen und nach Sequenzen anhand einer eindeutigen Sequenz-ID suchen. Aufgrund der Redundanz in der Datenbank, die Analysen beeinträchtigen könnte, wurde die NCBI-RefSeq-Datenbank entwickelt, die unter `https://www.ncbi.nlm.nih.gov/refseq/` erreichbar ist (Pettersson et al., 2006), (Merkl, 2022).

2.3.2 PDB

Die Protein Data Bank PDB ist eine primäre Datenbank, die eine umfangreiche Sammlung von dreidimensionalen Strukturdaten von Biomolekülen enthält. Sie enthält Informationen über die räumliche

Anordnung von Atomen in Proteinen, Nukleinsäuren und anderen biologischen Molekülen (Zardecki et al., 2022).

2.3.3 Uniport

Die UniProt-Datenbank ist eine primäre Datenbank und umfasst im April 2022 etwa 230 Millionen Datensätze, die in sämtlichen Lebensbereichen vorkommen. Die neueste Version der UniProtKB, veröffentlicht am Mittwoch, dem 24. Januar 2024, enthält insgesamt 250.322.721 Einträge. Die UniProt wird als eine nicht redundante Datenbank bezeichnet (Hansen, 2013), (UniProt, 2024), (Consortium, 2022).

2.4 Weitere Datenbanken

2.4.1 Smart

SMART (Simple Modular Architecture Research Tool) ist ein Werkzeug zur Analyse von Proteindomänen. Es erkennt und beschreibt funktionelle Domänen in Proteinen. Die Grundlage der SMART-Datenbank bilden Einträge aus UniProt. Sie ist unter `http://smart.embl-heidelberg.de` erreichbar (Merkl, 2022).

2.4.2 Interpro

InterPro ist eine Sekundärdatenbank und klassifiziert Proteine in Familien und sagt Domänen sowie wichtige Stellen in der Sequenz voraus. Es bietet Zugriff auf 13 verschiedene Datenbanken, darunter SMART und Pfam. Somit fungiert InterPro als eine einheitliche Schnittstelle und Nomenklatur für diese wichtigen sekundären Datenbanken (Merkl, 2022). Darüber hinaus ermöglicht die Integration der Ergebnisseite eine schnelle Vergleichbarkeit der Ausgaben einzelner Abfragen. Dadurch können die Vor- und Nachteile der verschiedenen Datenbanken effizient berücksichtigt werden. Sie ist unter `https://www.ebi.ac.uk/interpro/` erreichbar (Selzer et al., 2018).

2.5 Grundlagen der Sequenzalignment

Der Vergleich von Sequenzen, auch Sequenzalignierung genannt, ist von zentraler Bedeutung für die bioinformatische Analyse und bildet den ersten Schritt bei der Untersuchung neu entdeckter Sequenzen. Dieser Vergleich dient dazu, Funktionen und Evolutionsmuster zu erforschen sowie neue Proteine mit bereits in der Datenbank vorhandenen Proteinen abzugleichen. Es gibt verschiedene Arten von Sequenzalignments, die sich hinsichtlich der Anzahl der verglichenen Sequenzen und der Vergleichsmethode unterscheiden. Wenn nur zwei Sequenzen verglichen werden, spricht man von paarweisem Sequenzalignment. Beim Multiple Sequence Alignment (MSA) werden dagegen mehr als zwei Sequenzen gleichzeitig verglichen. Hinsichtlich der Vergleichsmethode unterscheidet man zwischen globalen und lokalen Alignments.

Hier ist ein Beispiel von drei verschiedenen globalen paarweisen Alignments mit denselben DNA-Sequenzen, die aus den Nukleinbasen Adenin (A), Cytosin (C), Guanin (G) und Thymin (T) bestehen:

```
C  G  A  T  C  -  C  T  G  T
C  -  A  T  C  G  C  C  T  T
```

in diesem Alignment gibt es 6 identische Positionen

```
C  G  A  T  -  -  C  C  T  G  T
C  -  A  T  C  G  C  C  T  -  T
```

in diesem Alignment gibt es 7 identische Positionen

```
C  G  A  T  C  C  T  G  T
C  A  T  C  G  C  C  T  T
```

in diesem Alignment gibt es 3 identische Positionen

Es wurde hier anhand des Beispiels gezeigt, dass aus zwei identischen Sequenzen mehrere Alignments gebildet werden können. Daher ist es wichtig, ein optimales Alignment aus den gegebenen Sequenzen zu finden. Ein optimales Alignment sollte darauf abzielen, die Ähnlichkeit dieser Sequenzen zu maximieren. Der erste Schritt zur Bewertung von Ähnlichkeiten besteht darin, ein Ähnlichkeitsmaß bzw. ein Bewertungsverfahren zwischen den Sequenzen einzuführen. Für die DNA-Sequenzen gibt es ein etabliertes Bewertungsverfahren (Scoring-Modell). Das besagt, dass für jede Übereinstimmung (Match) ein Punkt und für jeden Unterschied (Mismatches) ein Punkt abgezogen wird. Die Summe aller Punkte ergibt dann die Bewertung oder den Score dieses Alignments. Die Einfügung von Lücken (Gaps), um das bessere Alignment zu erreichen, wird separat behandelt. Es wird zwischen zwei Arten von Gaps unterschieden: einerseits die sogenannte Gap-Opening-Penalty, bei der ein neues Gap entsteht, und andererseits die Gap-Extension-Penalty, bei der ein bereits vorhandenes Gap verlängert wird. Hier gibt es verschiedene Modelle, wie sich diese Bewertung auf den Score auswirkt. Diese Bewertung wird als Kosten bezeichnet, und wie sich diese Kosten zusammensetzen, ergibt die sogenannte Kostenfunktion, die sich je nach Anwendung variieren kann (Hütt and Dehnert, 2015), (Xiong, 2006).

Es wird zwischen zwei Arten von Alignments unterschieden:

- Globales Alignment: Bei einem globalen Alignment erfolgt der Vergleich von vollständigen Sequenzen über ihre gesamte Länge hinweg.

```
A C T A G A T T A C T T A C G G A T
A C T A G A T T - - - - A C G G A T
```

- Lokales Alignment: Bei einem lokalen Alignment werden lediglich ähnliche Teilbereiche der Sequenzen miteinander verglichen. Dabei wird oft eine kürzere Sequenz innerhalb einer längeren gesucht. Auf diese Weise können beispielsweise Domänen in Proteinsequenzen identifiziert werden.

```
A G A T T A C T T A C G G A T C
          T A C T C A C G
```

2.5.1 Substitutionsmatrix

Die Übereinstimmung ist bei einfachen Zeichenketten einfach zu bestimmen, da jede Abweichung eine klare Unstimmigkeit darstellt. Bei Proteinsequenzen ist dies jedoch anders, da ähnliche Aminosäuren als Match betrachtet werden können, während unähnliche Aminosäuren als Mismatch betrachtet werden. Diese Unterscheidung zwischen ähnlichen und unähnlichen Aminosäuren lässt sich mithilfe von Substitutionsmatrizen erzielen. Für die Erstellung einer Substitutionsmatrix für Aminosäureaustausche ist erstmal die Bestimmung eines Austauschmusters erforderlich. Dies wurde durch Margaret Dayhoff 1978 erreicht. Es wurden 34 homologe Proteine, also Proteine, die aufgrund einer gemeinsamen evolutionären Abstammung ähnliche Sequenzen oder Strukturen aufweisen, untersucht. Es wurde in allen Alignments gezählt, wie oft eine Aminosäure durch eine andere ersetzt wurde. Diese Zahlen wurden dann in einer 400-Felder-Matrix, bekannt als PAM-Matrix, festgehalten (20 Aminosäuren * 20 Aminosäuren). Nachfolgend ist diese Matrix 7 zu sehen.

	A Ala	R Arg	N Asn	D Asp	C Cys	Q Gln	E Glu	G Gly	H His	I Ile	L Leu	K Lys	M Met	F Phe	P Pro	S Ser	T Thr	W Trp	Y Tyr	V Val
A																				
R	30																			
N	109	17																		
D	154	0	532																	
C	33	10	0	0																
Q	93	120	50	76	0															
E	266	0	94	831	0	422														
G	579	10	156	162	10	30	112													
H	21	103	226	43	10	243	23	10												
I	66	30	36	13	17	8	35	0	3											
L	95	17	37	0	0	75	15	17	40	253										
K	57	477	322	85	0	147	104	60	23	43	39									
M	29	17	0	0	0	20	7	7	0	57	207	90								
F	20	7	7	0	0	0	0	17	20	90	167	0	17							
P	345	67	27	10	10	93	40	49	50	7	43	43	4	7						
S	772	137	432	98	117	47	86	450	26	20	32	168	20	40	269					
T	590	20	169	57	10	37	31	50	14	129	52	200	28	10	73	696				
W	0	27	3	0	0	0	0	0	3	0	13	0	0	10	0	17	0			
Y	20	3	36	0	30	0	10	0	40	13	23	10	0	260	0	22	23	6		
V	365	20	13	17	33	27	37	97	30	661	303	17	77	10	50	43	186	0	17	

Abbildung 7: Anzahl der spezifischen Austausche (PAMs) aus 1572 beobachteten Austauschen von Aminosäuren in verwandten Proteinen. (Nach Dayhoff 1978) (Lohrer, 2022).

Bei PAM-Matrizen handelt es sich um Substitutionsmatrizen, die hauptsächlich für die Berechnung von Ähnlichkeiten basierend auf globalen Alignments entwickelt wurden. Um lokale Alignments zu untersuchen, wurden BLOSUM-Matrizen entwickelt. Es gibt verschiedene Substitutionsmatrizen, die je nach Anwendungsgebiet genutzt werden können (Lohrer, 2022), (Hansen, 2013).

2.6 Multiple Sequenzalignment (MSA)

Der Vorteil von MSA liegt darin, dass es mehr biologische Informationen liefert als viele einzelne paarweise Alignments. Durch den Vergleich mehrerer Sequenzen können konservierte Sequenzmuster und Motive innerhalb einer Sequenzfamilie identifiziert werden, was durch den Vergleich nur zweier Sequenzen möglicherweise nicht ersichtlich ist. Es gibt verschiedene Algorithmen zur Bestimmung von Alignments, wobei die Herausforderung bei der MSA größer ist als bei der paarweisen Alignments. Dies liegt daran, dass viele vorhandene Algorithmen mit zunehmender Anzahl von Sequenzen exponentiell mehr Rechenzeit benötigen. Daher werden in der MSA bestimmte Algorithmen verwendet, um diese Probleme zu bewältigen (Xiong, 2006). Die progressiven Algorithmen sind die am häufigsten verwendeten Algorithmen für das Multiple Alignment (Katoh and Toh, 2008).

Hier ist ein Beispiel, das die Problematik mit der Zunahme der Anzahl der Sequenzen erläutert:
Angenommen, es gäbe drei Sequenzen, die verglichen werden sollen, also ein MSA (multiple Sequenzalignment) aus drei Sequenzen. Es muss ein Score für dieses MSA mit der sogenannten Levenshtein-Distanz berechnet werden, genauso wie beim paarweisen Alignment nach dem Standardverfahren.

	1	2	3	4	5	6
Sequenz 1	A	T	A	A	G	C
Sequenz 2	A	$-$	A	T	G	C
Sequenz 3	A	$-$	A	A	G	C

Dabei ergeben sich drei Scores für die drei Sequenzkombinationen im paarweisen Vergleich.
Dabei gilt: $s(a, a) = 1$, $s(a, b) = -1$ und $s(a, \epsilon) = -2$.

Für das paarweise Alignment ergeben sich folgende Scores:

- Sequenz 1 mit Sequenz 2: 1
- Sequenz 1 mit Sequenz 3: 3
- Sequenz 2 mit Sequenz 3: 3

Der Gesamtscore beträgt (1+3+3) = 7 . Daher ist der Aufwand für das Alignment von Sequenzen der Länge n in Bezug auf die Anzahl der Sequenzen z $O(n^z)$ (Merkl, 2022).

2.6.1 ClustalW

Der ClustalW Algorithmus wird zur Durchführung von Multiplen Sequenzalignments (MSA) verwendet. Er nutzt eine progressive Alignierungsstrategie, die in mehreren Schritten durchgeführt wird:

- **Paarweises Alignment:** Zunächst werden alle paarweisen Alignments gebildet, und ein Score für jedes Paar wird berechnet.
- **Distanzmatrix:** Diese Scores werden in einer Ähnlichkeitsmatrix eingetragen. Dies geschieht unter Verwendung einer bestimmten Substitutionsmatrix wie BLOSUM.
- **Aufbau des Guide Trees:** Basierend auf den berechneten Scores zwischen den Sequenzen aus der Distanzmatrix wird ein Guide Tree mit dem Neighbor-Joining-Algorithmus gebildet. Dieser Baum repräsentiert die evolutionäre Beziehung zwischen den Sequenzen.
- **Progressive Alignierung:** Die Sequenzen werden basierend auf ihrer Position im binären Baum (Guide Tree) paarweise aligniert oder dem bestehenden Alignment hinzugefügt. Dabei wird von demjenigen Knoten des Baums ausgegangen, der als erster in den Baum eingefügt wurde, also den besten Score oder die meisten Übereinstimmungen aufweist.

Die nachfolgende Abbildung verdeutlicht das Verfahren eines multiplen Alignments.

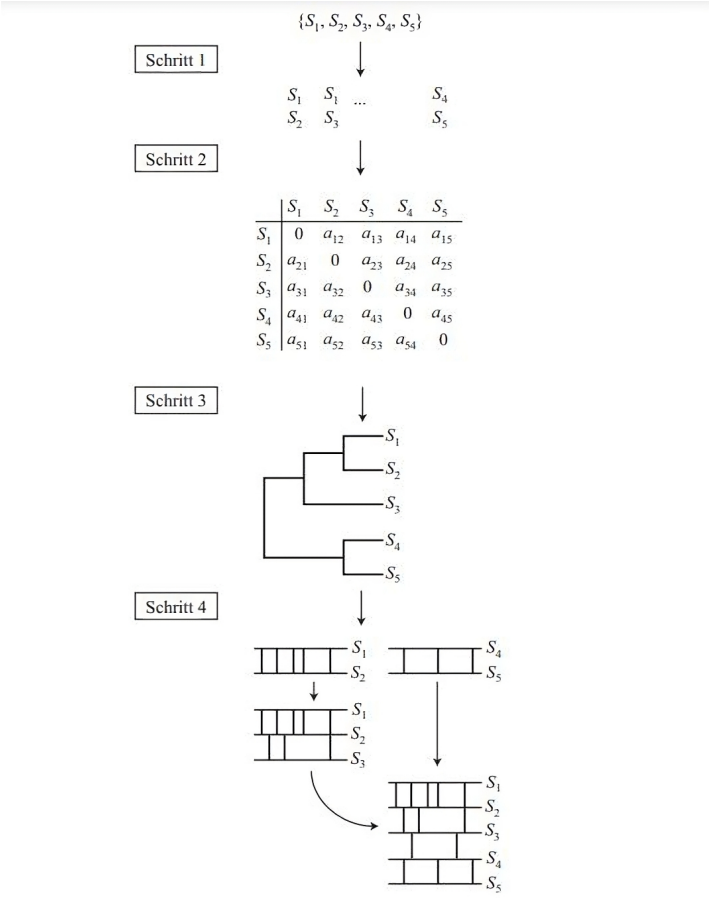


Abbildung 8: Ablaufschema eines multiplen Alignments, das folgende Schritte umfasst: (1) Paarweises Alignment, (2) Erstellung einer Distanzmatrix, (3) Aufbau des Guide Trees und (4) Progressive Alignierung (Hütt and Dehnert, 2015).

Der Algorithmus wird anhand eines Beispiels veranschaulicht. Im ersten Schritt wurden die Scores für alle paarweisen Alignments berechnet. Dabei entspricht die Spalte Len der Länge der Sequenz, und die Spalte Score gibt den Score für das paarweise Alignment der beiden Sequenzen in dieser Zeile an:

Tabelle 1: Score aller paarweisen Alignments der Sequenzen SeqA und SeqB (Merkl, 2022).

SeqA	Name	Len	SeqB	Name	Len	Score
1	EETIII	30	2	li_Mutant	28	96
1	EETIII	30	3	BDTIII	29	82
1	EETIII	30	4	CMeTIB	29	68
1	EETIII	30	5	CMTIIV	32	66
1	EETIII	30	6	CSTIIIB	32	60
1	EETIII	30	7	MRTII	29	68
1	EETIII	30	8	MTCIS	28	57
1	EETIII	30	9	ITRA_MOMCH	28	57
2	Ii_Mutant	28	3	BDTIII	29	82
2	Ii_Mutant	28	4	CMeTIB	29	67
2	Ii_Mutant	28	5	CMTIIV	32	67

Anhand der Scores aus der Tabelle wird ein Guide Tree rekonstruiert, wobei der beste Score in der ersten Zeile bei 96 liegt. Die beiden Proteine mit der höchsten prozentualen Paaridentität (EETIII, li_Mutant) haben auch die kürzesten Verbindungszweiglängen im Baum.

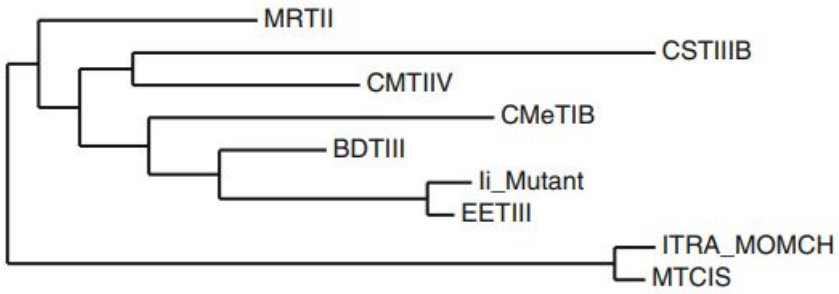


Abbildung 9: Rekonstruktion des Guide Trees anhand der Scores aus der Tabelle (Merkl, 2022).

im letzten Schritt werden die Sequnzen basirend auf ihrer Position im Guide Tree wieder paarweise aligniert

```
EETIII,        ----GCPRILMRCKQDSDCLAGCVCGPN-GFCGSP
Ii Mutant,     ----GCPRLLMRCKODSDCLAGCVCGPN-GFCG--
BDTIII,        ---RGCPRILMRCKRDSDCLAGCVCOKN-GYCG--
CMeTIB,        ---VGCPRILMKCKTDRDCLTGCTCKRN-GYCG--
CMTIIV,      HEERVCPRILMKCKKDSDCLAECVCLEH-GYCG--
CSTIIIB,       ---MVCPKILMKCKHDSDCLLDCVCLEDIGYCGVS
MRTII,         ---GICPRILMECKRDSDCLAQCVCKRQ-GYCG-
MTCIS,         ---RICPRIWMECTRDSDCMAKCICVAG--HCG--
ITRA MOMCH,    ---RSCPRIWMECTRDSDCMAKCICVAG--HCG--
```

In diesem Algorithmus besteht jedoch die Einschränkung, dass die Berechnung der Distanz von einem globalen Alignment abgeleitet wird. Das bedeutet, dass ClustalW für Sequenzmengen, die nur eine einzige Domäne gemeinsam haben (also nur einen kleinen Teil übereinstimmender Sequenzen aufweisen und ansonsten deutlich voneinander abweichen), nicht geeignet ist. Stattdessen muss ein Verfahren verwendet werden, das auch das lokale Sequenzalignment berücksichtigt (Merkl, 2022).

2.6.2 T-Coffee

T-Coffee ist eine Weiterentwicklung von ClustalW und basiert ebenfalls auf einer progressiven Alignmentsstrategie. Allerdings unterscheidet sich die Berechnung der Scores von T-Coffee von der von ClustalW. T-Coffee verwendet zwei verschiedene paarweise Alignment-Techniken, um die Scores zu generieren. Die erste Technik basiert auf einem globalen Alignment, das mit ClustalW durchgeführt wird. Die zweite Technik hingegen verwendet ein lokales Alignment. Die Alignments werden mit einem Score versehen, der als Nebenbedingung betrachtet wird. Um den größten Informationsgehalt aus den paarweisen Alignments zu gewinnen, nutzt T-Coffee die sogenannte Bibliothekserweiterung. Dabei wird eine dritte Sequenz als Referenzsequenz verwendet, um den Score des ursprünglichen Alignments weiter zu verfeinern.

Folgendes ist ein Beispiel für den paarweisen Sequenzvergleich mit vier Sequenzen, Seq1, Seq2, Seq3 und Seq4:

Die Alignments wurden basierend auf dem Anteil identischer Residuen (ohne Berücksichtigung von Gaps) bewertet. Seq1 und Seq2 haben einen Score von 88, während Seq3 und Seq4 einen Score von 100 haben. Die Sequenzen Seq1 und Seq3 haben einen Score von 77.

```
Seq1  GARFIELD THE LAST FAT CAT
Seq2  GARFIELD THE FAST CAT
```

```
Seq3  GARFIELD THE VERY FAST CAT
Seq4  -------- THE ---- FA-T CAT ---
```

```
Seq1  GARFIELD THE LAST FA-T CAT
Seq3  GARFIELD THE VERY FAST CAT
```

Die Scores dieser paarweisen Alignments werden noch mithilfe einer dritten Sequenz bewertet. Im gezeigten Beispiel werden Seq1 und Seq2 unter Verwendung von Seq3 transitiv aligniert.

```
Seq1  GARFIELD THE LAST FA-T CAT
Seq3  GARFIELD THE VERY FAST CAT
Seq2  GARFIELD THE ---- FAST CAT
```

Für Seq1 und Seq3 ergibt sich ein Score von 77, während Seq3 und Seq2 ein Score von 100 haben. Für die Berechnung des neuen Scores des Alignments aus Seq1 und Seq2 wird das Minimum aus dem Beispiel mit der transitiven Seq3 genommen und zum ursprünglichen Score addiert.

$$\text{Score}(\text{Seq1}, \text{Seq2}) = \text{Score}(\text{Seq1}, \text{Seq2}) + \min\left(\text{Score}(\text{Seq1}, \text{Seq3}), \text{Score}(\text{Seq2}, \text{Seq3})\right)$$

$$\text{Score}(\text{Seq1}, \text{Seq2}) = 88 + 77.$$

Nachdem alle Scores berechnet wurden, erstellt T-Coffee die endgültige MSA mithilfe progressiver Alignments. Dieser Ansatz zielt darauf ab, die Qualität des MSA zu verbessern, indem zusätzliche Informationen aus den Alignments gewonnen werden. (Merkl, 2022), (Russell, 2014).

2.6.3 MAFFT

MAFFT ist eine Methode zur Erstellung von MSA, die zwei verschiedene Heuristiken implementiert: die progressive Methode (FFT-NS-1), (FFT-NS-2) und die iterative Verfeinerungsmethode (FFT-NS-i). Diese Methoden nutzen die Fourier-Transformation (FFT) als Kernkomponente für ihre Berechnungen. Die Rechenzeit von FFT Algorithmen ist im Vergleich zu ClustalW oder T-Coffee. bei vergleichbarer Genauigkeit deutlich reduziert.

- FFT-NS1: nutzt den FFT-Algorithmus und eine normalisierte Ähnlichkeitsmatrix, um ein Guide Tree aufzubauen. Dabei werden die Werte in dieser Matrix normalisiert, wobei verschiedene Faktoren berücksichtigt werden, wie die physikochemischen Eigenschaften von Aminosäuren. Durch die Normalisierung wird sichergestellt, dass der Austausch bestimmter Aminosäuren keinen signifikanten Einfluss auf die Proteinstruktur hat und die Struktur erhalten bleibt, während ein anderer Austausch möglicherweise völlig unterschiedlich wirken könnte. Dies macht auch die Suche nach Homologen innerhalb der Sequenzen effizienter. Der aufgebaute Guide Tree dient dann als Grundlage für den Alignierungsprozess, indem er die Reihenfolge angibt, in der die Sequenzen aligniert werden sollen, was zur effizienten Erstellung des finalen Multiple Sequence Alignments beiträgt.
- FFT-NS-2: nutzt den Guide Tree, der durch FFT-NS-1 abgeleitet wurde. Die Eingabesequenzen werden entlang dieses Guide Trees neu ausgerichtet. FFT-NS-2 ist somit eine Methode zur Verbesserung der Alignmentsqualität.
- FFT-NS-i: Die Genauigkeit der progressiven Ausrichtung kann durch die iterative Verfeinerungsmethode verbessert werden. In FFT-NS-i wird ein initiales Alignment durch FFT-NS-2 einem iterativen Verfeinerungsprozess unterzogen (Katoh, 2024), (Katoh et al., 2002).

2.7 Bestimmung von 3D-Proteinstrukturen

2.7.1 FASTA

FASTA ist eines der am häufigsten verwendeten Sequenzformate in der Bioinformatik, aufgrund seiner einfachen Struktur und seiner Lesbarkeit für viele Analyseprogramme. Die Sequenz wird durch eine einzige Zeile definiert, die mit einem spitzen Spizenklammer (>) beginnt, gefolgt vom Sequenznamen. Daran kann sich noch eine Beschreibung der Sequenz anschlieden. In der zweiten Zeile steht die eigentliche Sequenz (Xiong, 2006), (Baxevanis et al., 2020).

Nachfolgend ist ein Beispiel für eine FASTA-Datei aus der Proteinfamilie 5.1.5:

```
>sp|Q8R454|KCNK1_CAVPO Potassium channel subfamily K member 1 OS=Cavia porcellus
MLQSLAGSSCVRLVERHRSAWCFGLLVLGYLLYLVFGAVVFSSVELPYEDLLRQELRKLK
```

```
RRFLEEHECLSEPQLEQFLGRVLEASNYGVSVLSNASGNWNWDFTSALFFASTVLSTTGY
GHTVPLSDGGKAFCIIYSVIGIPFTLLFLTAVVQRITVHVTRRPVLYFHIRWGFSKQMVG
IVHAVVLGFVTVSCFFFIPAAVFSVLEDDWNFLESFYFCFISLSTIGLGDYVPGEGYNQK
FRELYKIGITCYLLLGLIAMLVVLETFCELHELKKFRKMFYVKKDKDEDQVHIVEHDQLS
FSSITDQAASVKEEQKQSEPFVAAQVSAYAEDSASH
```

2.7.2 DSSP

Die DSSP-Methode (Define Secondary Structure of Proteins) dient dazu, Sekundärstrukturannotationen einer Proteinstruktur zuzuweisen. Sie nutzt die atomaren Koordinaten einer Struktur, um die entsprechenden sekundären Codes zuzuweisen. Hier sind die Sekundärstrukturen, die identifiziert werden können (Klose et al., 2010), (Systems Biology Research Group), (dss).

- **H :** Eine regelmäßige, rechtsgängige Helixstruktur, die typischerweise etwa 3,6 Aminosäurereste pro Umdrehung enthält.
- **B :** Einzelner Aminosäurerest, der Teil einer β-Faltblattstruktur ist, jedoch nicht Teil einer längeren Kette von β-Faltblattstrukturen.
- **G :** Eine 3-Helixstruktur, die etwa drei Aminosäurereste pro Umdrehung aufweist. Im Gegensatz zur regelmäßigen H-Helix bildet die Carboxylgruppe (CO-Gruppe) eine Bindung mit der Aminogruppe (NH-Gruppe) des dritten Aminosäurerests, nicht des vierten.
- **I :** Eine 5-Helixstruktur, bei der die Carboxylgruppe (CO-Gruppe) eine Bindung mit der Aminogruppe (NH-Gruppe) des fünften Aminosäurerests bildet, nicht des vierten wie bei der regelmäßigen H-Helix.
- **S :** Ein Aminosäurerest, der an einer flexiblen Biegung in der Proteinstruktur beteiligt ist.
- **T :** Ein Aminosäurerest, der an einer Schleife oder einem Wendel in der Proteinstruktur beteiligt ist und eine Wasserstoffbrückenbindung aufweist.
- **E :** Ein Aminosäurerest, der Teil einer längeren Kette von β-Faltblattstrukturen ist und an einer β-Leiter teilnimmt.
- **- :** keine Zuordnung

2.7.3 Alphafold

Die Lücke zwischen bekannten Proteinsequenzen und experimentell ermittelten 3D-Strukturen wird aufgrund der Schwierigkeiten bei der Bestimmung von Proteinstrukturen mit experimentellen Techniken immer größer. Im Jahr 2022 enthält UniProt über 230 Millionen Proteinsequenzen, während die Protein Data Bank (PDB) etwa 200.000 Strukturen für rund 60.000 einzigartige Proteine enthält. In diesem Jahr gab es einen Durchbruch, bei dem es mithilfe künstlicher Intelligenz möglich wurde, die 3D-Struktur von Proteinen anhand ihrer Aminosäuresequenz vorherzusagen. AlphaFold ist ein KI-System, das von Google DeepMind entwickelt wurde. Es kann die 3D-Struktur von Proteinen anhand ihrer Aminosäuresequenz vorhersagen. Die aktuelle Version der Datenbank umfasst mehr als 200 Millionen Einträge und deckt den gesamten Umfang von UniProt ab (Varadi and Velankar, 2023), (Alphafold-Webseite).
Es gibt drei Hauptansätze zur Vorhersage von Proteinstrukturen:

- **Homologie Modellierung:** Sie basiert auf der Hypothese, dass die Konsistenz der 3D-Strukturen von Proteinen größer ist als die Konsistenz ihrer Aminosäuresequenzen. Daher wird angenommen, dass ähnliche Aminosäuresequenzen ähnliche 3D-Strukturen aufweisen sollten. Der Ablauf der Homologiemodellierung ist wie folgt: Als Eingabe dient eine Aminosäuresequenz (Zielsequenz). Im ersten Schritt werden homologe Sequenzen aus Protein-Datenbanken gesucht. Diese Zielsequenz wird dann mit den homologen Templates aligniert. Bereiche mit hoher Sequenzähnlichkeit zwischen Ziel und Template werden identifiziert. Anschließend werden die Koordinaten der Aminosäuren der bekannten Struktur homologer Proteine als Koordinaten der entsprechenden Aminosäuren des Zielproteins übernommen. Schließlich wird eine 3D-Struktur generiert, basierend auf diesen Erkenntnissen aus den homologen Templates. Die Vorteile dieser Modellierungsart liegen in ihrem einfachen Algorithmus, ihrer schnellen Vorhersagegeschwindigkeit und ihrer hohen Genauigkeit für Proteine, deren homologe Strukturen bekannt sind. Ein bedeutender Nachteil besteht jedoch darin, dass die Vorhersage stark von den verfügbaren Vorlagenstrukturen abhängt. Das bedeutet, dass bei fehlenden passenden homologen Strukturen für eine gegebene Sequenz keine Vorhersage möglich ist.

- **De-novo-Modellierung:** Sie basiert auf physikalischen Gesetzen und nicht auf vorhandenen Proteinstrukturen. Sie nutzt eine Energiefunktion, die die Energie einer Proteinfaltung vorhersagt, basierend auf der räumlichen Anordnung der Aminosäuren, um die optimale Konformation zu finden, und kann so neue Proteinstrukturen entdecken. Jedoch sind die Berechnungen aufgrund der Komplexität der freien Energiefunktion und des großen Konformationsraums herausfordernd. Daher ist diese Methode hauptsächlich für kleine Proteine mit weniger als 80 Aminosäureresten geeignet.

- **ML-basierte Modellierung:** Die ML-basierte Modellierung nutzt ML-Algorithmen in Verbindung mit bekannten Proteinstrukturen, um Vorhersagen über die Strukturen von Zielproteinen zu treffen. Dieser Ansatz wird auch in AlphaFold verwendet (Yang et al., 2023), (Steger, 2013).

2.8 Proteinmodellierung mit Molecular Operating Environment (MOE)

Die Molecular Operating Environment (MOE) ist eine interaktive Software für chemische Berechnungen und Molekülmodellierung. Sie bietet eine Vielzahl wissenschaftlicher Anwendungen, darunter Modellierung sowie Alignierung von Proteinen in der dreidimensionalen Struktur. Sie verwendet eine modifizierte Version eines Algorithmus, der ursprünglich für das globale Sequenzalignment von zwei Sequenzen entwickelt wurde und von Needleman im Jahr 1970 eingeführt wurde. Dieser Algorithmus basiert auf dynamischer Programmierung, bei der das Problem in kleinere Teilprobleme aufgeteilt wird, um diese einfacher zu lösen und dann die Lösungen zu kombinieren, um das Gesamtproblem zu lösen. Der Needleman-Wunsch-Algorithmus bewertet alle möglichen Alignments zwischen den Sequenzen, um dasjenige mit der höchsten Ähnlichkeit zu finden. Das Ergebnis des Algorithmus ist ein Alignment, das die optimale Übereinstimmung zwischen den beiden Sequenzen darstellt.Außerdem enthält MOE verschiedene Ähnlichkeitsmatrizen, wie BLOSUM 30, 55, 60 oder PAM 60, 70, 80, die sich im Verzeichnis $MOE/lib/matrix befinden.

Die Sequenzalignierung in MOE erfolgt in vier Schritten:

1. Aufbau des initialen Paarweisen Alignments: Es gibt zwei Möglichkeiten, das Alignment zu erstellen.

   - Progressive: Hier werden zunächst die Sequenzen 1 und 2 aligniert, und dann wird die Sequenz 3 auf das resultierende Alignment ausgerichtet. Dieser Vorgang wird fortgesetzt, bis alle Sequenzen aligniert sind. Der Nachteil hierbei ist, dass diese Methode empfindlich auf die Reihenfolge der Sequenzen reagieren kann.
   - Baumbasiert: Hier werden alle Alignmentscores zwischen allen möglichen Paaren von Sequenzen berechnet. Das Alignment wird mit dem höchsten paarweisen Score aufgebaut. Diese Methode ist nicht empfindlich auf die Reihenfolge der Sequenzen.

2. Round-Robin-Neualignierung: Die entstehenden Alignments werden jetzt durch diese Neuausrichtung verfeinert, bei der jede Sequenz nacheinander aus dem globalen Alignment extrahiert und gegen die verbleibenden Sequenzen neu ausgerichtet wird.

3. Randomisierte iterative Verfeinerung: Da die Rundum-Neuausrichtung ebenfalls empfindlich auf die Reihenfolge der Sequenzen reagieren kann, wird diese Empfindlichkeit verringert, indem eine neue Ausrichtung durchgeführt wird, bei der die Sequenzen in zwei zufällige Gruppen aufgeteilt werden und die Neuausrichtung innerhalb dieser beiden Teilgruppen erfolgt. Wenn die neue Ausrichtung den Alignmentscore verbessert, wird sie akzeptiert; andernfalls wird sie abgelehnt, und die Alignments aus der Rundum-Neuausrichtung werden beibehalten.

4. Strukturbasierte Neualignierung: Die Sequenzen werden unter Berücksichtigung ihrer Struktur neu aligniert. Zuerst werden die Proteinsequenzen untersucht, um diejenigen zu identifizieren,

die vollständige strukturelle Informationen besitzen. insbesondere die Alpha-Kohlenstoffatome. Diese Sequenzen werden als strukturierte Sequenzen betrachtet. Anschließend erfolgt eine initiale Schätzung des Alignments aller Sequenzen.
Für dieses Alignment wird eine initiale Ähnlichkeitsmatrix erstellt. Diese Matrix berücksichtigt die tatsächliche räumliche Anordnung der Alpha-Kohlenstoffatome in den strukturierten Sequenzen. Dazu wird eine Superposition verwendet, um die strukturierten Sequenzen so zu überlagern, dass ihre Alpha-Kohlenstoffatome möglichst gut übereinstimmen. Die resultierenden relativen Koordinaten dieser Atome werden verwendet, um eine neue Ähnlichkeitsmatrix zu generieren, die die Ähnlichkeit zwischen den Ketten aufgrund ihrer räumlichen Struktur widerspiegelt. Schließlich werden die Alignments unter Verwendung dieser neuen Ähnlichkeitsmatrix angepasst, wodurch die Sequenzen basierend auf ihrer Struktur neu aligniert werden. Nach diesem Vorgang wird das Root-Mean-Square-Distanz (RMSD) berechnet. Dieser gesamte Prozess wird wiederholt, bis die RMSD der keine weitere Verbesserung aufweist.

In MOE können Sequenzen auf zwei Arten aligniert werden. Entweder sequenziell, ohne den Schritt 4, die strukturbasierte Neualignierung, oder sequenziell und strukturell, also einschließlich der strukturbasierten Neualignierung (Berger and Munson, 1991) (Hersh, 1967), (Gotoh, 1993), (Shapiro et al., 1992), (Needleman and Wunsch, 1970).

2.8.1 RMSD

Der Root Mean Square Deviation (RMSD) ist ein Maß für die durchschnittliche Abweichung zwischen den Positionen von Atomen in zwei Strukturen. Um den RMSD-Wert für zwei Strukturen zu berechnen, müssen diese optimal miteinander überlagert werden, was mit der Superpositions-Funktion in MOE möglich ist. Dabei wird versucht, die bestmögliche Übereinstimmung zwischen den Atomen in den beiden Strukturen zu erzielen. Für jedes Atom-Paar werden die quadratischen Differenzen der Abstände in allen drei Dimensionen berechnet $(d_i) = \big((x_i - \bar{x})^2 + (y_i - \bar{y})^2 + (z_i - \bar{z})^2\big)$. Diese quadratischen Abweichungen werden summiert und durch die Anzahl der Atome, n geteilt, um den durchschnittlichen quadratischen Fehler zu erhalten. Schließlich wird die Quadratwurzel aus diesem Durchschnitt gezogen, um den RMSD zu erhalten.

$$\text{RMSD} = \sqrt{\tfrac{1}{n}\sum_{i=1}^{n} di^2}$$

Ein niedriger RMSD-Wert deutet auf eine größere strukturelle Ähnlichkeit zwischen den beiden Strukturen hin, während ein hoher RMSD-Wert auf größere strukturelle Unterschiede hinweist (Kufareva and Abagyan, 2012).

3 Methodik und Datenerhebung

In diesem Abschnitt wird die Vorgehensweise bei der Datenaufbereitung erläutert. Zuerst wird auf die Datensammlung, wie die Primärsequenzen und PDB-Dateien, eingegangen sowie welche Datenbanken dafür genutzt wurden. Anschließend wird die Strukturierung dieser Daten behandelt, was die Bildung von MSAs mit MAFFT und T-Coffee sowie die Berechnung von Distanzmatrizen umfasst. Des Weiteren wird das Parsen von PDB-Dateien in DSSP behandelt, um die Sekundärstruktur der Proteine zu extrahieren und diese Daten für die Analyse nutzbar zu machen. Am Ende werden die gewonnenen Daten mithilfe der verschiedenen Proteinfamilien analysiert, um Zusammenhänge zu schließen und neues Wissen zu gewinnen.

3.1 Beschaffung von Primärsequenzen und PDB-Dateien

Die Primärsequenzen der untersuchten Proteinfamilien wurden einzeln als FASTA-Dateien von der Proteidatenbank UniProt gespeichert. Diese wurden dann alle zusammen für je eine Proteinfamillie in einer FASTA-Datei eingepackt, um mit diesen Primärsequnzen ein MSA bilden zu können. Die PDB-Dateien wurden von der Strukturdatenbank AlphaFold gespeichert und haben das Strukturformat PDB.

3.2 Bildung von MSA und Distanzmatrixberechnung

Für die Erstellung des MSA wurden die beiden MSA-Tools MAFFT und T-Coffee verwendet. Diese wurden lokal auf einem Ubuntu System installiert.

Die verwendete Version für MAFFT ist

```
MAFFT v7.505 (2022/Apr/10).
```

Um das MSA mit MAFFT zu erstellen, wird die folgende Syntax verwendet:

```
mafft input > output
```

Die automatisch generierte Ausgabedatei wird im FASTA-Format vorliegen. Sollte jedoch ein anderes Format gewünscht sein, kann dies im Terminal entsprechend angepasst werden. In dieser Arbeit wurde das Clustal-Format verwendet.

Für die Bildung einer Distanzmatrix mit MAFFT wird folgende Syntax verwendet.

```
mafft --distout input > output
```

Hierbei war die Ausgabe der Datei im Format „hat2“. Aufgrund der unübersichtlichen und unpraktischen Darstellung der Ausgabe wurde entschieden, auf diese Berechnung der Distanzmatrix mit MAFFT zu verzichten und stattdessen einen anderen Ansatz zur Berechnung zu wählen. Diese Berechnung wurde dann mit Biopython durchgeführt (MAFFT Team, 2021).
Der folgende Ausschnitt stammt aus dieser Datei für die Protein Familie „At1g58602“, die 46 Proteinsequenzen hat. Hier sind alle Distanzen nicht separat aufgeführt oder in Form einer Matrix, was den Zugriff auf diese Distanzen und die Zuordnung zu den einzelnen Sequenzen erschwert. Besonders ist zu beachten, dass es in jeder untersuchten Proteinfamilie eine andere Anzahl von Sequenzen geben könnte. Die ersten vier Zeilen enthalten die Distanzen der ersten Sequenz zu allen anderen möglichen Sequenzen. Die Zeilen ab Zeile fünf bis zum Ende zeigen die Distanzen der zweiten Sequenz zu allen Sequenzen außer der ersten. Die Einträge sind also immer um eins weniger.

```
0.035 1.521 1.476 1.943 1.253 1.444 1.233 1.314 1.466 1.518 1.060 1.648
1.218 1.430 1.518 1.489 1.385 1.442 1.603 1.630 1.491 1.249 1.443 1.600
1.238 1.569 1.279 1.423 1.450 1.594 1.518 1.609 1.438 1.464 1.282 1.451
1.530 1.221 1.456 1.574 1.540 1.609 1.473 1.436 1.451
1.525 1.481 1.947 1.251 1.454 1.231 1.315 1.472 1.518 1.054 1.650 1.218
1.430 1.524 1.493 1.390 1.451 1.610 1.630 1.493 1.248 1.452 1.606 1.237
1.569 1.277 1.432 1.454 1.598 1.523 1.609 1.438 1.470 1.280 1.458 1.534
1.220 1.459 1.574 1.542 1.607 1.477 1.443 1.455
```

Die verwendete Version für T-Coffee ist

```
T-COFFEE Version_13.41.0.28bdc39 (2019-11-30 10:21:53 - Revision 5d5a1c1 -
Build 465)
```

Um das MSA mit T-Coffee zu erstellen, wird die folgende Syntax verwendet:

```
t_coffee input.fasta -distance_matrix_mode=very_fast
```

Hierbei wird der Parameter `distance_matrix_mode=very_fast` verwendet, um die Substitutionsmatrix BLOSUM62 für die Berechnung der Distanzmatrix zu verwenden. Dies ist von Bedeutung, da später im Python-Code ebenfalls die Substitutionsmatrix BLOSUM62 für die Erstellung der Distanzmatrix verwendet wird. Mit T-Coffee lässt sich keine Distanzmatrix ausgeben, daher wurde entschieden, auf die direkte Berechnung der Distanzmatrix mit Biopython umzusteigen. Dies erleichtert die weitere Analyse der Daten (T-Coffee Team, 2018).

Für die Bildung der Distanzmatrix wurde die Biopython-Bibliothek in Python 3 verwendet (Python Software Foundation, 2023), (Biopython Contributors, 2024).

```
!pip install biopython
```

Listing 1: Installation von Biopython

```
from Bio import AlignIO
from Bio.Phylo.TreeConstruction import DistanceCalculator
alignment = AlignIO.read("Input_all.aln", "clustal")  #  die Alignments sind
    im Clustal-Format
calculator = DistanceCalculator('blosum62')
dm = calculator.get_distance(alignment)  # Die Distanzmatrix für die
    Alignments wird mit der Substitutionsmatrix 'Blosum62' gerechnet.
print(dm)
```

Listing 2: Distanzmatrix Abrechnung

Nachdem in den Listings 1 und 2 die Distanzen aller möglichen paarweisen Alignments für jede Proteinfamilie berechnet wurden, wurde in Listing 4 eine spezifische Distanz ausgewählt, um Alignments zu filtern, die als gut oder sehr ähnlich betrachtet wurden. Für jede Proteinfamilie wurde eine unterschiedliche Distanz festgelegt. Zum Beispiel wurde für die erste Proteinfamilie die Distanz von 0.090 ausgewählt, wie in Zeile 21 in 4 zu sehen ist. Diese Distanz wurde durch das Ausprobieren verschiedener Werte ermittelt, bis eine Distanz gefunden wurde, die möglichst ähnliche Sequenzen, aber mit Unterschieden in Bezug auf Aminosäuren, definierte. Diese Distanz muss größer als null sein, um redundante Sequenzen zu vermeiden. Die ausgewählten Alignments wurden anschließend weiter analysiert und in einer CSV-Datei gespeichert. Dabei wurde für jede Position überprüft, ob die beiden Aminosäuren an dieser Position identisch waren oder nicht und ob sie zur Bildung einer Helix beitrugen oder diese unterbrachen. Diese Klassifizierung basierte auf vordefinierten Sets von Aminosäuren, die entweder als helixbildend oder helixabbrechend betrachtet wurden. Zusätzlich wurden leere Einträge für die sekundäre Struktur für jede Aminosäure hinzugefügt, um Platz für Informationen zu schaffen, die später aus der DSSP-Datei extrahiert werden sollten.

Im folgenden Codeausschnitt ist zunächst eine Funktion enthalten, die dazu dient, Unterschiede zwischen Aminosäuren zu identifizieren und zu speichern. Diese Unterschiede werden später in einem anderen Codeausschnitt verwendet, um Ergebnisse direkt in der Konsole anzuzeigen, unabhängig von der CSV-Datei.

```
def compare_sequences(seq1, seq2):

    differences = [
        {
            "Position": pos + 1,
            "Sequence1": aa1,
            "Sequence2": aa2,
        }
        # Enumerieren über die Paare von Aminosäuren an jeder Position in den
            Sequenzen
        for pos, (aa1, aa2) in enumerate(zip(seq1, seq2))


        if aa1 != aa2
    ]

    return differences
```

Listing 3: Unterschiedliche Aminosäuren finden

Die nachfolgende Tabelle zeigt die Helixpotentiale (Pα) von den Aminosäureresten wieder. Das Pα repräsentiert die relative Häufigkeit, mit der die Aminosäure in einer Helix vorkommt. Mit einem Wert über Pα 1 gelten diese Aminosäuren als Helixbildner, während solche mit einem Pα-Wert unter 1 als Helixabbrecher bezeichnet werden. Diese Informationen wurden im Code integriert und sind im nachfolgenden Codeauszug 4 zu sehen. In den Sets helixbildend und helixabbrechend im nachfolgenden Codeauschnitt wurden sowohl die ersten vier als auch die letzten vier Aminosäuren von der Tabelle 2. Diese gelten im Code als Helixbildende oder Helixabbrechende Aminosäuren.

Tabelle 2: Helixpotenziale (Pα) von Aminosäuren, wobei Werte über 1 auf „Helixbildner“ und Werte unter 1 auf „Helixbrecher“ hinweisen (Wik).

Aminosäure	(Pα)-Wert
Glu	1.59
Ala	1.41
Leu	1.34
Met	1.30
Gln	1.27
Lys	1.23
Arg	1.21
Phe	1.16
Ile	1.09
His	1.05
Trp	1.02
Asp	0.99
Val	0.90
Thr	0.76
Asn	0.76
Cys	0.66
Tyr	0.61
Ser	0.57
Gly	0.43
Pro	0.34

```
import pandas as pd

helix_bildend = set(['E', 'A', 'L', 'M'])
helix_abbrechend = set(['T', 'S', 'P', 'G'])

pos2=0
helix_bildend_positions = []
helix_abbrechend_positions = []
df_data = []
seq1_list = []
seq2_list = []

print("Sequenzpaare mit Distanz < 0.0080:")
print()

for i in range(len(dm.names)):
    for j in range(i + 1, len(dm.names)):
        distance = dm[i, j]

```

```
        # Überprüfe, ob die Distanz im gewünschten Bereich liegt.Die Bedingung > 0 wird verwendet, um Redundanz zu vermeiden
        if distance < 0.090 and distance > 0 :
            # Wenn die Bedingung erfüllt ist, dann werden die Sequenzen gespeichert.
            seq1 = alignment[i]
            seq2 = alignment[j]
            print(f"Sequenz {dm.names[i]} und Sequenz {dm.names[j]} haben eine Distanz von {distance}")
            print()
            seq1_list.append(dm.names[i])
            seq2_list.append(dm.names[j])

            # Schleife über jede Position in den Sequenzen
            for pos, (aa1, aa2) in enumerate(zip(seq1.seq, seq2.seq), start=1):
                pos2 = 0 if pos == 1 else pos2
                pos3 = 0 if pos == 1 else pos3
                pos2 = pos2+1 if aa1 != '-' else pos2
                pos3 = pos3+1 if aa2 != '-' else pos3

                helix_bildend_seq1 = 'J' if aa1 in helix_bildend else 'N'
                helix_bildend_seq2 = 'J' if aa2 in helix_bildend else 'N'
                helix_abbrechend_seq1 = 'J' if aa1 in helix_abbrechend else 'N'
                helix_abbrechend_seq2 = 'J' if aa2 in helix_abbrechend else 'N'

                identical = 'nid' if aa1 != aa2 else 'id'

                df_data.append({
                    'Position1': pos,
                    'Position2': pos2,
                    'Position3' : pos3,
                    'seq1_name': seq1.id,
                    'seq2_name': seq2.id,
                    'Sequenz1': aa1,
                    'Sequenz2': aa2,
                    'identisch': identical,
                    'Helix-bildend1': helix_bildend_seq1,
                    'Helix-bildend2': helix_bildend_seq2,
```

```
                    'Helix-abbrechend1': helix_abbrechend_seq1,
                    'Helix-abbrechend2': helix_abbrechend_seq2,
                    'dssp_seq1': None,  # Platzhalter für die Sekundärstruktur
                        aus der DSSP-Datei
                    'dssp_seq2': None,  # Platzhalter für die Sekundärstruktur
                        aus der DSSP-DAtei
                })
            differences = compare_sequences(seq1.seq, seq2.seq)
            for diff in differences:
                print(f"Unterschied an Position {diff['Position']}:")
                print(f"  Sequenz 1: {diff['Sequence1']}, Sequenz 2: {diff['
                    Sequence2']}")
                print()
            Aminosäuren
            helix_bildend_positions = []
            helix_abbrechend_positions = []

speichere sie in einer CSV-Datei
helix_df = pd.DataFrame(df_data)
helix_df.to_csv('daf1.csv', index=False)

print(helix_df)
```

Listing 4: Klassifizierung der Daten (Sequenzen)

Der Inhalt der Datei daf1.csv ist in der folgenden Tabelle 3 dargestellt. Zur besseren Übersichtlichkeit wurde nur ein kleiner Ausschnitt für die Arbeit ausgewählt. In der ersten Spalte (pos1) wird die Position, beginnend mit eins aufgeführt und für jede Position um eins erhöht. Wenn es sich um ein neues Alignment handelt, dann wird es wieder mit Pos1=0 begonnen. Die Spalte pos2 bezieht sich nur auf Positionen des ersten Proteins, also auf die Daten in Spalte 4. Die Spalte pos3 bezieht sich auf Positionen des zweiten Proteins, also auf die Daten in Spalte 5. Wenn es Lücken in der ersten Proteinsequenz gibt, wird pos2 nicht um 1 inkrementiert. Wenn es Lücken in der zweiten Proteinsequenz gibt, wird pos3 nicht um 1 inkrementiert. Tritt eine Lücke auf, treten Unterschiede zwischen pos2 und pos3 auf. Diese Implementierung wurde vorgenommen, um die spätere Analyse (mit MOE) zu vereinfachen. In der 6. und 7. Spalte sind die Aminosäuren des ersten bzw. des zweiten Proteins zu sehen. In der 8. Spalte steht 'id', wenn diese Aminosäuren identisch sind, und 'nid', wenn sie nicht identisch sind. In der 9. Spalte steht 'J', wenn die Aminosäure des ersten Proteins helixbildend ist, sonst steht 'N'. In der 10. Spalte steht 'J', falls die Aminosäure des zweiten Proteins helixbildend ist, sonst steht 'N'. In den Zeilen 11 und 12 ist es umgekehrt, denn hier steht 'J', falls die Aminosäure helixabbrechend ist, und 'N', falls sie nicht helixabbrechend ist. In den Spalten 13 und 14 stehen später die sekundären Strukturen, die aus der DSSP-Datei extrahiert werden sollen.

Tabelle 3: Inhalt von daf1.csv. Die Tabelle enthält Informationen über die Positionen in jeder Sequenz sowie eine gemeinsame Position, die Namen der beiden Sequenzen, die beiden Aminosäuren und weitere Aussagen über diese Aminosäuren.

Pos1	pos2	pos3	na1	na2	AS1	AS2	id	hb1	hb2	ha1	hb2	dssp1	dssp2
1	1	1	Q8W3K0	G1JSI4	M	M	id	J	J	N	N		
2	1	1	Q8W3K0	G1JSI4	-	-	id	N	N	N	N		
30	2	2	Q8W3K0	G1JSI4	A	A	id	J	J	N	N		
54	9	9	Q8W3K0	G1JSI4	A	G	nid	J	N	N	J		
72	23	23	Q8W3K0	G1JSI4	L	Q	nid	J	N	N	N		
1	1	1	A0A1U7V7J6	A0A1S4A301	M	M	id	J	J	N	N		
2	1	1	A0A1U7V7J6	A0A1S4A301	-	-	id	N	N	N	N		
30	2	2	A0A1U7V7J6	A0A1S4A301	Y	Y	id	N	N	N	N		
54	9	9	A0A1U7V7J6	A0A1S4A30	L	L	id	J	J	N	N		
72	23	23	A0A1U7V7J6	A0A1S4A301	F	F	id	N	N	N	N		
1	1	1	A0A6P6WZI1	A0A6P6WMG8	M	M	id	J	J	N	N		
2	1	1	A0A6P6WZI1	A0A6P6WMG8	-	-	id	N	N	N	N		
30	2	2	A0A6P6WZI1	A0A6P6WMG8	A	A	id	J	J	N	N		
54	12	12	A0A6P6WZI1	A0A6P6WMG8	I	I	id	N	N	N	N		
72	26	26	A0A6P6WZI1	A0A6P6WMG8	H	H	id	N	N	N	N		
1898	961	960	A0A6P6WZI1	A0A6P6WMG8	P	P	id	N	N	J	J		
1899	962	961	A0A6P6WZI1	A0A6P6WMG8	N	N	id	N	N	N	N		
1900	963	962	A0A6P6WZI	A0A6P6WMG8	I	L	nid	N	J	N	N		

3.3 Parsing von PDB in das DSSP-Format

Für das Parsen der PDB-Dateien in das DSSP-Format wurde die Conda-Umgebung genutzt, und dann wurde das DSSP-Programm lokal in dieser Umgebung verwendet. Der folgende Befehl aktiviert eine Conda-Umgebung mit dem Namen 'meineUmgebung'.

```
conda activate meineUmgebung
```

Es wurden verschiedene Versionen ausprobiert, aber einige, wie Version 4.2.2 von mkdssp oder auch Version 4.1.1, lieferten Fehlermeldungen beim Parsen von manchen PDB-Dateien. Diese Fehlermeldung lautete:

```
Trying to parse 'NICS'
Error parsing PDB at line 38
Not a valid integer in PDB record
```

Die Version des DSSP-Formats, die keine Probleme verursachte und mit der alle DSSP-Dateien erfolgreich erzeugt werden konnten, ist:

```
mkdssp 3.0.0
```

Um die PDB Datei in DSSP Format zu parsen wird folgende Syntax verwendet.

```
mkdssp -i input.pdb -o output.dssp
```

3.4 Analyse von DSSP-Dateien

Es werden alle Dateien im Verzeichnis durchgegangen. Für jede Datei wird überprüft, ob sie die Endung ".dssp"hat. Wenn ja, wird der Pfad zur aktuellen DSSP-Datei erstellt, um die Sekundärstrukturen zu speichern. Zunächst werden die Headerinformationen übersprungen, bis die Zeile mit den eigentlichen Daten beginnt. Mithilfe regulärer Ausdrücke werden Leerzeichen entfernt und der Inhalt jeder Zeile in Felder unterteilt. Anschließend werden die entsprechenden Indizes für die sekundäre Struktur extrahiert und gespeichert. Die Spalten werden entsprechend den Dateinamen der DSSP-Dateien im Verzeichnis benannt."

```
import pandas as pd
import re
import os
# Verzeichnis mit DSSP-Dateien
dssp_directory = "dssp_dateien2"
```

```
all_sec_structures = []
# Durchlaufe jede DSSP-Datei im Verzeichnis
for filename in os.listdir(dssp_directory):
    if filename.endswith(".dssp"):
        dssp_file_path = os.path.join(dssp_directory, filename)
        # Liste für die Sekundaerstrukturen einer Datei
        sec_structures = []
        with open(dssp_file_path, 'r') as dssp_file:
            # Überspringe Header-Informationen
            for line in dssp_file:
                if line.startswith('  #  RESIDUE'):
                    break
            for line in dssp_file:
                if line.strip():
                    fields = re.split(r'\s+', line.strip())

                    if len(fields[3]) == 3:
                        structure = fields[5]
                    else:
                        structure = fields[4]

                    if structure in {'H', 'B', 'E', 'G', 'I', 'T', 'S'}:
                        sec_structures.append(structure)
                    else:
                        sec_structures.append('-')  # Wenn die Struktur ungü
                            ltig ist, füge '-' hinzu

        all_sec_structures.append(sec_structures)

df = pd.DataFrame(all_sec_structures).T
df.columns = [f"{os.path.splitext(os.path.basename(filename))[0]}" for
    filename in os.listdir(dssp_directory) if filename.endswith(".dssp")]
df.insert(0, 'Nummerierung', range(1, len(df) + 1))
df.to_csv('daf2.csv', index=False)
print(df)
```

Listing 5: DSSP Dateien analysieren

Der Inhalt dieser Datei (daf2.csv) ist in der Tabelle 4 zu sehen. Zur Übersichtlichkeit wurde nur ein kleiner Ausschnitt davon für die Arbeit ausgewählt. Jede Spalte repräsentiert die Sekundärstruktur eines einzelnen Proteins, wobei der vollständige Name des Proteins in der ersten Zeile steht. Darun-

ter folgt die Sekundärstruktur, die aus der DSSP-Datei extrahiert wurde. Sollte es für eine Position keine Sekundärstruktur geben, wird ein '-' eingetragen. Dies tritt auf, wenn an dieser Position keine Sekundärstruktur in der DSSP-Datei vorhanden ist.

Tabelle 4: Inhalt von daf2.csv mit sekundären Strukturen aus der DSSP-Datei. "wird verwendet, um anzugeben, dass für eine Position keine Sekundärstruktur vorhanden ist.

pos														
1	-	-	-	-	-	-	-	-	-	-	-	-	-	-
2	H	H	H	H	H	-	H	-	H	-	-	-	H	T
3	H	H	H	H	H	-	H	-	H	-	-	T	H	T
4	H	H	H	H	H	H	H	-	H	H	-	T	H	T
5	H	H	H	H	H	H	H	S	H	H	-	H	H	T
6	H	H	H	H	H	H	H	-	H	H	-	H	H	-
7	H	H	H	H	H	H	H	-	H	H	-	H	H	-
8	H	H	H	H	H	H	H	-	H	H	-	H	H	-
9	H	H	H	H	H	H	H	-	H	H	-	H	H	-
10	H	H	H	H	H	H	H	T	H	H	-	H	H	T
11	H	H	H	H	H	H	H	T	H	H	-	H	H	T
12	H	H	H	H	H	H	H	-	H	H	S	H	H	-
13	H	H	H	H	H	H	H	-	H	H	S	H	H	-
14	H	H	H	H	H	H	H	-	H	H	S	H	H	-
15	H	H	H	H	H	H	H	S	H	H	S	H	H	T
16	H	H	H	H	H	H	H	-	H	H	S	H	H	T
17	H	H	H	H	H	H	H	-	H	H	S	H	H	-
18	H	H	H	H	H	H	H	-	H	H	S	H	H	-
19	H	H	H	H	H	H	H	S	H	H	S	H	H	S
20	H	H	H	T	H	H	H	-	-	H	H	H	S	-
21	H	-	H	G	-	H	H	H	T	H	H	H	G	H
22	H	T	H	G	T	H	H	H	T	H	H	H	G	H
23	T	T	H	G	T	H	H	H	S	H	H	H	G	H
24	G	-	H	G	T	H	H	H	-	H	H	G	G	H
25	G	S	H	T	T	H	H	H	-	H	H	G	T	H
26	G	S	H	T	T	H	H	H	T	H	H	G	T	H
27	-	-	H	-	T	H	H	H	T	H	H	-	-	H
28	T	T	S	H	T	H	S	H	H	H	H	T	H	H
29	T	T	G	H	H	H	G	H	H	H	H	T	H	H
30	-	S	G	H	H	H	G	H	H	H	H	T	H	H

Nachdem die Sekundärstrukturen extrahiert wurden, sollten sie der Datei 'daf1.csv', also der Tabelle 3, hinzugefügt werden. Dieser Code greift auf 'seq1_list' und 'seq2_list' zu, die die Namen der Sequenzalignments enthalten. Es ist möglich, dass einige Sequenzen mehrfach im definierten Bereich der Distanz auftreten, der für die Analyse festgelegt wurde (in mehreren Alignments). Daher müssen die Daten aus der 'DSSP-Datei' entsprechend so oft kopiert werden. Aus diesem Grund wurde dieser Code 6 implementiert, um sicherzustellen, dass die Daten für jede auftretende Sequenz korrekt verarbeitet

und in die entsprechenden DataFrames eingefügt werden.

```
import pandas as pd

df_seq1 = pd.DataFrame()
df_seq2 = pd.DataFrame()

added_columns = []
added_columns2 = []

for i in seq1_list:
    if i in df.columns:  # Überprüfe, ob der Spaltenname in df vorhanden ist
        counter = 1
        new_column_name = f"{i}_{counter}"

        while new_column_name in added_columns:
            counter += 1
            new_column_name = f"{i}_{counter}"  # Ändere den Spaltennamen,
                wenn er bereits vorhanden ist
        df_seq1[new_column_name] = df[i]

        added_columns.append(new_column_name)

# Durchlaufe seq2_list, um Spalten für df_seq2 hinzuzufügen (ähnlich wie oben)
for j in seq2_list:
    if j in df.columns:
        counter2 = 1
        x = f"{j}_{counter2}"
        while x in added_columns2:
            counter2 += 1
            x = f"{j}_{counter2}"
        df_seq2[x] = df[j]
        added_columns2.append(x)
```

Listing 6: DSSP Einträge speichern

Diese DSSP Einträge werden jetzt in einer eizigen Spalte geschmolzen.

```
df_combined_1 = pd.melt(df_seq1, value_name='dssp_seq1')
df_combined_2 = pd.melt(df_seq2, value_name='dssp_seq2')
```

Listing 7: Dataframe schmelzen

Im nachfolgenden Codeausschnitt 8 werden die Sekundärstrukturen im helix_df DataFrame gespeichert. Hier mussten einige Dinge beachtet werden, insbesondere dass in dieser Zeile eine Aminosäure vorliegt und nicht ein Gap (-), um die entsprechende Sekundärstruktur zu speichern. Die Position in der dssp_seq1 darf nicht leer sein; wenn sie leer ist, wird diese Zeile übersprungen.

```
index1, index2 = 0, 0
for k, row in helix_df.iterrows():
    if row['Sequenz1'] not in ['-', None, '']:
        # Überprüfe, ob index1 innerhalb des gültigen Bereichs liegt
        while index1 < len(df_combined_1) and (df_combined_1.at[index1, '
            dssp_seq1'] in [None, '']):
            index1 += 1
        if index1 < len(df_combined_1):
            helix_df.at[k, 'dssp_seq1'] = df_combined_1.at[index1, 'dssp_seq1'
                ]
            index1 += 1
        else:
            helix_df.at[k, 'dssp_seq1'] = '-'
    else:
        helix_df.at[k, 'dssp_seq1'] = '-'
    # Hier ist as gleiche wie oben aber für der zweiten Sequenz
    if row['Sequenz2'] not in ['-', None, '']:
        while index2 < len(df_combined_2) and (df_combined_2.at[index2, '
            dssp_seq2'] in [None, '']):
            index2 += 1
        if index2 < len(df_combined_2):
            helix_df.at[k, 'dssp_seq2'] = df_combined_2.at[index2, 'dssp_seq2'
                ]
            index2 += 1
        else:
            helix_df.at[k, 'dssp_seq2'] = '-'
    else:
        helix_df.at[k, 'dssp_seq2'] = '-'
```

Listing 8: Ergänzung der daf1.csv

nachfolgend ist dann die ergäntze Tabelle 5.

Tabelle 5: Ergänzung von daf1 mit den sekundären Strukturen

Pos1	pos2	pos3	seq1	seq2	AS1	AS2	id	hb1	hb2	ha1	ha2	dssp1	dssp2
1	1	1	Q8W3K0	G1JSI4	M	M	id	J	J	N	N	-	-
2	1	1	Q8W3K0	G1JSI4	-	-	id	N	N	N	N	-	-
30	2	2	Q8W3K0	G1JSI4	A	A	id	J	J	N	N	H	H
54	9	9	Q8W3K0	G1JSI4	A	G	nid	J	N	N	J	H	H
72	23	23	Q8W3K0	G1JSI4	L	Q	nid	J	N	N	N	G	G
1	1	1	A0A1U7V7J6	A0A1S4A301	M	M	id	J	J	N	N	-	-
2	1	1	A0A1U7V7J6	A0A1S4A301	-	-	id	N	N	N	N	-	-
30	2	2	A0A1U7V7J6	A0A1S4A301	Y	Y	id	N	N	N	N	-	-
54	9	9	A0A1U7V7J6	A0A1S4A30	L	L	id	J	J	N	N	H	H
72	23	23	A0A1U7V7J6	A0A1S4A301	F	F	id	N	N	N	N	H	H
1	1	1	A0A6P6WZI1	A0A6P6WMG8	M	M	id	J	J	N	N	-	-
2	1	1	A0A6P6WZI1	A0A6P6WMG8	-	-	id	N	N	N	N	-	-
30	2	2	A0A6P6WZI1	A0A6P6WMG8	A	A	id	J	J	N	N	-	H
54	12	12	A0A6P6WZI1	A0A6P6WMG8	I	I	id	N	N	N	N	H	H
72	26	26	A0A6P6WZI1	A0A6P6WMG8	H	H	id	N	N	N	N	G	G
1898	961	960	A0A6P6WZI1	A0A6P6WMG8	P	P	id	N	N	J	J	-	-
1899	962	961	A0A6P6WZI1	A0A6P6WMG8	N	N	id	N	N	N	N	-	-
1900	963	962	A0A6P6WZI1	A0A6P6WMG8	I	L	nid	N	J	N	N	-	-

Die ergänzte Tabelle 6 ermöglicht es, relevante Zeilen zu extrahieren, um spezifische Positionen genauer zu untersuchen. In der folgenden Tabelle sind Beispiele zu finden, in denen sich die Sekundärstrukturen der beiden Sequenzen unterscheiden. In einem Fall sollte eine Alpha-Helix vorliegen, während es sich in dem anderen Fall um ein Beta-Faltblatt handeln sollte. Solche Unterschiede werden im nächsten Abschnitt genutzt, um die Integration der Sekundärstruktur zu illustrieren.

Tabelle 6: Die ergänzte Tabelle

Pos1	Pos2	Pos3	seq1	seq2	AS1	AS2	id	hb1	hb2	ha1	ha2	dssp1	dssp2
154	87	87	Q8W3K0	G1JSI4	T	K	nid	N	N	J	N	T	H
155	88	88	Q8W3K0	G1JSI4	T	T	id	N	N	J	J	T	H
165	97	97	Q8W3K0	G1JSI4	R	R	id	N	N	N	N	H	S
167	98	98	Q8W3K0	G1JSI4	L	L	id	J	J	N	N	H	S
266	163	163	Q8W3K0	G1JSI4	V	V	id	N	N	N	N	S	H
267	164	164	Q8W3K0	G1JSI4	A	A	id	J	J	N	N	S	H
268	165	165	Q8W3K0	G1JSI4	L	L	id	J	J	N	N	-	H
703	403	403	A0A1U7V7J6	A0A1S4A301	G	G	id	N	N	J	J	H	T
727	426	426	A0A1U7V7J6	A0A1S4A301	L	L	id	J	J	N	N	H	G
838	518	518	A0A1U7V7J6	A0A1S4A301	Y	Y	id	N	N	N	N	E	H
845	538	538	A0A6P6G1A9	A0A6P3ZEI4	T	T	id	N	N	J	J	H	T
856	543	543	A0A6P6G1A9	A0A6P3ZEI4	F	F	id	N	N	N	N	H	G
447	272	270	A0A6P6WN18	A0A6P6WMJ8	K	K	id	N	N	N	N	S	H
458	283	281	A0A6P6WN18	A0A6P6WMJ8	D	D	id	N	N	N	N	H	-
469	294	292	A0A6P6WN18	A0A6P6WMJ8	V	F	nid	N	N	N	N	H	S
633	415	18	A0A6P6WSC7	A0A6P6X4U5	E	D	nid	J	N	N	N	H	S
635	416	19	A0A6P6WSC7	A0A6P6X4U5	Q	Q	id	N	N	N	N	H	S
200	133	133	A0A6P6WZI1	A0A6P6WMG8	R	R	id	N	N	N	N	H	T
201	134	134	A0A6P6WZI1	A0A6P6WMG8	D	D	id	N	N	N	N	H	S

4 Vergleich von Proteinstrukturen

4.1 Primärsequenzvergleich

Hier werden die Aminosäurensequenzabfolgen genutzt. Es können bioinformatische Werkzeuge und Algorithmen wie z. B. T-Coffee durchgeführt werden, die die Ähnlichkeit zwischen Sequenzen bewerten, indem sie gemeinsame Aminosäurereste und Evolutionssubstitutionen berücksichtigen. Außerdem können Proteindatenbanken wie SMART oder InterPro verwendet werden, um Homologie- und Evolutionäre Analysen sowie Motivanalysen zur Domänenfindung durchzuführen. Dies kann wichtige Informationen über das Protein liefern, aber ohne die 3D-Struktur des Proteins können nicht alle Aspekte seiner Struktur und Funktion vollständig erfasst werden.

4.2 Strukturvergleich auf 3D-Ebene mit MOE

In MOE werden die Proteine in 3D-Struktur dargestellt, was eine bessere Analyse der Proteine ermöglicht. Hier können die zwei Proteine auf zwei Arten aligniert werden: nur sequenziell oder se-

quenziell und strukturell. Dazu werden dann noch zwei RMSD-Werte für diese Proteine berechnet. In MOE besteht auch die Möglichkeit, die Gewichtung der Aminosäuren mit Übereinstimmungen in regulären Sekundärstrukturen (Helix oder Faltblatt) zu erhöhen. Dies wird berücksichtigt und ein neuer RMSD-Wert wird berechnet.

In der nächsten Abbildung ist ein Beispiel, wie ein aligniertes Protein aussieht. Hier sind zwei verschiedene Proteine aus derselben Proteinfamilie mit MOE aligniert. Je ähnlicher diese Proteinsequenzen sind, desto deckungsgleicher und übereinander liegen sie.

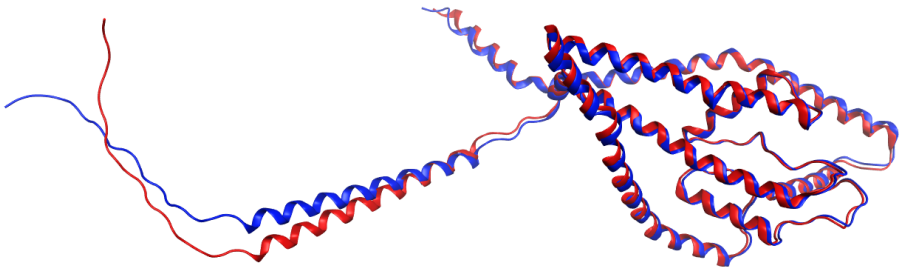


Abbildung 10: Beispiel eines alignierten Proteins. Hier ist ein Alignment von zwei Proteinen dargestellt. Das eine Protein ist in rot und das andere in blau markiert. Erstellt mit MOE.

4.3 Integration von Sekundärstrukturinformationen

In der Analyse werden die Sekundärstrukturen aus den DSSP-Dateien integriert, um die Konsistenz der Proteinvergleiche auf verschiedenen Ebenen zu überprüfen. Dabei wird untersucht, ob es Unterschiede zwischen den vorhergesagten Sekundärstrukturen und den in MOE dargestellten 3D-Strukturen gibt.

5 Analyse der Proteinfamilien

In diesem Abschnitt werden die verschiedenen Proteinfamilien analysiert. Zunächst werden die Proteine jeder Familie mithilfe von MOE aligniert, und die Ergebnisse werden mit der Alignierung von T-Coffee verglichen. Darüber hinaus werden verschiedene RMSD-Werte berechnet, um die strukturelle Ähnlichkeit zwischen den Proteinen zu quantifizieren. Des Weiteren wird untersucht, welchen Einfluss einzelne Aminosäuren auf die Proteinstruktur haben könnten.

5.1 Proteinfamilie: probable disease resistance protein At1g58602

In der nachfolgenden Tabelle 7 sind in der ersten Spalte die Abkürzungen der Namen der untersuchten Proteine aufgeführt. In der zweiten Spalte befindet sich der Score von T-Coffee für die Alignment dieser beiden Proteinsequenzen. Die dritte Spalte enthält einen RMSD-Wert von MOE, wenn diese nur sequenziell aligniert werden. In der vierten Spalte ist ein RMSD-Wert angegeben, wenn diese sowohl sequenziell als auch strukturell aligniert werden. Die fünfte Spalte enthält einen RMSD-Wert, wenn sie strukturell und sequenziell mit Gewichtung für die Sekundärstruktur aligniert werden. Die letzte Spalte zeigt die Positionen der Domänen, die mit Interpro gefunden wurden.

Tabelle 7: Analyse von At1g58602

Name	**T-Coffee**	**RMSD $_{seq}$**	**RMSD $_{seq, str}$**	**RMSD $_{seq, str, sek}$**	**Domänen**
Q8W3/G1JS	99	2.04	1.95	1.68	6-84, 6-124, 166-422
7J6/A301	100	1.70	1.68	1.14	3-117, 8-88, 163-400
B9K5/B9D8	99	0.71	0.68	0.56	22-249
G1A9/ZEI4	99	1.94	1.94	1.50	11-118, 13-94, 164-424
M18/NJ8	99	8.21	8.17	4.99	164-424
WSC7/X4U5	98	5.14	5.14	3.78	191-350, keine Domänen

5.1.1 Q8W3K0/G1JSI4

In der Abbildung 11 ist die Domäne von 6 bis 124 in schwarz markiert, während die andere Domäne von 166 bis 422 in lila markiert ist.

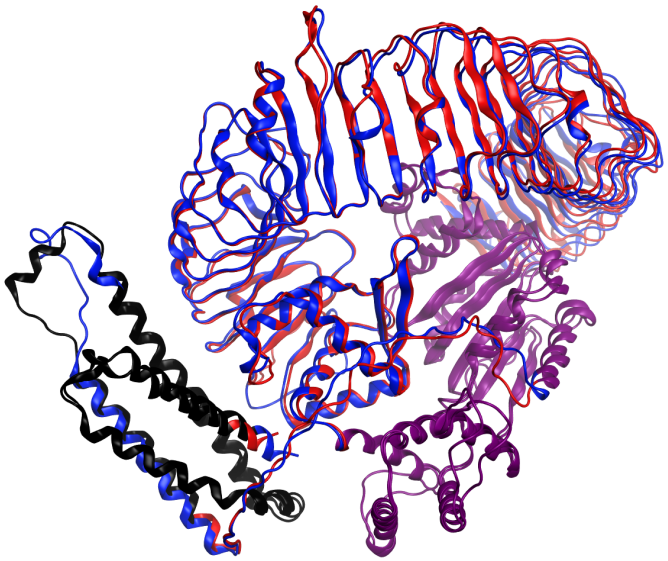


Abbildung 11: Q8W3K0/G1JSI4 (1). Die Domänen der Proteine Q8W3K0 (rot) und G1JSI4 (blau). Sie sind in schwarz und lila markiert. Erstellt mit MOE.

In der Tabelle 8 sind die wichtigsten Zeilen extrahiert, die das Ergebnis der Analyse darstellen, die mit dem Codeteil durchgeführt wurde.

Tabelle 8: Analyse von Q8W3K0 und G1JSI4

159	91	91	Q8W3K0	G1JSI4	I	I	id	N	N	N	N	T	-
160	92	92	Q8W3K0	G1JSI4	R	R	id	N	N	N	N	H	T
161	93	93	Q8W3K0	G1JSI4	K	K	id	N	N	N	N	H	T
162	94	94	Q8W3K0	G1JSI4	H	H	id	N	N	N	N	H	T
163	95	95	Q8W3K0	G1JSI4	I	I	id	N	N	N	N	H	T
164	96	96	Q8W3K0	G1JSI4	K	K	id	N	N	N	N	H	T
165	97	97	Q8W3K0	G1JSI4	R	R	id	N	N	N	N	H	S
166	97	97	Q8W3K0	G1JSI4	-	-	id	N	N	N	N	-	-
167	98	98	Q8W3K0	G1JSI4	L	L	id	J	J	N	N	H	S
168	99	99	Q8W3K0	G1JSI4	T	T	id	N	N	J	J	S	-
266	163	163	Q8W3K0	G1JSI4	V	V	id	N	N	N	N	S	H
267	164	164	Q8W3K0	G1JSI4	A	A	id	J	J	N	N	S	H
268	165	165	Q8W3K0	G1JSI4	L	L	id	J	J	N	N	-	H
446	269	264	Q8W3K0	G1JSI4	M	M	id	J	J	N	N	H	S

Die Abbildung 12 zeigt die Proteine Q8W3K0 und G1JSI4. Das Protein Q8W3K0 ist in rot dargestellt, wobei die relevanten Stellen in gelb markiert sind. Das Protein G1JSI4 hingegen ist blau und die relevanten Stellen sind grün markiert.

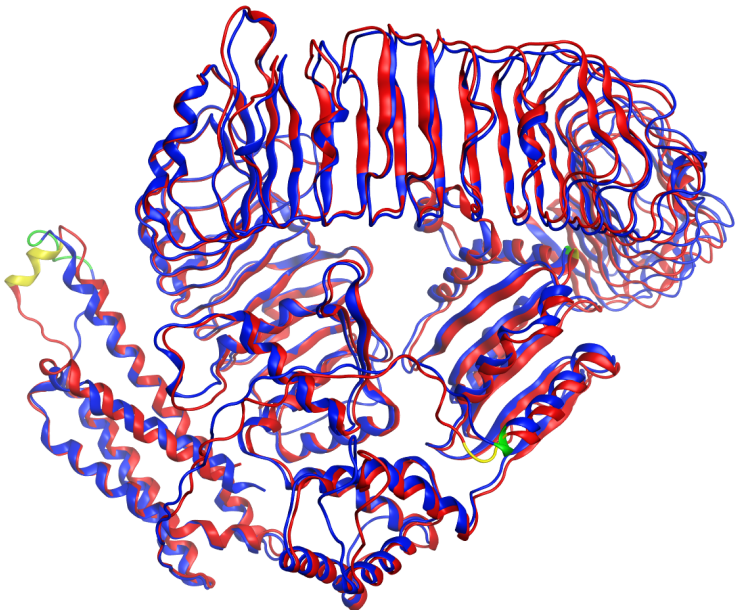


Abbildung 12: Vergleich der Proteine Q8W3K0 (rot) und G1JSI4 (blau) mit markierten Positionen aus der Tabelle. Die relevanten Stellen des Proteins Q8W3K0 sind gelb markiert, während die relevanten Stellen des Proteins G1JSI4 grün markiert sind. Erstellt mit MOE.

Die Positionen 159 bis 168 beziehen sich auf den linken Teil. In den Positionen 165 und 167 stimmt die 3D-Struktur in der Proteinstruktur Q8W3K0 in MOE mit der Tabelle überein. Jedoch gibt es einen Unterschied in der Sequenz G1JSI4 zwischen der Sekundärstruktur, die in der Tabelle als S vorausgesagt wird, und in MOE, wo diese Positionen Teil der grünen Schlinge sind, was T entspricht. In Position 168 wird die Sekundärstruktur laut der Tabelle in Q8W3K0 als S vorausgesagt, jedoch ist dies in MOE noch der letzte Teil der Alphahelix (gelber Teil), bevor es in die Schlinge übergeht.
Um die Ursache dafür zu finden, wurde auf Unterschiede in der Nähe dieses Bereichs geachtet und folgendes wurde gefunden, wie in Tabelle 9 gezeigt wird. Es treten in allen drei Positionen verschiedene Aminosäuren in jeder Sequenz auf. In Position 146 kommt in der ersten Sequenz die Aminosäure Val vor, die in der Struktur kürzer ist als die Aminosäure Leu, die in der zweiten Sequenz vorkommt. In Position 147 kommt in der ersten Sequenz die Aminosäure Gln vor, die länger ist als die Aminosäure Leu, die in der zweiten Struktur vorkommt. In Position 154 kommt in der ersten Sequenz die Aminosäure Thr vor, die in der Struktur viel kürzer ist als die Aminosäure Lys. Außerdem gibt es laut der Tabelle Unterschiede im Bezug auf helixbildende und helixabbrechende Aminosäuren. Diese Unterschiede und das Vorhandensein der Aminosäuren mit unterschiedlichen Eigenschaften beeinträchtigen die Weiterbildung dieser Alphahelix.
Zusätzlich ist es wichtig anzumerken, dass diese Aminosäuren unterschiedliche chemische Eigenschaften haben. Glutamin ist polar, Leu ist unpolar, Thr ist eine polare neutrale Aminosäure und Leu ist eine polare basische Aminosäure.

Tabelle 9: Analyse von Q8W3K0 und G1JSI4

146	80	80	Q8W3K0	G1JSI4	V	L	nid	N	J	N	N	H	H
147	81	81	Q8W3K0	G1JSI4	Q	L	nid	N	J	N	N	H	H
154	87	87	Q8W3K0	G1JSI4	T	K	nid	N	N	J	N	T	H

In der nächsten Abbildung 13 (Die ist die gleiche letzte abbildung aber gespieglt für eine bessere Ansicht.) ist noch gezeigt, dass dadurch dass diese Substitution zwischen Aminosäuren in diesen Positionen 146,147,154 (diese sind in lila markiert) gibt, sind die Alphahelices ab diesen Positionen nicht mehr deckungsgleich. Dies erklärt auch den Unterschied in den gelben und grünen Bereichen zwischen den beiden Sequenezen.

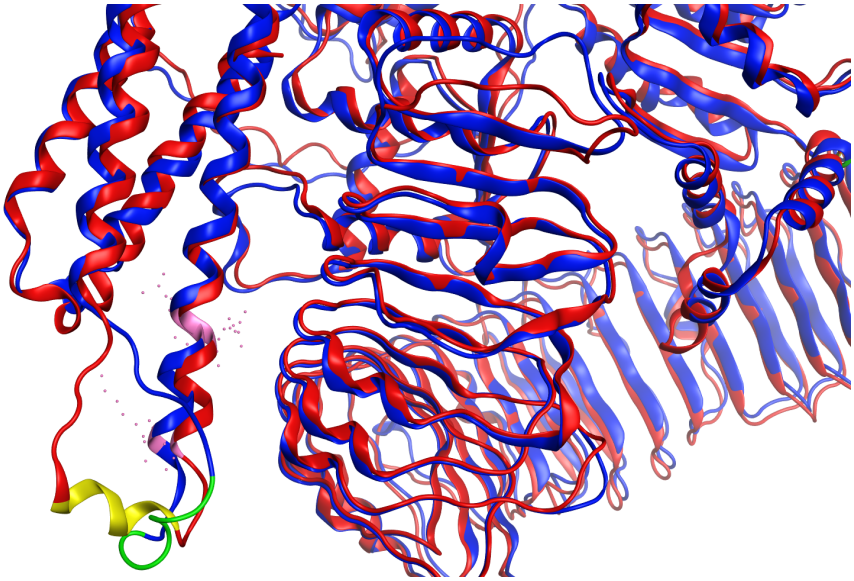


Abbildung 13: Einfluss der Substitutionen der Aminosäuren auf die Bildung einer Helixstruktur in den Proteinen (Q8W3K0 in rot) und (G1JSI4 in blau). Diese Substitutionen finden an den Positionen 146, 147 und 154 statt, die in lila markiert sind. Die Abbildung wurde mit MOE erstellt.

Die Positionen 266 bis 268 in Tabelle 8 repräsentieren in Abbildung 12 den unteren rechten Teil. Hier tritt wieder ein Unterschied zwischen der Sekundärstruktur und MOE in der Sequenz Q8W3K0 auf. Was in der Tabelle als S voraussagt ist, wird in MOE als Teil der gelben Schlinge (T) dargestellt. Hier wurden auch in diesem Bereich Unterschiede in der Struktur der vorhandenen Aminosäuren festgestellt. In der Position 446, die in der Abbildung 12 oben rechts ist, tritt dieser Unterschied erneut auf.

5.1.2 7J6/A301

In diesen beiden Sequenzen gibt es wieder Unterschiede zwischen der Sekundärstruktur und der 3D-Struktur in MOE an den Stellen 843-844. In MOE sind diese Positionen Teil der gelben Schleife in Abbildung 14. Es wurden keine wesentlichen Unterschiede in den Aminosäuren in der Nähe dieser Positionen festgestellt.

Tabelle 10: 7J6/A301

838	518	518	A0A1U7V7J6	A0A1S4A301	Y	Y	id	N	N	N	N	E	H
839	519	519	A0A1U7V7J6	A0A1S4A301	Q	Q	id	N	N	N	N	-	H
840	520	520	A0A1U7V7J6	A0A1S4A301	H	H	id	N	N	N	N	-	H
841	521	521	A0A1U7V7J6	A0A1S4A301	C	C	id	N	N	N	N	-	H
842	522	522	A0A1U7V7J6	A0A1S4A301	H	H	id	N	N	N	N	S	H
843	523	523	A0A1U7V7J6	A0A1S4A301	K	K	id	N	N	N	N	S	H
844	524	524	A0A1U7V7J6	A0A1S4A301	S	S	id	N	N	J	J	S	H
845	525	525	A0A1U7V7J6	A0A1S4A301	M	M	id	J	J	N	N	-	H
847	526	526	A0A1U7V7J6	A0A1S4A301	C	C	id	N	N	N	N	-	H

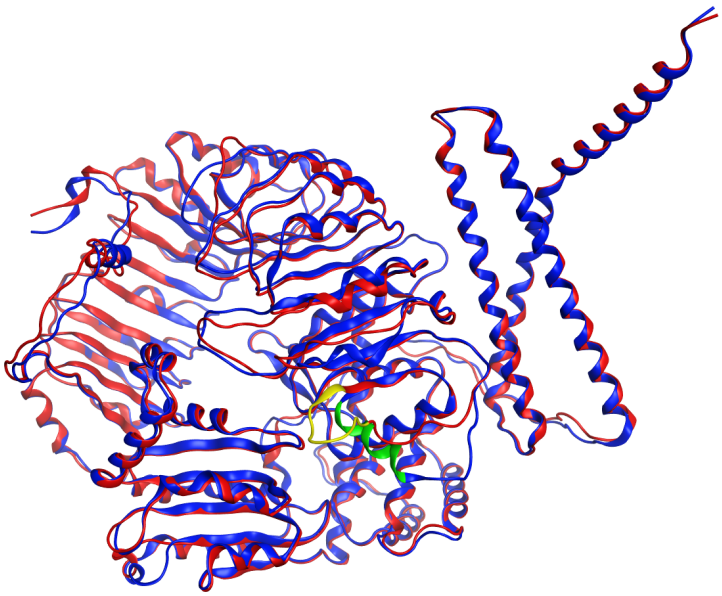


Abbildung 14: Vergleich der Proteine A0A1U7V7J6 (rot) und A0A1S4A301 (blau). Die relevanten Stellen des Proteins A0A1U7V7J6 sind gelb markiert, während die relevanten Stellen des Proteins A0A1S4A301 grün markiert sind. Erstellt mit MOE.

In der Abbildung 15 ist die Domäne von 3-117 in lila markiert und die andere Domäne von 163-400 in schwarz markiert.

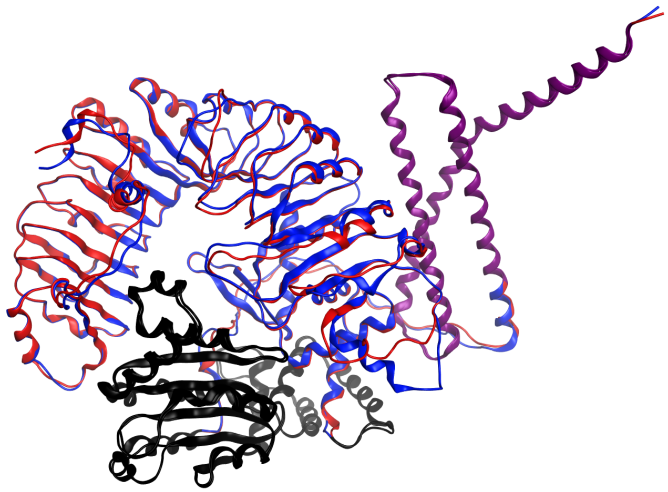


Abbildung 15: Die Domänen der Proteine A0A1U7V7J6 (rot) und A0A1S4A301 (blau). Sie sind in schwarz und lila markiert. Erstellt in MOE.

5.1.3 B9K5/B9D8

Diese zwei Proteine weisen in der Analyse keine kritischen Punkte bzw. große Unterschiede auf, daher werden sie nicht weiter analysiert. Die Domäne von 22 bis 249 ist in lila markiert und ist der Abbildung 16 zu sehen.

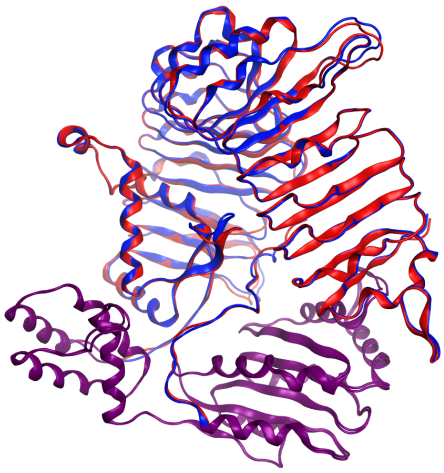


Abbildung 16: Domäne der Proteine B9K5 (rot) und B9D8 (blau) (1). Sie ist in lila markiert. Erstellt mit MOE.

5.1.4 G1A9/ZEI4

In diesen beiden Proteinen A0A6P6G1A9 und A0A6P3ZEI4 gibt es keine größeren Unterschiede bis auf einen Punkt, an dem ein Beta-Faltblatt in einer der Sequenzen abbricht (das Ende dieser Sequenz ist in gelb markiert) und nicht weitergeht, während es in der anderen Sequenz weitergeht und sogar eine Alpha-Helix bildet (in grün markiert), die in der ersten Sequenz komplett fehlt. Dies ist in Abbildung 17 zu sehen. Die Länge der ersten Sequenz A0A6P6G1A9 beträgt 881, und die der zweiten Sequenz A0A6P3ZEI4 beträgt 966. Diese Längen entsprechen der Länge der Primärsequenz dieser beiden Proteinsequenzen.

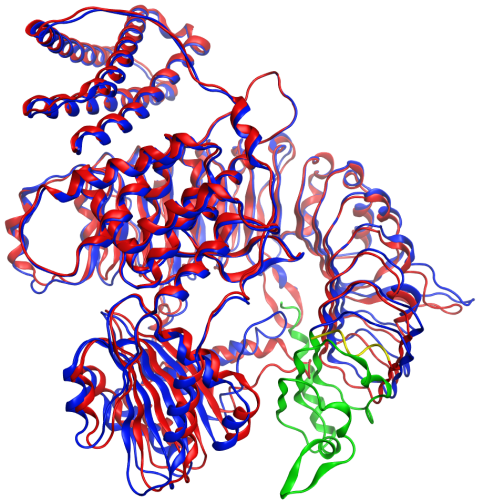


Abbildung 17: Vergleich der Proteine A0A6P6G1A9 (rot) und A0A6P3ZEI4 (blau). Die relevanten Stellen des Proteins A0A6P6G1A9 sind gelb markiert, während die relevanten Stellen des Proteins A0A6P3ZEI4 grün markiert sind. Erstellt mit MOE.

Es ist in Tabelle 11 zu sehen, dass es im Abschnitt, der sich am Ende der Sequenz A0A6P6G1A9 und vor dem grünen Teil der Sequenz A0A6P3ZEI4 befindet, viele Unterschiede zwischen den Aminosäuren gibt.

Tabelle 11: Analyse von G1A9/ZEI4

1409	875	875	A0A6P6G1A9	A0A6P3ZEI4	D	G	nid	N	N	N	J	T	T
1410	876	876	A0A6P6G1A9	A0A6P3ZEI4	L	A	nid	J	J	N	N	S	T
1411	877	877	A0A6P6G1A9	A0A6P3ZEI4	K	L	nid	N	J	N	N	T	T
1412	878	878	A0A6P6G1A9	A0A6P3ZEI4	S	A	nid	N	J	J	N	T	T
1413	879	879	A0A6P6G1A9	A0A6P3ZEI4	K	N	nid	N	N	N	N	S	T
1414	880	880	A0A6P6G1A9	A0A6P3ZEI4	M	L	nid	J	J	N	N	-	-
1415	881	881	A0A6P6G1A9	A0A6P3ZEI4	E	R	nid	J	N	N	N	-	-
1416	881	882	A0A6P6G1A9	A0A6P3ZEI4	-	E	nid	N	J	N	N	-	E

In der Abbildung 18 sieht man, dass der grüne Teil, der nur in einer Sequenz vorkommt, kein Teil einer

Domäne ist. Die erste Domäne, markiert von 11 bis 118, ist in lila dargestellt, während die andere Domäne, markiert von 164 bis 424, in schwarz erscheint.

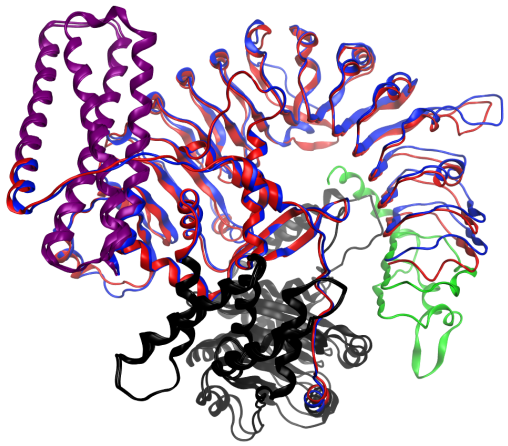


Abbildung 18: Domänen der Proteine A0A6P6G1A9 (rot) und A0A6P3ZEI4 (blau). Sie sind in lila und schwarz markiert. Der grüne Teil, der beim Protein A0A6P6WN18 fehlt, ist kein Teil der Domänen. Erstellt mit MOE.

5.1.5 N18/MJ8

In diesen Proteinsequenzen A0A6P6WN18 (in rot markiert) und A0A6P6WMJ8 (in blau markiert) gibt es zwei Bereiche, die näher angeguckt wurden. Der erste Bereich ist in der folgenden Tabelle 12 analysiert.

Tabelle 12: Analyse von N18/MJ8, Positionen 1846-1877

1846	929	932	A0A6P6WN18	A0A6P6WMJ8	E	E	id	J	J	N	N	S	H
1853	930	933	A0A6P6WN18	A0A6P6WMJ8	S	S	id	N	N	J	J	S	H
1863	931	934	A0A6P6WN18	A0A6P6WMJ8	T	T	id	N	N	J	J	S	H
1864	932	935	A0A6P6WN18	A0A6P6WMJ8	N	I	nid	N	N	N	N	S	H
1865	933	936	A0A6P6WN18	A0A6P6WMJ8	S	S	id	N	N	J	J	S	H
1875	934	937	A0A6P6WN18	A0A6P6WMJ8	A	A	id	J	J	N	N	-	H
1876	935	938	A0A6P6WN18	A0A6P6WMJ8	S	C	nid	N	N	J	N	S	H
1877	936	939	A0A6P6WN18	A0A6P6WMJ8	Q	Q	id	N	N	N	N	S	H

In der ersten Sequenz bilden diese Positionen in der 3D-Struktur eine Biegung (19), die in gelb markiert ist und in der Sekundärstruktur als S vorhergesagt wurde. Außerdem bildet sich in der zweiten blauen Sequenz eine Alpha-Helix, die in der ersten Sequenz fehlt. Diese entsprechen der sekundären Struktur.

Der Grund für die unterschiedliche Bildung in den beiden Sequenzen liegt im Vorhandensein verschiedener Aminosäuren an den Positionen 1864 und 1876. In der Position 1864 kommt in der roten

Sequenz die Aminosäure Asn vor, die einen (Pα)-Wert von 0.76 hat, während in der blauen Sequenz an dieser Position die Aminosäure Ile vorkommt, die einen höheren (Pα)-Wert von 1.09 aufweist. Ebenso liegt in der Position 1876 in der roten Sequenz die Aminosäure Ser mit einem (Pα)-Wert von 0.57 vor, während in der blauen Sequenz an dieser Stelle die Aminosäure Cys mit einem (Pα)-Wert von 0.66 vorhanden ist. Zusätzlich ist zu beachten, dass die Aminosäure ASN eine etwas größere Struktur als Ile aufweist, was ebenfalls die Bildung der Alpha-Helix beeinflussen könnte.

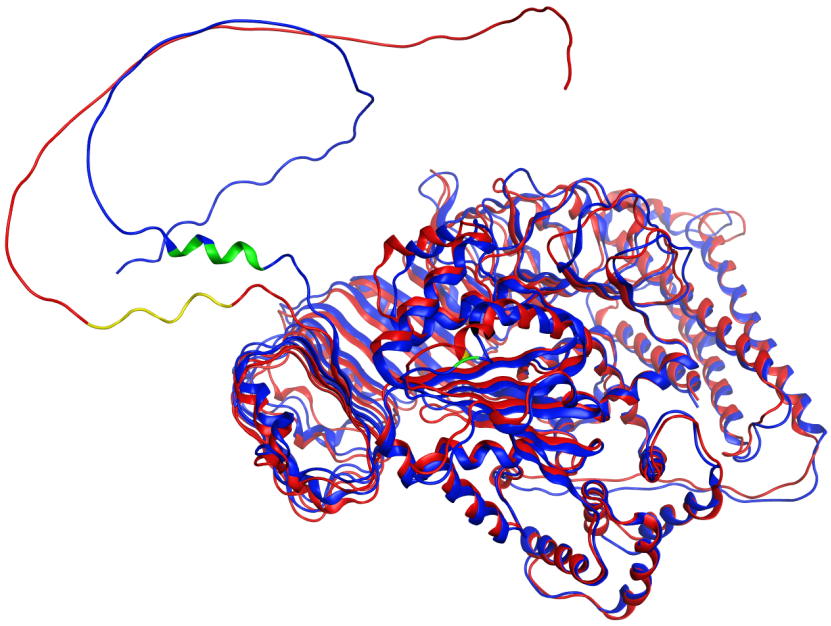


Abbildung 19: Vergleich der Proteine A0A6P6WN18 (rot) und A0A6P6WMJ8 (blau). Die Unterschiede in der Strukturbildung in den grün-gelben Bereichen sind auf das Vorhandensein verschiedener Aminosäuren mit unterschiedlichen (Pα)-Werten zurückzuführen. Erstellt mit MOE.

Die nächsten Positionen von 469 bis 473 liegen am Ende einer Alpha-Helix 20. In der blauen Sequenz bricht die Helix früher ab und geht in eine Schlinge über. Die Position 469 ist in schwarz markiert und enthält in der ersten Sequenz die Aminosäure Val und in der anderen Phe. Die Position 473 ist jeweils in gelb und grün markiert. Aus der Tabelle 13 geht hervor, dass die Aminosäure Pro an Position 470 vorkommt. Das bedeutet, dass es zwei Aminosäuren mit einem Ring in der blauen Sequenz gibt, nämlich Pro und Phe. Dies ist der Grund für das frühere Abbrechen der Alpha-Helix. Das Abbrechen der Alpha-Helix in der roten Sequenz könnte ebenfalls darauf zurückzuführen sein, dass die Aminosäure Pro vorhanden ist.

Tabelle 13: Analyse von M18/NJ8, Positionen 469- 473

469	294	292	A0A6P6WN18	A0A6P6WMJ8	V	F	nid	N	N	N	N	H	S
470	295	293	A0A6P6WN18	A0A6P6WMJ8	P	P	id	N	N	J	J	H	-
471	296	294	A0A6P6WN18	A0A6P6WMJ8	F	F	id	N	N	N	N	H	T
472	297	295	A0A6P6WN18	A0A6P6WMJ8	A	A	id	J	J	N	N	H	T
473	298	296	A0A6P6WN18	A0A6P6WMJ8	V	V	id	N	N	N	N	H	S

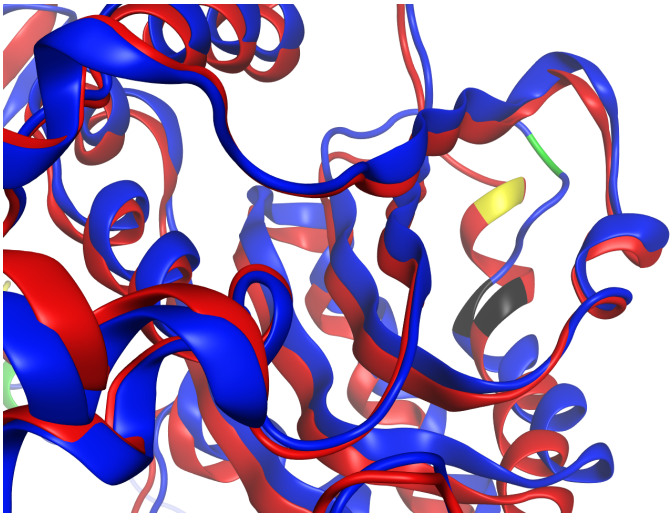


Abbildung 20: Abbruch einer Alpha-Helix im Protein A0A6P6WMJ8 (blau) ab der schwarzen Markierung aufgrund von Aminosäuren, die eine Ringstruktur aufweisen. Erstellt mit MOE.

Erstellt mit MOE.

Die Domäne 164-424 ist in der Abbildung 21 lila markiert

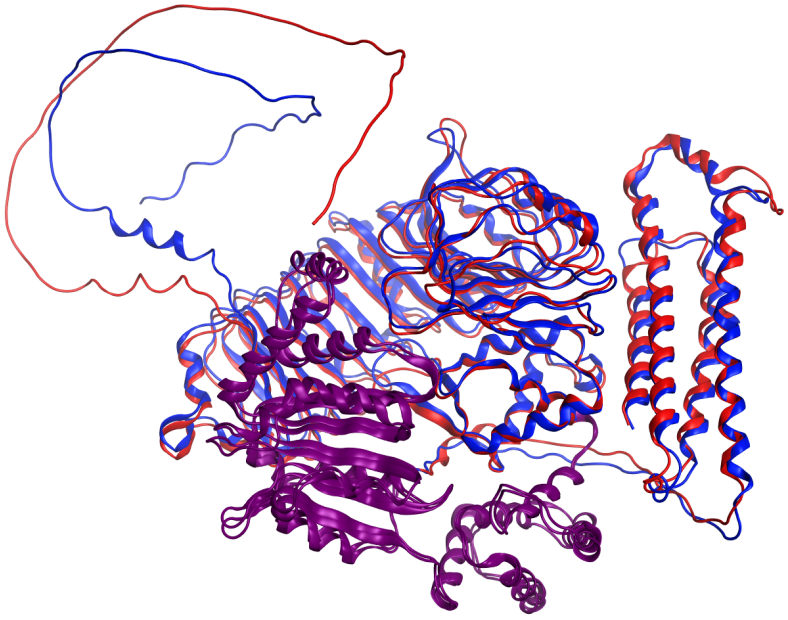


Abbildung 21: Domäne des Proteins A0A6P6WN18 (rot) und A0A6P6WMJ8 (blau). Sie ist in lila markiert. Erstellt mit MOE.

5.1.6 WSc7/X4U5

Diese Proteinsequenzen sind in MOE anders als in T-Coffee aligniert. Sie unterscheiden sich stark in ihrer Länge. Die Sequenz A0A6P6WSC7 ist 986 Aminosäuren lang, während A0A6P6X4U5 nur 588 Aminosäuren lang ist. Die Längen der Primärsequenz und die 3D-Struktur stimmen hier überein. In Tabelle 14 gibt es zwei Positionen, die den Beginn einer Alpha-Helix repräsentieren. In der ersten Sequenz beginnt die Alpha-Helix mit der Sequenz A0A6P6WSC7 ab den Positionen 633, 415 und 18, während die Alpha-Helix in der zweiten Sequenz erst in den Positionen 639, 417 und 20 beginnt. Der Unterschied liegt darin, dass an Position 633 zwei verschiedene Aminosäuren vorkommen. In der ersten Sequenz ist dies die Aminosäure Glu, die gemäß Spalte 9 helixbildend ist. In der zweiten Sequenz hingegen ist dies die Aminosäure Asp, die gemäß Spalte 10 nicht helixbildend ist. Außerdem unterscheiden sich die beiden Aminosäuren in ihrer Struktur. Weiterhin entspricht die Sekundärstruktur nicht der 3D-Struktur in den Positionen 633 und 635 in der zweiten Sequenz 22. Es sind Schlingen in der 3D-Struktur, aber in der Sekundärstruktur sind es β-Faltblätter.

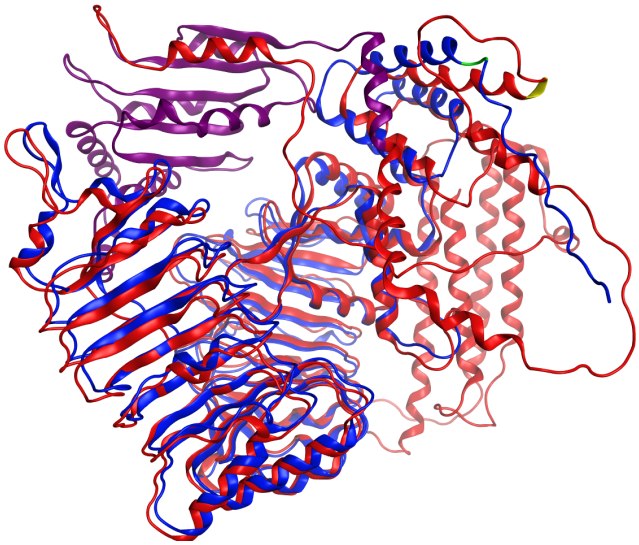


Abbildung 22: Vergleich der Proteine A0A6P6WSC7 (rot) und A0A6P6X4U5 (blau). Die Markierungen in gelb und grün repräsentieren verschiedene Aminosäuren, nämlich Glu und Asp. Daher gibt es einen Unterschied in der Strukturbildung. Die Domäne ist in lila markiert. Erstellt mit MOE.

Tabelle 14: Analyse von WSc7/X4U5

633	415	18	A0A6P6WSC7	A0A6P6X4U5	E	D	nid	J	N	N	N	H	S
635	416	19	A0A6P6WSC7	A0A6P6X4U5	Q	Q	id	N	N	N	N	H	S
639	417	20	A0A6P6WSC7	A0A6P6X4U5	G	G	id	N	N	J	J	H	H

5.2 Proteinfamilie:Free fatty acid receptor 2

Hier wurden keine größeren Unterschiede zwischen den beiden Sequenzen festgestellt. In der nächsten Abbildung 23 ist ein Unterschied zwischen der sekundären Struktur und dem, was MOE zeigt.
Die Sequenz A0A2K5XT84 ist in rot und die Sequenz F7HN43 ist in blau markiert. Jedoch zeigen die sekundären Strukturen in der Tabelle 15, dass die Positionen 345 und 346 Teil eines Beta-Faltblatts sein sollen. Dies ist jedoch laut der 3D Struktur nicht korrekt. Sie bilden eine Biegung in einer Alpha-Helix.

Tabelle 15: Analyse von T84/N43

345	150	150	A0A2K5XT84	F7HN43	L	L	id	J	J	N	N	H	S
346	151	151	A0A2K5XT84	F7HN43	N	N	id	N	N	N	N	H	S

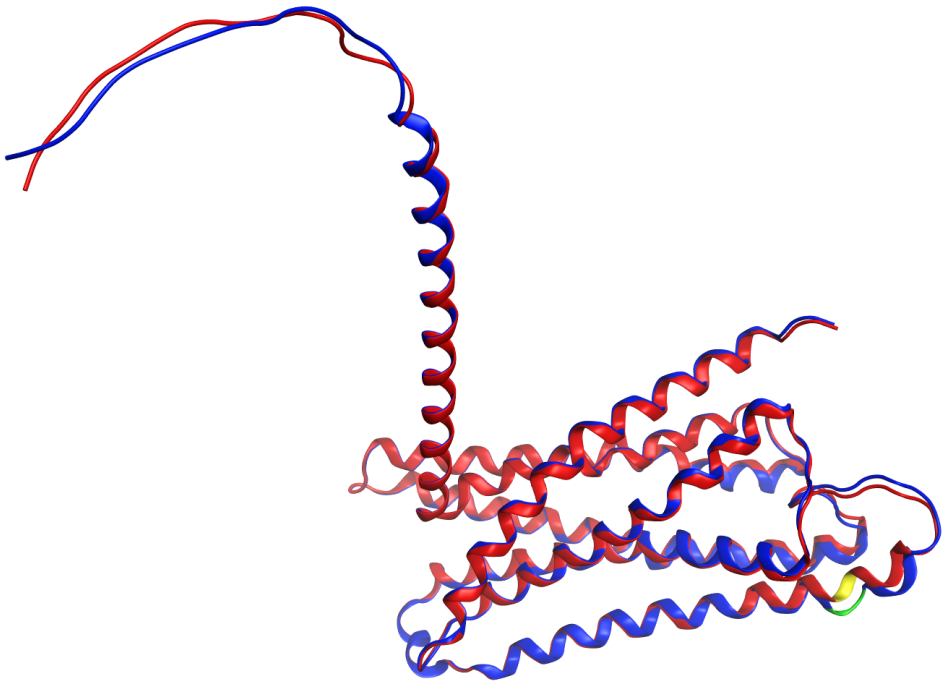


Abbildung 23: Vergleich der Proteine A0A2K5XT84 (rot) und F7HN43 (blau). Die Markierungen in gelb und grün repräsentieren eine Position, die sich in der sekundären Struktur und in der 3D-Struktur unterscheidet. Erstellt mit MOE.

5.3 Proteinfamilie: Hexokinase-1

in dieser Proteinfamilie wurden keine wesentliche Unterscheide in der Sekundärstrukr gefunden. Es wurde aber ein Beispiel gefunden, wo die Proteinsequezen mit T-Coffee anderes aligniert als in in MOE.

5.3.1 P17710/P05708

Es handelt sich hier um einen Teil einer Schlinge. Es ist der erste Teil der Sequenz P17710.
In der roten Sequenz (P17710) gibt es diese Schleife (in Orange), die in der zweiten Sequenz nicht vorkommt. Dabei handelt es sich um die ersten 56 Aminosäuren. Diese wurden mit T-coffee ganz am Anfang (siehe 24) mit der Alpha-Helix der zweiten Sequenz (P05708) aligniert. Während in MOE das Ende dieser Schleife (siehe 25) mit der Alpha-Helix aligniert wurde.

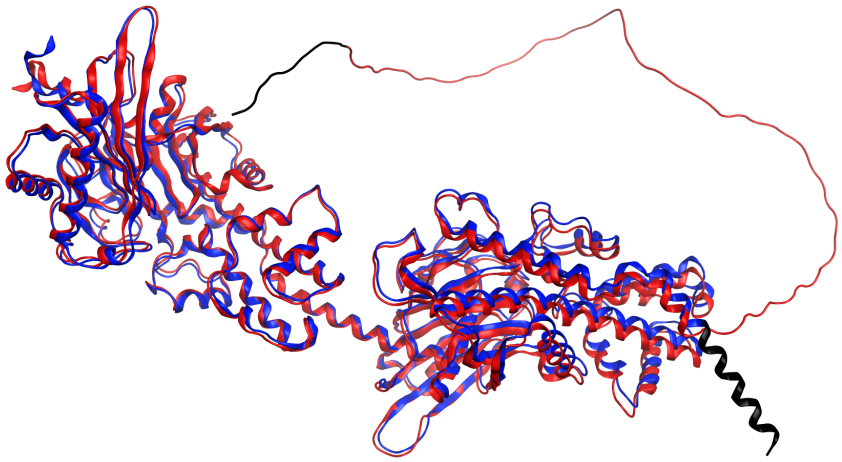


Abbildung 24: Vergleich der Proteine P17710 (rot) und P05708 (blau) in T-Coffee Alignierung. Die Markierung in orange repräsentiert eine Schleife, die nur in einem Protein (P17710) vorkommt, während die schwarzen Markierungen repräsentieren, welcher Teil dieser Schleife mit dem anderen Protein aligniert ist. Erstellt mit MOE.

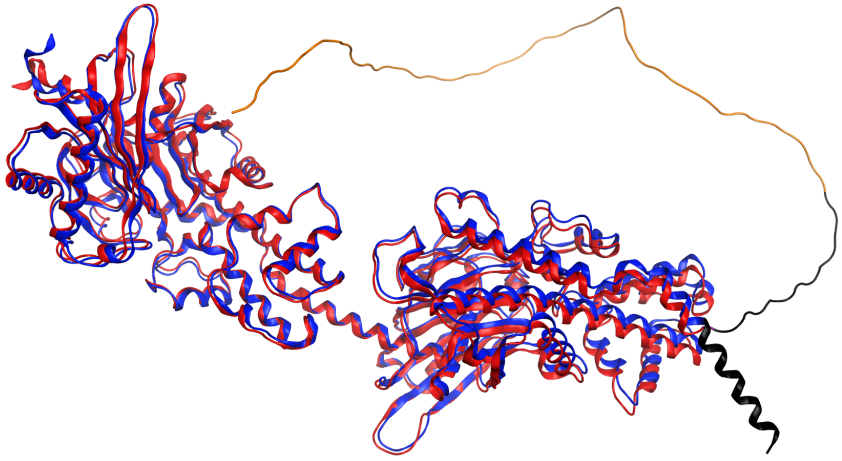


Abbildung 25: Vergleich der Proteine P17710 (rot) und P05708 (blau) in MOE Alignierung. Die Markierung in orange repräsentiert eine Schleife, die nur in einem Protein (P17710) vorkommt, während die schwarzen Markierungen repräsentieren, welcher Teil dieser Schleife mit dem anderen Protein aligniert ist. Erstellt mit MOE.

Diese Schlinge und die Alpha-Helix sind jedoch in keiner der Domänen zu sehen. Die Abbildung 26 zeigt die Domänen der ersten Sequenz (P17710). Die erste Domäne (78-275) ist in schwarz markiert. Die zweite Domäne (282-515) ist in gelb markiert. Die dritte Domäne (526-723) ist in lila markiert. Die vierte Domäne (729-963) ist in grün markiert.

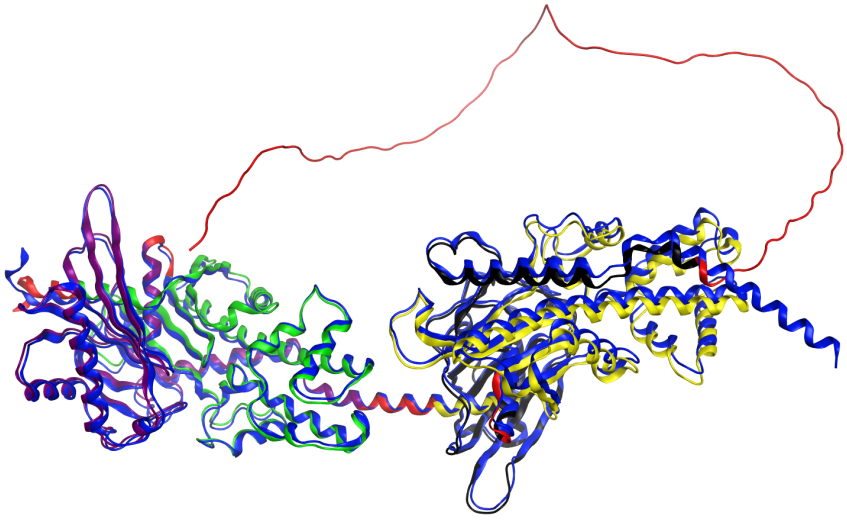


Abbildung 26: Domänen der Proteine P17710 (rot) und P05708 (blau). Sie sind in schwarz, gelb, lila und grün markiert. Erstellt mit MOE.

5.4 Proteinfamilie: Vascular endothelial growth factor A

Es gibt erneut Unterschiede in der Alignierung zwischen T-Coffee und MOE. In der ersten Abbildung 27 ist die Alignierung von T-Coffee dargestellt, während in der zweiten Abbildung 28 die Alignierung von MOE zu sehen ist. T-Coffee aligniert den Anfang der roten Sequenz, P49151, mit einer Schlinge der blauen Sequenz P15692 (Diese sind in grün und schwarz dargestellt). Im Gegensatz dazu aligniert MOE diese Schlinge mit Gaps in der zweiten Sequenz und bringt die beiden Alpha-Helices auf der linken Seite miteinander in Übereinstimmung. Zusätzlich gibt es Unterschiede zwischen der primären Sequenz und der 3D-Struktur. Die Länge der primären Sequenz P15692 beträgt 395, während sie in MOE nur 231 beträgt. Die 3D-Struktur in Alphafold besteht ebenfalls nur aus 231 Aminosäuren. Nach Angaben von InterPro hat die Sequenz P15692 zwei Domänen, nämlich (219-315) und im Bereich (346-395) 16. Diese Positionen sind in der 3D-Struktur nicht zu finden. Dennoch werden diese Bereiche trotzdem in der 3D-Struktur beibehalten, basierend auf dem Vergleich der Aminosäuren zwischen der Primärsequenz und der vorhergesagten Struktur von Alphafold. Daher hat die kürzere 3D-Struktur trotzdem die wichtigen Bereiche bzw. Domänen beibehalten.

Tabelle 16: Analyse von P49151/P15692

Name	**T-Coffee**	**RMSD $_{seq}$**	**RMSD $_{seq, str}$**	**RMSD $_{seq, str, sek}$**	**Domänen**
P49151/P15692	99	11.6	11.6	10.3	P15692 (219-315), (346-395)

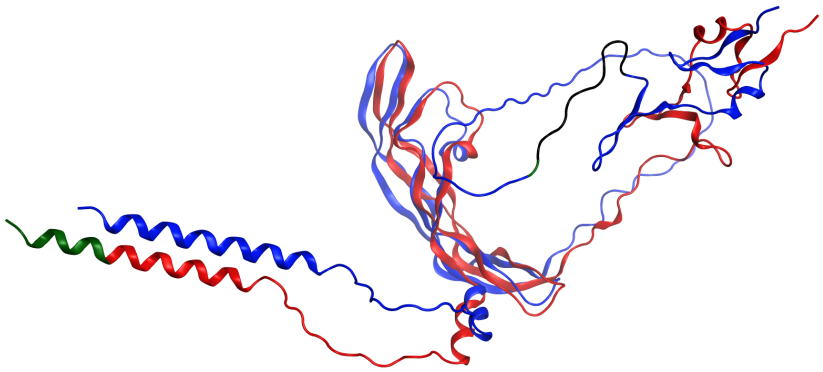


Abbildung 27: Vergleich der Proteine P49151 (rot) und P15692 (blau) in T-Coffee Alignierung. Die Bereiche in grün und schwarz repräsentieren die alignierten Positionen in T-Coffee. Erstellt mit MOE.

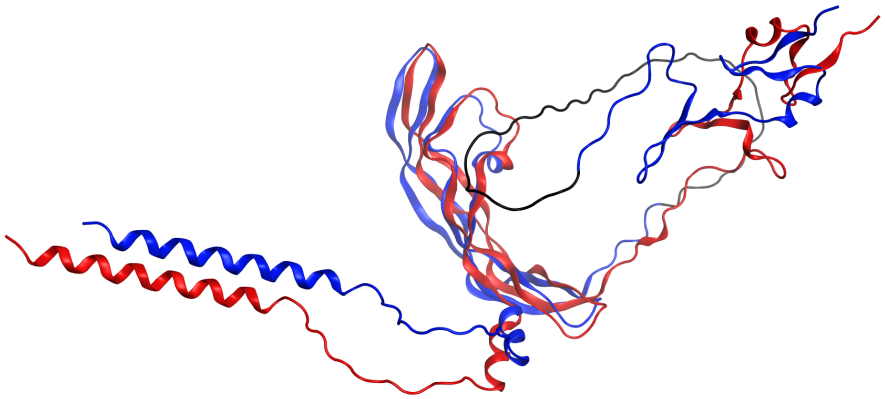


Abbildung 28: Vergleich der Proteine P49151 (rot) und P15692 (blau) in MOE Alignierung. Der schwarze Bereich repräsentiert die alignierten Positionen mit Gaps in MOE. Erstellt mit MOE.

In der nächsten Abbildung 29 sind die beiden Domänen zu finden: Die erste Domäne, die eigentlich (219-315) entsprechen sollte, ist in lila markiert und erstreckt sich von Position (39-135). Die zweite Domäne, die eigentlich (346-395) sein sollte, ist in schwarz gekennzeichnet und erstreckt sich von Position (183-232).

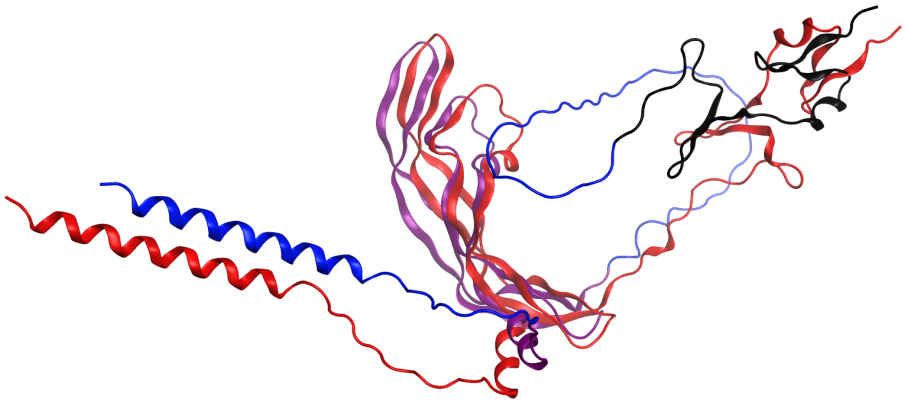


Abbildung 29: Domänen der Proteine P49151 und P15692. Sie sind in lila und schwarz markiert. Erstellt mit MOE.

5.5 Proteinfamilie: Potassium channel subfamily K member 1

Die folgende Tabelle 17 zeigt erneut die Analyse der Proteinstrukturen der Familie des Kaliumkanal-subtyps K-Mitglied 1.

Tabelle 17: Analyse von Kcnk1

Name	T-Coffee	RMSD $_{seq}$	RMSD $_{seq, str}$	RMSD $_{seq, str, sek}$	Domänen
Q5UE96/Q5RD07	100	3.24	3.24	2.95	91-157, 192-268, 166-422
Q8R454/Q9Z2T2	100	1.70	1.68	1.14	3-117, 93-157, 192- 268

5.5.1 Q5UE96/Q5RD07

In der nachfolgenden Abildung 30 ist die Domäne von 91-157 in lila markiert und die Domäne 192-268 ist in schwarz markiert.

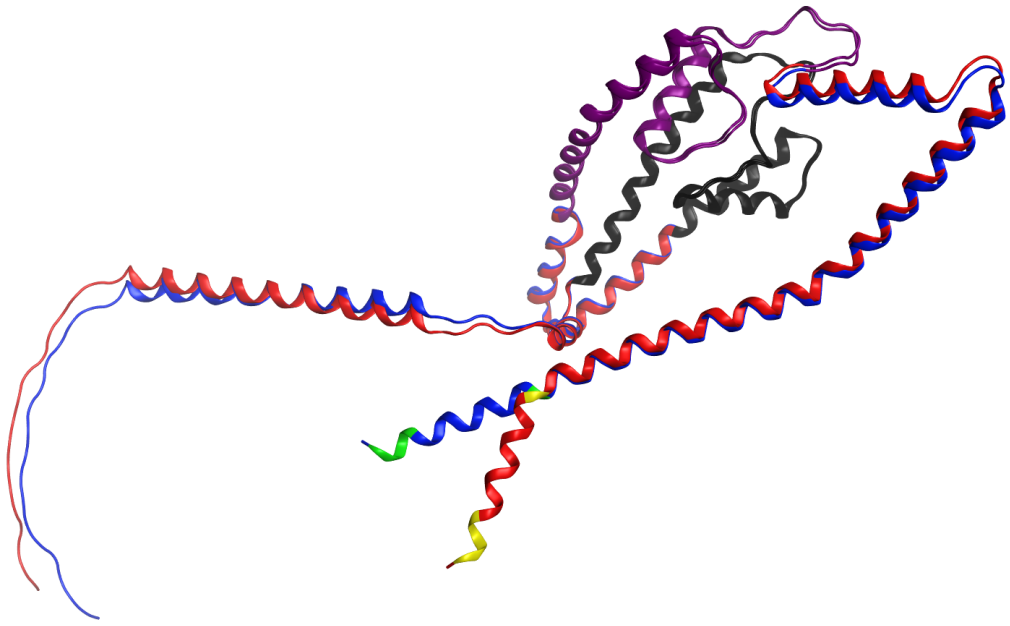


Abbildung 30: Domänen der Proteine Q5UE96 (rot) und Q5RD07 (blau). Sie sind in Lila und Schwarz markiert. Die grünen und gelben Markierungen beziehen sich auf das Vorhandensein verschiedener Aminosäuren an derselben Position mit unterschiedlichen Eigenschaften, was diesen Knick verursacht. Erstellt mit MOE.

Tabelle 18: Analyse von Q5UE96/Q5RD07

2	2	2	Q5UE96	Q5RD07	L	L	id	J	J	N	N	H	-
3	3	3	Q5UE96	Q5RD07	Q	Q	id	N	N	N	N	H	S
4	4	4	Q5UE96	Q5RD07	S	S	id	N	N	J	J	H	S
5	5	5	Q5UE96	Q5RD07	L	L	id	J	J	N	N	H	S
17	17	17	Q5UE96	Q5RD07	H	H	id	N	N	N	N	H	T
21	21	21	Q5UE96	Q5RD07	W	R	nid	N	N	N	N	H	H

Q5UE96 und Q5RD07 sind farblich markiert, wobei Q5UE96 in rot und Q5RD07 in blau erscheint. Die Positionen 2, 3, 4 und 5 befinden sich am unteren Rand. Gemäß der Sekundärstruktur in der Tabelle 18 sollten die Positionen 3, 4 und 5 eigentlich ein Beta-Faltblatt bilden, aber stattdessen sind sie Teil einer Alpha-Helix (gelb). Im Protein Q5RD07 hingegen sind diese Positionen Teil einer Alpha-Helix, was der Sekundärstruktur entspricht. Ein weiterer Unterschied liegt in Position 17, was auch in gelb und grün markiert, wo sich der Knick befindet. Der Grund dafür ist folgendes: Im roten Protein tritt in der Position 21 die Aminosäure Trp auf, während im blauen Protein an derselben Position eine andere Aminosäure, nämlich Arg, vorliegt. Da die Aminosäure Trp einen Ring aufweist, verursacht sie einen Knick nach unten. Dadurch verläuft die Alpha-Helix an dieser Stelle anders und kann ihre Struktur nicht beibehalten.

5.5.2 Q8R454/Q9Z2T2

In Abbildung 31 sind die Domäne von 93 bis 157 in lila und die Domäne von 192 bis 268 in schwarz markiert.

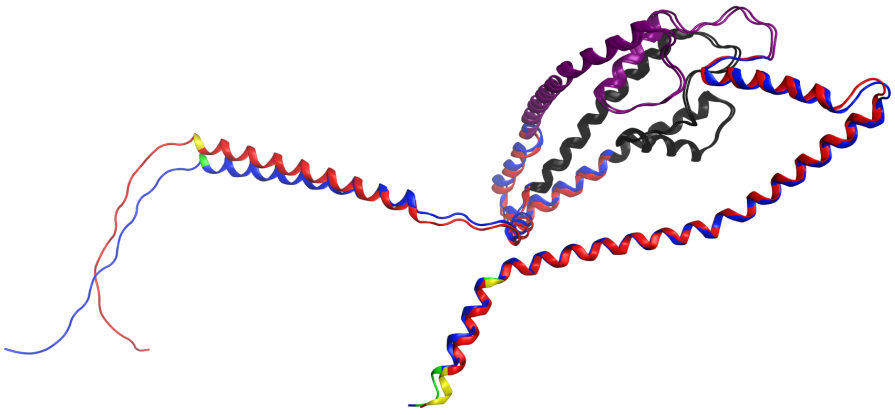


Abbildung 31: Vergleich der Proteine Q8R454 (rot) und Q9Z2T2 (blau). Die gelben und grünen Bereiche repräsentieren das Vorhandensein verschiedener Aminosäuren an denselben Positionen in beiden Proteinen. Erstellt mit MOE.

Hier sind Q8R454 in rot und Q9Z2T2 in blau dargestellt. Die Positionen 2, 3, 4 und 5 befinden sich am unteren Rand der Abbildung. Gemäß der Sekundärstruktur in Tabelle 19 sollten die Positionen 3, 4 und 5 eigentlich ein Beta-Faltblatt bilden, stattdessen sind sie jedoch Teil einer Alpha-Helix (gelb). Im Protein Q9Z2T2 hingegen sind diese Positionen Teil einer Alpha-Helix, was der erwarteten Sekundärstruktur entspricht. An Position 212 ist in beiden Proteinen die Aminosäure W, die einen Ring aufweist, daher weisen beide Proteine einen ähnlichen Knick im Vergleich zum letzten Beispiel auf. Ein weiterer Unterschied liegt in Position 317: Hier ist die Sekundärstruktur in einem Protein als S und im anderen als T markiert. Diese Alpha-Helices sind nicht so gut deckungsgleich aufgrund mehrerer Unterschiede zwischen den Aminosäuren, die unterschiedliche Strukturen aufweisen wie z. B. (Asp, Glu), (Val, Met), (Ser, Asn in Position 318), (Val, Leu) und (Ser, Gly).

Tabelle 19: Analyse von Q8R454/Q9Z2T2

2	2	2	Q8R454	Q9Z2T2	L	L	id	J	J	N	N	H	-
3	3	3	Q8R454	Q9Z2T2	Q	Q	id	N	N	N	N	H	S
4	4	4	Q8R454	Q9Z2T2	S	S	id	N	N	J	J	H	S
5	5	5	Q8R454	Q9Z2T2	L	L	id	J	J	N	N	H	S
17	17	17	Q8R454	Q9Z2T2	H	H	id	N	N	N	N	H	T
21	21	21	Q8R454	Q9Z2T2	W	W	id	N	N	N	N	H	H
369	317	317	Q8R454	Q9Z2T2	Q	Q	id	N	N	N	N	S	T

5.6 Helixbildende und Helixabbrechende Aminosäuren

Der nachfolgende Codeabschnitt ist darauf ausgelegt, den Einfluss einzelner Aminosäuren auf die Struktur von Proteinen zu analysieren, insbesondere die Bildung und den Abbruch von Alpha-Helices. Dabei werden Zeilen gesucht, die gemäß der Sekundärstruktur eine Alpha-Helix darstellen. Anschließend wird überprüft, ob in der nächsten Zeile eine Aminosäure vorkommt, die das Ende der Helix signalisiert, und ob die Helix tatsächlich abgebrochen wird. Falls dies der Fall ist, werden diese beiden Zeilen gespeichert. Dies erfolgt mit den Bedingungen 3, 4, 9 und 10 im Code. Darüber hinaus wird auch das Gegenteil überprüft, nämlich es werden Zeilen gesucht, die gemäß der Sekundärstruktur keine Alpha-Helix darstellen, und anschließend wird geprüft, ob in der nächsten Zeile eine Aminosäure vorkommt, die den Beginn einer Alpha-Helix signalisiert, und ob tatsächlich eine Helix gebildet wird. Falls dies der Fall ist, werden diese beiden Zeilen ebenfalls gespeichert. Dies erfolgt mit den Bedingungen 5, 6, 11 und 12 im Code. Es sind nicht alle Ergebnisse aus allen Protein-Familien in dieser Arbeit dargestellt, sondern nur einige Beispiele.

```
1  selected_rows_list_x = []
2  selected_rows_list_y = []
3
4  for index in range(len(helix_df)):
5      condition_seq3 = helix_df.loc[index, 'dssp_seq1'] == 'H'
6      condition_seq4 = helix_df.loc[index, 'dssp_seq2'] == 'H'
7
8
9      condition_seq5 = helix_df.loc[index, 'dssp_seq1'] != 'H'
10     condition_seq6 = helix_df.loc[index, 'dssp_seq2'] != 'H'
11
12     if index + 1 < len(helix_df):
13         row_next = helix_df.loc[index + 1]
14         condition_seq9 = row_next['Helix-abbrechend1'] == 'J' and row_next['
               dssp_seq1'] != 'H'
15         condition_seq10 = row_next['Helix-abbrechend2'] == 'J' and row_next['
               dssp_seq2'] != 'H'
16
17
18         if index + 1 < len(helix_df):
19         row_next = helix_df.loc[index + 1]
20         condition_seq11 = row_next['Helix-bildened1'] == 'J' and row_next['
               dssp_seq1'] == 'H'
21         condition_seq12 = row_next['Helix-bildend2'] == 'J' and row_next['
               dssp_seq2'] == 'H'
22
```

```
23
24
25          if (condition_seq3 and condition_seq9) or (condition_seq4 and
                condition_seq10):
26              selected_rows_list_x.append(helix_df.loc[index])
27              selected_rows_list_x.append(row_next)
28
29
30           if (condition_seq5 and condition_seq11) or (condition_seq6 and
                condition_seq12):
31              selected_rows_list_y.append(helix_df.loc[index])
32              selected_rows_list_y.append(row_next)
33
34  selected_rows_df_x = pd.DataFrame(selected_rows_list_x, columns=helix_df.
        columns)
35
36  selected_rows_df_y = pd.DataFrame(selected_rows_list_y, columns=helix_df.
        columns)
```

Listing 9: Helixbildende und Helixabbrechende Aminosäuren

In der nachfolgenden Tabelle sind Beispiele für den ersten Fall, in dem Alpha-Helices abgebrochen werden. Die Zeilen 263-501 stammen aus der zweiten Proteinfamilie FFAR2. Die Zeilen 217-328 stammen aus der vierten Proteinfamilie VEGFA.

Tabelle 20: Ergebnisse vom Listing 9

263	70	70	A0A2K5XT84	A0A2I3LNU7	A	A	id	J	J	N	N	H	H
264	71	71	A0A2K5XT84	A0A2I3LNU7	S	S	id	N	N	J	J	T	T
313	119	119	A0A2K5XT84	A0A2I3LNU7	L	L	id	J	J	N	N	H	H
314	120	120	A0A2K5XT84	A0A2I3LNU7	S	S	id	N	N	J	J	S	S
500	276	276	A0A2K5XT84	A0A2I3LNU7	S	S	id	N	N	J	J	H	H
501	277	277	A0A2K5XT84	A0A2I3LNU7	S	S	id	N	N	J	J	-	-
217	35	35	Q9GKR0	P15691	K	K	id	N	N	N	N	S	H
218	36	36	Q9GKR0	P15691	T	P	nid	N	N	J	J	S	T
349	142	142	Q9GKR0	P15691	C	C	id	N	N	N	N	H	S
350	143	143	Q9GKR0	P15691	G	G	id	N	N	J	J	-	T
312	130	130	Q9MYV3	P15691	R	R	id	N	N	N	N	H	-
313	131	131	Q9MYV3	P15691	P	P	id	N	N	J	J	B	-
327	144	139	Q9MYV3	P15691	R	-	nid	N	N	N	N	H	-
328	145	139	Q9MYV3	P15691	G	-	nid	N	N	J	N	-	-

Die Ergebnisse wurden mit MOE verglichen:

- Zeilen 263 und 264 markieren einen Übergang zwischen zwei Alpha-Helices. In Zeile 264 beginnt die Schlinge, die diese Helices verbindet.
- Zeilen 313 und 314 zeigen einen Übergang zwischen einer kleinen Alpha-Helix mit zwei Windungen und einer größeren Alpha-Helix, was auf eine Biegung hinweist.
- In Zeilen 500 und 501 ist eine Biegung zwischen zwei längeren Alpha-Helices zu erkennen. Diese Biegung besteht aus 3 Aminosäuren, die alle Ser sind.
- In Zeilen 217 und 218 wird in MOE ein Teil einer längeren Schlinge angezeigt, jedoch keine Alpha-Helix.
- In Zeilen 349 und 350 wird in MOE keine Alpha-Helix angezeigt, sondern nur eine Schleife. Dies zeigt einen Unterschied zwischen MOE und der sekundären Struktur.
- In Zeilen 312 und 313 handelt es sich um einen Teil eines Beta-Faltblatts. Dieser Bereich weist jedoch Unordnung auf. Es wird häufig zwischen Beta-Faltblatt und einer Schlinge in einer Alpha-Helix mit 1-2 Windungen gewechselt. Die genauen Positionen 312 und 313 befinden sich im Bereich eines Beta-Faltblatts.
- Positionen 327 und 328 zeigen einen Unterschied der Alignierung zwischen MOE und T-Coffee. Position 327 ist in MOE Teil einer Schlinge und keine Alpha-Helix.

In der nachfolgenden Tabelle sind Beispiele für den zweiten Fall, in dem Alpha-Helices gebildet werden. Die Zeilen 77-94 stammen aus der ersten Proteinfamilie At1g58602. Die Zeilen 217-328 stammen aus der dritten Proteinfamilie Hexokinase.

Tabelle 21: Weitere Ergebnisse vom Listing 9

77	27	27	Q8W3K0	G1JSI4	V	V	id	N	N	N	N	-	-
78	28	28	Q8W3K0	G1JSI4	E	E	id	J	J	N	N	H	H
121	55	55	Q8W3K0	G1JSI4	S	S	id	N	N	J	J	-	-
122	56	56	Q8W3K0	G1JSI4	A	A	id	J	J	N	N	H	H
399	242	242	Q8W3K0	G1JSI4	E	E	id	J	J	N	N	G	G
400	243	243	Q8W3K0	G1JSI4	E	E	id	J	J	N	N	-	H
1325	791	786	Q8W3K0	G1JSI4	P	P	id	N	N	J	J	S	S
1326	792	787	Q8W3K0	G1JSI4	M	M	id	J	J	N	N	H	H
742	436	436	A0A1U7V7J6	A0A1S4A301	S	S	id	N	N	J	J	E	E
743	437	437	A0A1U7V7J6	A0A1S4A301	A	A	id	J	J	N	N	H	H
93	36	36	A0A6P6WN18	A0A6P6WMJ8	V	V	id	N	N	N	N	I	I
94	37	37	A0A6P6WN18	A0A6P6WMJ8	L	L	id	J	J	N	N	H	H
74	74	18	P17710	P05708	T	Q	nid	N	N	J	N	-	H
75	75	19	P17710	P05708	E	V	nid	J	N	N	N	H	H

Die Ergebnisse wurden mit MOE verglichen:

- In den Zeilen 77 und 78 sowie 121 und 122 markieren das Ende einer kurzen Schlinge und den Anfang einer Alpha-Helix. Diese Schlinge ist zwischen zwei Alpha-Helices.
- In den Zeilen 399 und 400 befindet sich ein Bereich zwischen zwei Alpha-Helices. In Position 399 bildet sich eine kürzere Alpha-Helix (Sekundärstruktur G), während in Position 400 eine Schlinge in der ersten Sequenz verläuft und in der zweiten Sequenz eine Alpha-Helix gebildet wird. Position 400 markiert den Anfang dieser Alpha-Helix.
- Die Positionen 1325 und 1326 zeigen einen Bereich, in dem sich ein langes Beta-Faltblatt befindet. In diesen Positionen geht es von einer Schlinge über, und es bildet sich eine sehr kurze Alpha-Helix ab Position 1326.
- In den Zeilen 742 und 743 befindet sich Position 742 am Ende einer Schlinge zwischen zwei Alpha-Helices, während Position 743 den Anfang der zweiten Alpha-Helix markiert. In MOE wird Position 742 als ein sehr kleiner Teil eines Beta-Faltblatts betrachtet, was der Sekundärstruktur entspricht.
- Die Zeilen 93 und 94 zeigen bereits eine Alpha-Helix, da sie eine ähnliche Struktur wie H aufweisen. Es handelt sich also nicht um eine Neubildung einer Alpha-Helix.
- In den Zeilen 74 und 75 markiert Position 75 den Anfang einer Helix nach einer sehr langen Schleife.

6 Schlussfolgerung und Zusammenfassung

Die vorliegende Arbeit untersuchte die Möglichkeit, mittels Sequenzalignments der Primärstrukturen verwandter Proteine Unterschiede in ihrer dreidimensionalen Struktur zu identifizieren. Ein Hauptfokus lag hierbei auf der Analyse von Aminosäureaustauschen, die Hinweise auf strukturelle Divergenzen liefern können. Das Ziel bestand darin, eine solide Grundlage für die Analyse der Proteinstrukturbildung zu schaffen und Erkenntnisse über den Einfluss verschiedener Aminosäuren auf die Struktur zu gewinnen. Zusätzlich wurde der Vergleich der Sekundärstrukturen mit der tatsächlichen 3D-Struktur durchgeführt, um potenzielle Abweichungen oder Konservierungen zwischen den verschiedenen Ebenen zu identifizieren und zu verstehen. Darüber hinaus wurde die Rolle von Aminosäuren in Bezug auf die Bildung oder Unterbrechung von Helices in der 3D-Struktur untersucht, um ihren potenziellen Einfluss auf diese strukturellen Aspekte zu erfassen. Diese ganzheitliche Herangehensweise ermöglichte eine gründliche Untersuchung der Proteinstruktur und ihrer dynamischen Eigenschaften. Die Ergebnisse zeigen deutliche Unterschiede, insbesondere zwischen T-Coffee und MOE, hinsichtlich der Art der Sequenzalignierung. Des Weiteren wurde herausgefunden, dass bestimmte Aminosäuren, insbesondere aromatische Aminosäuren wie Trp oder Pro erhebliche Auswirkungen auf die Proteinstruktur haben können, indem sie die Bildung von Helices oder Faltblättern beeinflussen oder zu Strukturbiegungen führen. Zusätzlich können Substitutionen von Aminosäuren durch solche mit einer längeren, kürzeren oder einer anderen chemischen Struktur ebenfalls die Proteinstruktur beeinflussen. Diese Erkenntnisse, ermöglichen es nur bedingt, bereits anhand der Primärstruktur Vorhersagen über potenzielle Unterschiede in der 3D-Struktur zu treffen. Trotz dieser Unterschiede und Herausforderungen konnten wichtige Bereiche, die die Domänen enthalten in den Proteinen konsistent identifiziert werden, was auf die Robustheit der verwendeten Methoden hinweist. Einige Fallbeispiele verdeutlichen jedoch, dass AlphaFold nicht immer die vollständige Tertiärstruktur eines Proteins präzise vorhersagen konnte, was eine Herausforderung für die Analyse darstellt. Zusätzlich wurde beobachtet, dass die mittels DSSP prognostizierte sekundäre Struktur nicht immer mit der beobachteten 3D-Struktur in MOE übereinstimmt. Diese Diskrepanz zwischen den Vorhersagemethoden unterstreicht die Komplexität bei der Bestimmung der sekundären Struktur und betont die Wichtigkeit einer gründlichen Analyse unter Verwendung verschiedener Ansätze. Es ist wichtig anzumerken, dass die sekundäre Struktur auf einer lokalen räumlichen Anordnung der Aminosäuren basiert, während die 3D-Struktur die Gesamtanordnung im Raum betrachtet. Diese Unterscheidung ist entscheidend für das Verständnis der Struktur-Funktions-Beziehung von Proteinen und unterstreicht die Notwendigkeit einer umfassenden Analyse auf verschiedenen Ebenen der Proteinstruktur. Insgesamt trägt diese Arbeit dazu bei, das komplexe Verhältnis zwischen Proteinstruktur und -funktion besser zu verstehen, und betont die Bedeutung einer präzisen Analyse von Sequenz- und Strukturdaten für die bioinformatische Forschung und Anwendung.

7 Literaturverzeichnis

F. Hucho and K. Koechy. *Materialien für einen Gentechnologiebericht: Grundlagenforschung-Medizinische Anwendung-Ökonomische Betreuung*. Spektrum Akademischer Verlag, 1 edition, 2003. ISBN 9783827415240.

Florian Horn. *Biochemie des Menschen - das Lehrbuch für das Medizinstudium*. Georg Thieme Verlag Stuttgart, 6 edition, 2015. ISBN 978-3-13-130886-3.

Ulrich Omasits. Protter. `http://wlab.ethz.ch/protter/start/`, 2024. Abgerufen am 24. März 2024.

Ulrich Helmich. `https://www.u-helmich.de/che/lexikon/A/aminosaeuren.html`, 2023. Abgerufen am 18. März 2024.

D. Whitford. *Proteins: Structure and Function*. John Wiley Sons New York, 1 edition, 2013. ISBN 9781118685723.

Marco F. Schmidt. *Chemische Biologie - und Wirkstoffentwicklung*. Springer, Berlin Heidelberg New York, 1 edition, 2020. ISBN 978-3-662-61115-9.

Wikipedia. `https://de.wikipedia.org/wiki/Aminos%C3%A4uren`, `https://de.wikipedia.org/wiki/Prolin`, `https://de.wikipedia.org/wiki/Peptidbindung`, `https://de.wikipedia.org/wiki/%CE%92-Faltblatt`, `https://de.wikipedia.org/wiki/%CE%91-Helix`. Abgerufen am 13. März 2024.

Rainer Merkl. *Bioinformatik*. Wiley-VCH, 4 edition, 2022. ISBN 9783527833900.

Supratim Choudhuri. *Bioinformatics for Beginners*. Elsevier Amsterdam, 1 edition, 2014. ISBN 978-0-124-10510-2.

Philipp Christen, Rolf Jaussi, and Roger Benoit. *Biochemie und Molekularbiologie - Eine Einführung in 40 Lerneinheiten*. Springer-Verlag, Berlin Heidelberg New York, 1 edition, 2015. ISBN 978-3-662-46430-4.

Andreas D. Baxevanis, Gary D. Bader, and David S. Wishart. *Bioinformatics*. John Wiley Sons New York, 1 edition, 2020. ISBN 978-1-119-33558-0.

Erik Pettersson, Mats Lindskog, Joakim Lundeberg, and Afshin Ahmadian. Tri-nucleotide threading for parallel amplification of minute amounts of genomic DNA. *Nucleic Acids Research*, 34(6):e49–e49, 01 2006. ISSN 0305-1048. doi: 10.1093/nar/gkl103.

Christine Zardecki, Shuchismita Dutta, David S. Goodsell, Robert Lowe, Maria Voigt, and Stephen K. Burley. Pdb-101: Educational resources supporting molecular explorations through biology and medicine. *Protein Science*, 31(1):129–140, 2022. doi: 10.1002/pro.4200.

Andrea Hansen. *Bioinformatik - Ein Leitfaden für Naturwissenschaftler*. Springer-Verlag, Berlin Heidelberg New York, 2 edition, 2013. ISBN 978-3-0348-7855-5.

UniProt. Uniprotkb statistics. `https://www.uniprot.org/uniprotkb/statistics#introduction`, 2024. Abgerufen am 22. März 2024.

The UniProt Consortium. UniProt: the Universal Protein Knowledgebase in 2023. *Nucleic Acids Research*, 51(D1):D523–D531, 11 2022. ISSN 0305-1048. doi: 10.1093/nar/gkac1052.

Paul M. Selzer, Richard J. Marhöfer, and Oliver Koch. *Angewandte Bioinformatik - Eine Einführung*. Springer-Verlag, Berlin Heidelberg New York, 2 edition, 2018. ISBN 978-3-662-54135-7.

Marc-Thorsten Hütt and Manuel Dehnert. *Methoden der Bioinformatik - Eine Einführung zur Anwendung in Biologie und Medizin*. Springer-Verlag, Berlin Heidelberg New York, 2 edition, 2015. ISBN 978-3-662-46150-1.

Jin Xiong. *Essential Bioinformatics*. Cambridge University Press Cambridge, 1 edition, 2006. ISBN 978-1-139-45062-1.

Horst D. Lohrer. *Einführung in die Bioinformatik - Eine Anleitung für Einsteiger*. Springer Berlin Heidelberg, 1 edition, 2022. ISBN 978-3-662-65294-7.

Kazutaka Katoh and Hiroyuki Toh. Recent developments in the MAFFT multiple sequence alignment program. *Briefings in Bioinformatics*, 9(4):286–298, 03 2008. ISSN 1467-5463. doi: 10.1093/bib/bbn013.

David J Russell. *Multiple Sequence Alignment Methods*. Springer New York Heidelberg Dordrecht London, 1 edition, 2014. ISBN 978-1-493-96047-7.

Kazutaka Katoh. Mafft: Multiple alignment program for amino acid or nucleotide sequences. `https://mafft.cbrc.jp/alignment/software/algorithms/algorithms.html`, 2024. Abgerufen am 14. März 2024.

Kazutaka Katoh, Kazuharu Misawa, Kei-ichi Kuma, and Takashi Miyata. MAFFT: a novel method for rapid multiple sequence alignment based on fast Fourier transform. *Nucleic Acids Research*, 30 (14):3059–3066, 07 2002. ISSN 0305-1048. doi: 10.1093/nar/gkf436.

D. P. Klose, B. A. Wallace, and Robert W. Janes. 2Struc: the secondary structure server. *Bioinformatics*, 26(20):2624–2625, 08 2010. ISSN 1367-4803. doi: 10.1093/bioinformatics/btq480.

Systems Biology Research Group. DSSP - define secondary structure of proteins. https://github.com/SBRG/ssbio/blob/master/docs/instructions/dssp.rst. Abgerufen am 26.02.2024.

DSSP - define secondary structure of proteins. https://swift.cmbi.umcn.nl/gv/dssp/. Abgerufen am 26.02.2024.

Mihaly Varadi and Sameer Velankar. The impact of alphafold protein structure database on the fields of life sciences. *PROTEOMICS*, 23(17):2200128, 2023. doi: 10.1002/pmic.202200128.

Alphafold-Webseite. Alphafold protein structure database. https://alphafold.ebi.ac.uk/search/text/At1g58602. Abgerufen am 08.03.2024.

Zhenyu Yang, Xiaoxi Zeng, Yi Zhao, and Runsheng Chen. Alphafold2 and its applications in the fields of biology and medicine. *Signal Transduction and Targeted Therapy*, 8(1):115, 03 2023. ISSN 2059-3635. doi: 10.1038/s41392-023-01381-z.

Gerhard Steger. *Bioinformatik - Methoden zur Vorhersage von RNA- und Proteinstrukturen*. Springer-Verlag, Berlin Heidelberg New York, 1 edition, 2013. ISBN 978-3-0348-7984-2.

Michael P. Berger and Peter J. Munson. A novel randomized iterative strategy for aligning multiple protein sequences. *Computer Applications in the Biosciences*, 7(4):479–484, 10 1991. doi: 10.1093/bioinformatics/7.4.479.

Robert T. Hersh. Atlas of Protein Sequence and Structure, 1966. *Systematic Biology*, 16(3):262–263, 09 1967. ISSN 1063-5157. doi: 10.2307/2412074.

Osamu Gotoh. Optimal alignment between groups of sequences and its application to multiple sequence alignment. *Bioinformatics*, 9(3):361–370, 06 1993. ISSN 1367-4803. doi: 10.1093/bioinformatics/9.3.361.

Aaron Shapiro, Johannes D. Botha, Annalisa Pastore, and Arthur M. Lesk. A method for multiple superposition of structures. *Acta Crystallographica Section A*, 48(Part 1):11–14, 01 1992. doi: 10.1107/s010876739100867x.

Saul B. Needleman and Christian D. Wunsch. A general method applicable to the search for similarities in the amino acid sequence of two proteins. *Journal of Molecular Biology*, 48(3):443–453, 1970. ISSN 0022-2836. doi: 10.1016/0022-2836(70)90057-4.

Irina Kufareva and Ruben Abagyan. Methods of protein structure comparison. *Methods in molecular biology*, 857:231–257, 2012. doi: 10.1007/978-1-61779-588-6_10.

MAFFT Team. MAFFT documentation. https://mafft.cbrc.jp/alignment/software/, 2021. Abgerufen am 15. November 2023.

T-Coffee Team. T-Coffee documentation. https://tcoffee.readthedocs.io/en/latest/tcoffee_main_documentation.html, 2018. Abgerufen am 10. November 2023.

Python Software Foundation. Python documentation. https://docs.python.org/3/, 2023. Abgerufen am 20. Oktober 2023.

Biopython Contributors. Biopython documentation. https://biopython.org/wiki/Documentation, 2024. Abgerufen am 03. Januar 2024.

The UniProt Consortium. UniProt. https://www.uniprot.org/, 2024. Abgerufen am 08. Februar 2024.

The UniProt Consortium. UniProt: a worldwide hub of protein knowledge. *Nucleic Acids Research*, 47(D1):D506–D515, 11 2018. ISSN 0305-1048. doi: 10.1093/nar/gky1049.

Engelbert Buxbaum. *Fundamentals of Protein Structure and Function*. Springer International Publishing, Berlin Heidelberg New York, 2 edition, 2015. ISBN 978-3-319-19919-1.

Overleaf. Overleaf documentation. https://de.overleaf.com/learn, 2024. Abgerufen am 23. Oktober 2023.

European Bioinformatics Institute (EMBL-EBI). AlphaFold. https://alphafold.ebi.ac.uk/, 2024. Abgerufen am 25. Februar 2024.

Pandas Development Team. Pandas Documentation. https://pandas.pydata.org/docs/, 2024. Abgerufen am 22. Februar 2024.

Thomas Dandekar and Meik Kunz. *Bioinformatik - Ein einführendes Lehrbuch*. Springer-Verlag, Berlin Heidelberg New York, 1 edition, 2017. ISBN 978-3-662-54698-7.

Kelly L. Damm and Heather A. Carlson. Gaussian-weighted RMSD superposition of proteins: a structural comparison for flexible proteins and predicted protein structures. *Biophysical Journal*, 90 (12):4558–4573, 06 2006. doi: 10.1529/biophysj.105.066654.

Daniel Fischer and David Eisenberg. Protein fold recognition using sequence-derived predictions. *Protein Science*, 5(5):947–955, 05 1996. doi: 10.1002/pro.5560050516.

Gaston H. Gonnet, Mark A. Cohen, and Steven A. Benner. Exhaustive matching of the entire protein sequence database. *Science*, 256(5062):1443–1445, 1992. doi: 10.1126/science.1604319.

Makoto Hirosawa, Yasushi Totoki, Masaki Hoshida, and Masato Ishikawa. Comprehensive study on iterative algorithms of multiple sequence alignment. *Bioinformatics*, 11(1):13–18, 02 1995. ISSN 1367-4803. doi: 10.1093/bioinformatics/11.1.13.

Abbildungsverzeichnis

1 Primärstruktur eines Proteins . . . 3
2 Grundgerüst einer Aminosäure . . . 4
3 Strukturformel der Aminosäure Prolin . . . 5
4 Struktur einer Peptidbindung . . . 6
5 Struktuer einer Alpha-Helix . . . 6
6 Struktur eines Beta-Faltblatts . . . 7
7 Anzahl der spezifischen Austausche (PAMs) . . . 12
8 Ablaufschema eines multiplen Alignments . . . 15
9 Guide Tree . . . 16
10 Beispiel eines alignierten Proteins . . . 39
11 Q8W3K0/G1JSI4 (1) . . . 40
12 Vergleich der Proteine Q8W3K0 und G1JSI4 . . . 41
13 Einfluss der Substitutionen der Aminosäuren auf die Bildung einer Helixstruktur . . . 43
14 Vergleich der Proteine A0A1U7V7J6 (rot) und A0A1S4A301 (blau) . . . 44
15 Die Domänen der Proteine A0A1U7V7J6 (rot) und A0A1S4A301 (blau) . . . 45
16 Domäne der Proteine B9K5 (rot) und B9D8 (blau) . . . 45
17 Vergleich der Proteine A0A6P6G1A9 (rot) und A0A6P3ZEI4 (blau). . . . 46
18 Domänen der Proteine A0A6P6G1A9 (rot) und A0A6P3ZEI4 (blau) . . . 47
19 Vergleich der Proteine A0A6P6WN18 (rot) und A0A6P6WMJ8 (blau) . . . 48
20 Abbruch einer Alpha-Helix im Protein A0A6P6WMJ8 (blau) . . . 49
21 Domäne des Proteins A0A6P6WN18 (rot) und A0A6P6WMJ8 (blau) . . . 50
22 Vergleich der Proteine A0A6P6WSC7 (rot) und A0A6P6X4U5 (blau) . . . 51
23 Vergleich der Proteine A0A2K5XT84 (rot) und F7HN43 (blau) . . . 52
24 Vergleich der Proteine P17710 (rot) und P05708 (blau) in T-Coffee Alignierung . . . 53
25 Vergleich der Proteine P17710 (rot) und P05708 (blau) in MOE Alignierung . . . 53
26 Domänen der Proteine P17710 (rot) und P05708 (blau) . . . 54
27 Vergleich der Proteine P49151 (rot) und P15692 (blau) in T-Coffee Alignierung . . . 55
28 Vergleich der Proteine P49151 (rot) und P15692 (blau) in MOE Alignierung . . . 55
29 Domänen der Proteine P49151 und P15692 . . . 56
30 Domänen der Proteine Q5UE96 (rot) und Q5RD07 (blau) . . . 57
31 Vergleich der Proteine Q8R454 (rot) und Q9Z2T2 (blau) . . . 58

Tabellenverzeichnis

1 Score aller paarweisen Alignments . . . 16
2 Helixpotenziale (Pα) von Aminosäureresten . . . 28

3 Inhalt von daf1 . . . 31
4 Inhalt von daf2.csv mit sekundären Strukturen aus der DSSP-Datei . . . 34
5 Ergänzung von daf1 . . . 37
6 Die ergänzte Tabelle . . . 38
7 Analyse von At1g58602 . . . 40
8 Analyse von Q8W3K0 und G1JSI4 . . . 41
9 Analyse von Q8W3K0 und G1JSI4 . . . 42
10 7J6/A301 . . . 44
11 Analyse von G1A9/ZEI4 . . . 46
12 Analyse von N18/MJ8, Positionen 1846-1877 . . . 47
13 Analyse von M18/NJ8, Positionen 469- 473 . . . 49
14 Analyse von WSc7/X4U5 . . . 51
15 Analyse von T84/N43 . . . 51
16 Analyse von P49151/P15692 . . . 54
17 Analyse von Kcnk1 . . . 57
18 Analyse von Q5UE96/Q5RD07 . . . 58
19 Analyse von Q8R454/Q9Z2T2 . . . 59
20 Ergebnisse vom Listing 9 . . . 62
21 Weitere Ergebnisse vom Listing 9 . . . 63

Listings

1 Installation von Biopython . . . 26
2 Distanzmatrix Abrechnung . . . 26
3 Unterschiedliche Aminosäuren finden . . . 27
4 Klassifizierung der Daten (Sequenzen) . . . 28
5 DSSP Dateien analysieren . . . 32
6 DSSP Einträge speichern . . . 35
7 Dataframe schmelzen . . . 36
8 Ergänzung der daf1.csv . . . 36
9 Helixbildende und Helixabbrechende Aminosäuren . . . 60

Abkürzungsverzeichnis

BLOSUM Blocks Substitution Matrix

ClustalW Series of computer programs used in bioinformatics for multiple sequence alignment.

CSV Comma-Separated Values

DNA Desoxyribonukleinsäure

DSSP Dictionary of Secondary Structure of Proteins

FFT Fast Fourier Transform

FFT-NS-1 Fast Fourier Transform - Nucleotide Sequence 1

FFT-NS-2 Fast Fourier Transform - Nucleotide Sequence 2

InterPro Integrated Resource of Protein Domains and Functional Sites

KI Künstliche Intelligenz

MAFFT Multiple Alignment using Fast Fourier Transform

MOE Molecular Operating Environment

MSA Multiple Sequence Alignment

NCBIRefseq National Center for Biotechnology Information Reference Sequence

PAM-Matrix Point Accepted Mutation Matrix

PDB Protein Data Base

Pfam Protein Families database

RMSD Root Mean Square Deviation

RNA Ribonukleinsäure

SMART Simple Modular Architecture Research Tool

T-Coffee Tree-based Consistency Objective Function for alignment Evaluation

UniProt Universal Protein Resource

UniProtKB UniProt Knowledgebase

A	Alanin, Ala
C	Cystein, Cys
D	Asparaginsäure, Asp
E	Glutaminsäure, Glu
F	Phenylalanin, Phe
G	Glycin, Gly
H	Histidin, His
I	Isoleucin, Ile
K	Lysin, Lys
L	Leucin, Leu
M	Methionin, Met
N	Asparagin, Asn
P	Prolin, Pro
Q	Glutamin, Gln
R	Arginin, Arg
S	Serin, Ser
T	Threonin, Thr
V	Valin, Val
W	Tryptophan, Trp
Y	Tyrosin, Tyr

A Verwendete Hilfsmittel

In dieser Arbeit wurden verschiedene Hilfsmittel und Ressourcen verwendet, um die Forschung durchzuführen und die Ergebnisse zu erzielen. Die wichtigsten Hilfsmittel umfassen:

- Jupyter Notebook: Zur interaktiven Ausführung von Python-Code und Dokumentation von Schritten.
- Python 3: Für die Implementierung und Analysen.
- MAFFT: Ein Werkzeug zur Bildung von MSA
- T-Coffee: Ein Werkzeug zur Bildung von MSA
- DSSP: Ein Programm zur Sekundärstrukturvorhersage von Proteinen aus ihrer dreidimensionalen Struktur.
- LaTeX: Für die Erstellung von wissenschaftlichen Dokumenten und Berichten.
- MOE: Für die Modellierung von Proteinen in dreidimensionalen Strukturen
- ChatGPT: Für die sprachliche und grammatikalische Verbesserung meiner geschriebenen Texte.
- Tableconvert `https://tableconvert.com/de/`: Für die Umwandlung von CSV-Dateien in LaTeX-Tabellen
- Protter `https://wlab.ethz.ch/protter/start/`: Für die Erstellung von Primärsequenzenabbidlungen

Diese Hilfsmittel wurden verwendet, um Daten zu verarbeiten, Analysen durchzuführen, Texte sprachlich oder grammatikalisch zu verbessern und somit entstammt der Inhalt dieser Bachelorarbeit komplett von mir und hat sich durch die Verwendung des Hilfsmittels nicht geändert

B Selbstständigkeitserklärung

Hiermit erkläre ich, dass ich die vorliegende Arbeit selbstständig angefertigt, nicht anderweitig zu Prüfungszwecken vorgelegt und keine anderen als die angegebenen Hilfsmittel verwendet habe. Sämtliche wissentlich verwendete Textausschnitte, Zitate oder Inhalte anderer Verfasser wurden ausdrücklich als solche gekennzeichnet.

Datum: Unterschrift: _____