Entwicklung und Evaluation verschiedener Verfahren zur automatisierten Extraktion von Tumormarkern aus deutschsprachigen Pathologiebefunden des Krebsregisters Sachsen-Anhalt

Eine Untersuchung regelbasierter Verfahren, Prompt-Engineering-basierter Verfahren und des Fine-Tunings lokaler Large Language Models sowie des Potenzials embedding-basierter Metriken zur goldstandardfreien Bewertung der Extraktionsqualität

30. Juli 2026

1 Einleitung und Problemstellung

Die automatisierte Informationsextraktion (IE) aus medizinischen Freitexten wird im Gesundheitswesen immer wichtiger (Wiest et al., 2025; Reichenpfader et al., 2025). Klinische Krebsregister nutzen sie, um relevante Informationen aus Pathologiebefunden – wie Tumor- und Biomarker sowie histopathologische, diagnostische und prognostische Merkmale – strukturiert zu erfassen und dadurch Dokumentation, Forschung und Patientenversorgung zu verbessern.

In der Praxis erfolgt die Extraktion dieser Informationen häufig manuell durch medizinische Dokumentarinnen und Dokumentare. Dieser Prozess ist zeitaufwendig, personalintensiv und aufgrund der zunehmenden Anzahl molekularpathologischer Untersuchungen nur begrenzt skalierbar. Die Entwicklung automatisierter Verfahren zur Information Extraction besitzt daher ein erhebliches Potenzial zur Unterstützung klinischer Dokumentationsprozesse.

Die Relevanz dieser Fragestellung wird durch das vom Bundesministerium für Gesundheit geförderte Forschungsprojekt **TeMeK (TextMining von Meldungstexten für einheitliche Klassifikationen)** des Krebsregisters Baden-Württemberg unterstrichen (Projektbeschreibung des BMG). Ziel des Projekts ist die Entwicklung KI-gestützter

Verfahren zur automatisierten Extraktion strukturierter Informationen aus den unstrukturierten Freitexten klinischer Krebsregister, um die Qualität und Effizienz der Krebsregistrierung zu verbessern.

Für die Extraktion medizinischer Informationen kommen regelbasierte Verfahren, Large Language Models (LLMs) mit Prompt Engineering sowie parameter-effizientes Fine-Tuning Sprachmodelle zum Einsatz. Welcher Ansatz unter den Anforderungen klinischer Krebsregister die beste Balance zwischen Extraktionsqualität, Implementierungsaufwand und Rechenressourcen bietet, ist bislang jedoch nicht ausreichend untersucht.

Die Evaluation von Extraktionsverfahren erfolgt meist anhand manuell erstellter Goldstandards und Kennzahlen wie Precision, Recall und F1-Score. Die Erstellung solcher Referenzdaten ist jedoch aufwendig, da medizinische Freitexte von Fachexpertinnen und Fachexperten sorgfältig annotiert und überprüft werden müssen. Dieser Prozess ist zeit- und kostenintensiv und lässt sich nur begrenzt skalieren. Daher untersucht die Arbeit, ob embedding-basierte semantische Ähnlichkeitsmaße als goldstandardfreie Alternative zur Qualitätsbewertung geeignet sind.

2 Zielsetzung

Ziel der Masterarbeit ist die Entwicklung und Evaluation verschiedener Verfahren zur automatisierten Extraktion von Tumormarkern aus deutschsprachigen Pathologiebefunden.

Hierzu werden drei unterschiedliche Ansätze untersucht:

- Regelbasierte Verfahren,
- Prompt Engineering verschiedener Large Language Models,
- Fine-Tuning lokaler Large Language Models.

Die Verfahren werden hinsichtlich ihrer Extraktionsqualität sowie ihres praktischen Einsatzpotenzials im Umfeld klinischer Krebsregister bewertet.

Darüber hinaus wird untersucht, ob embedding-basierte Ähnlichkeitsmetriken eine Abschätzung der Extraktionsqualität ermöglichen können.

3 Forschungsfragen

RQ1

Wie unterscheiden sich regelbasierte Verfahren, Prompt Engineering mit verschiedenen Large Language Models sowie parametereffizient fine-getunte Large Language Models hinsichtlich Precision, Recall und F1-Score bei der automatisierten Extraktion von Tumormarkern aus deutschsprachigen Pathologiebefunden?

RQ2

Kann ein ressourcenschonendes Fine-Tuning (z. B. LoRA oder QLoRA) eines kleinen lokalen Large Language Models die Extraktionsleistung gegenüber reinem Prompt Engineering verbessern, und wie schneidet es hinsichtlich Extraktionsqualität und Ressourcenbedarf im Vergleich zum Prompt Engineering größerer lokaler Large Language Models ab?

RQ3

Inwieweit eignen sich embedding-basierte semantische Ähnlichkeitsmetriken als goldstandardfreie Qualitätssignale für Information-Extraction-Aufgaben im medizinischen Kontext, und wie stehen diese Metriken mit den klassischen Qualitätsmaßen Precision, Recall und F1-Score in Beziehung?

4 Datengrundlage

Als Datengrundlage dienen Meldedaten des klinischen Krebsregisters Sachsen-Anhalt, die im bundeseinheitlichen onkologischen Basisdatensatz (oBDS) erfasst sind.

Der oBDS ist der standardisierte Datenaustauschstandard für Krebsregister in Deutschland und liegt als hierarchisch aufgebautes XML-Format vor. Die Meldungen enthalten sowohl strukturierte medizinische Informationen, beispielsweise ICD-10- und ICD-O als auch unstrukturierte Freitexte aus Pathologiebefunden.

Im Rahmen dieser Arbeit bilden die Freitexte der Pathologiebefunde die Grundlage für die Information Extraction.

5 Methodisches Vorgehen

Zunächst werden die Pathologiebefunde aus den oBDS-Meldungen aufbereitet und die relevanten Tumormarker definiert.

Anschließend werden drei unterschiedliche Extraktionsansätze entwickelt beziehungsweise konfiguriert:

- Ein regelbasiertes Verfahren auf Basis medizinischer Regeln und regulärer Ausdrücke,
- Prompt Engineering verschiedener Large Language Models,
- Ein parametereffizient fine-getuntes lokales Large Language Model.

Die Extraktionsergebnisse werden mit Precision, Recall und F1-Score bewertet. Im Anschluss werden verschiedene Embedding-Modelle untersucht. Hierbei werden die erzeugten Extraktionen semantisch mit den relevanten Informationen aus den Pathologiebefunden verglichen. Anschließend wird analysiert, inwieweit die resultierenden Ähnlichkeitsmetriken mit den klassischen Qualitätsmaßen der Information Extraction zusammenhängen.

6 Erwarteter wissenschaftlicher Beitrag

Die Arbeit liefert einen systematischen Beitrag zur automatisierten Information Extraction aus deutschsprachigen Pathologiebefunden.

Zum einen werden unterschiedliche methodische Ansätze hinsichtlich ihrer Extraktionsqualität, ihres Implementierungsaufwands und ihrer benötigten Rechenressourcen untersucht. Daraus lassen sich Handlungsempfehlungen für den praktischen Einsatz in klinischen Krebsregistern ableiten.

Zum anderen wird untersucht, ob embedding-basierte Evaluationsmetriken geeignet sind, die Qualität automatisierter Information-Extraction-Verfahren ohne manuell annotierte Referenzdaten abzuschätzen. Da entsprechende Verfahren auch für die Evaluation von LLM-Anwendungen noch Gegenstand aktueller Forschung sind, wird dieser Ansatz auf die strukturierte Information Extraction im medizinischen Kontext übertragen und bewertet.

Darüber hinaus entsteht im Rahmen der Arbeit eine Anwendung zur automatisierten Extraktion relevanter Informationen aus Pathologiebefunden, die perspektivisch im Krebsregister Sachsen-Anhalt eingesetzt werden kann. Sie unterstützt die strukturierte Erfassung onkologischer Informationen und schafft eine Grundlage für eine effizientere Verarbeitung medizinischer Befunddaten.

Alle Verfahren werden ausschließlich lokal implementiert und evaluiert, um den Schutz sensibler Patientendaten und die Einhaltung datenschutzrechtlicher Anforderungen sicherzustellen.