Automatisierte Extraktion von Tumormarkern aus deutschsprachigen Pathologiebefunden

Exposé zur Masterarbeit
zur Erlangung des Grades Master of Science (M.Sc.)

Ahmad Wattar

Martin-Luther-Universität Halle-Wittenberg

5. August 2026

Motivation und Problemstellung

- Meldepflichtige onkologische Daten werden elektronisch an Krebsregister übermittelt.
- Pathologiebefunde enthalten wichtige klinische Informationen wie Tumormarker.
- Diese Informationen liegen häufig als unstrukturierter Freitext vor.
- Die Erfassung erfolgt aktuell oft manuell durch medizinische Dokumentarinnen und Dokumentare.
- Der Prozess ist zeitaufwendig, personalintensiv
- Automatisierte Information Extraction kann Krebsregister bei der Dokumentation unterstützen.

Ziel: Strukturierte Informationen automatisch aus Pathologiebefunden extrahieren.

Datengrundlage

- Antrag auf Nutzung von Krebsregisterdaten
- Datenquelle: Krebsregister Sachsen-Anhalt
- Meldedaten liegen als **XML-Dateien gemäß dem oBDS-Standard** vor.
- oBDS = bundeseinheitlicher onkologischer Basisdatensatz
- Standardisiertes Austauschformat für Krebsregisterdaten in Deutschland

Umfang

- Pathologie-Meldungen: 762 (Halle, Magdeburg, Dessau)
- GTDS-Meldungen: 692 (Gießener Tumordokumentationssystem)
- Zeitraum der Pathologie-Meldungen: 16.07.2024 bis 04.09.2025

Struktur der XML-Daten

- Die Daten sind in einer **hierarchischen Baumstruktur** organisiert.
- Die Meldungen enthalten beispielsweise:
  - Patienten- und Meldungsidentifikatoren,
  - Tumorzuordnung und ICD-Codes,
  - Angaben zur Histologie und Morphologie,
  - den vollständigen pathologischen Befundtext.

Für die Information Extraction ist vor allem der Befundtext relevant.

Ziel der Masterarbeit

Ziel ist die Entwicklung und Evaluation verschiedener Verfahren zur automatisierten Extraktion von Tumormarkern aus deutschsprachigen Pathologiebefunden.

Untersucht werden drei Ansätze:

1. Regelbasierte Verfahren (reguläre Ausdrücke)
2. Prompt Engineering für Large Language Models (mit verschiedenen Prompt-Strategien)
3. Fine-tuning lokale Large Language Models

Zusätzlich wird untersucht, ob embedding-basierte Metriken als goldstandardfreie Qualitätsindikatoren geeignet sind.

Forschungsfragen

RQ1: Vergleich der Extraktionsverfahren

Wie unterscheiden sich regelbasierte Verfahren, Prompt Engineering und parametereffizient fine-getunte LLMs hinsichtlich Precision, Recall und F1-Score?

RQ2: Fine-Tuning und Ressourcenbedarf

Verbessert LoRA bzw. QLoRA die Extraktionsleistung kleiner lokaler LLMs gegenüber Prompt Engineering, und wie ist der Vergleich zu größeren lokalen LLMs?

RQ3: Embedding-basierte Qualitätsbewertung

Eignen sich semantische Ähnlichkeitsmetriken als goldstandardfreie Qualitätssignale, und wie hängen sie mit Precision, Recall und F1-Score zusammen?

Erwarteter wissenschaftlicher Beitrag

- Systematischer Vergleich verschiedener IE-Verfahren für deutschsprachige Pathologiebefunde
- Bewertung lokaler, datenschutzkonformer LLM-Ansätze
- Analyse, ob Embeddings die Extraktionsqualität ohne Goldstandard abschätzen können
- Praktische Anwendung im Krebsregister Sachsen-Anhalt

Zusammenfassung

- Pathologiebefunde enthalten wichtige Informationen, liegen aber oft als Freitext vor.
- Die manuelle Erfassung ist aufwendig.
- Die Arbeit vergleicht Regex, Prompting und Fine-Tuning.
- Zusätzlich wird eine goldstandardfreie Bewertung mit Embeddings untersucht.

Vielen Dank für die Aufmerksamkeit!