

REFERENCE-FREE LLM SUMMARY BENCHMARKING

For Local Medical Speech-to-Text Pipelines

Reference-Free Benchmarking of LLM-Generated Medical Summaries

Ahmad Wattar · Jan Christoph · Christoph Demus · Patrick Liegel · Christian Jäger

Research Group (Bio-) Medical Data Science · Martin Luther University Halle-Wittenberg

Ahmad.wattar@uk-halle.de

Published Paper



Embedding-Based Evaluation and Benchmarking Framework for Optimizing LLM Post-Processing of Medical Transcriptions from a Local Whisper System

Ahmad WATTAR[a], Jan CHRISTOPH[a], Christoph DEMUS[a], Patrick LIEGEL[a], and Christian JÄGER[a1]

[a] Research Group (Bio-) Medical Data Science, Faculty of Medicine, Martin Luther University Halle-Wittenberg, Halle (Saale), Germany
ORCiD ID: AW 0000-0002-3434-566X , JC 0000-0003-4369-3591 , CD 0000-0003-4319-3175 , PL 0009-0007-5179-6343 , CJ 0000-0002-2740-8386

Abstract. **Introduction:** Locally deployed speech-to-text systems such as Whisper enable privacy-preserving transcription of medical encounters. However, the resulting transcripts are often lengthy, noisy, and insufficiently structured for direct integration into clinical documentation workflows. Large language models (LLMs) can transform such transcripts into concise clinical summaries, yet evaluating their quality and reliability remains challenging, particularly in the absence of gold-standard reference summaries. **Materials and Methods:** We propose a reference-free evaluation framework for benchmarking LLM-based post-processing of clinical transcripts generated by a locally deployed Whisper system. The framework combines embedding-based transcript–summary semantic similarity, stability analysis across repeated generations, and structured human evaluation. It was applied to 26 German physician–patient conversations. Four LLMs generated four summaries per transcript using standardized prompts and decoding parameters, resulting in 416 summaries. A subset of summaries was additionally assessed by three human raters using six predefined quality criteria. **Results:** GPT-OSS-120B and MedGemma-27B achieved the highest transcript–summary similarity scores across most embedding models. Although absolute similarity values varied across embedding models, relative model rankings remained largely consistent, indicating robustness of the evaluation framework. Stability analysis showed high consistency across repeated runs, with cosine similarities typically exceeding 0.90, while higher sampling temperatures reduced semantic similarity. Human evaluation showed partial agreement between embedding-based similarity signals and human judgments of summary quality. **Conclusion:** The proposed framework enables scalable, reference-free evaluation of LLM-based clinical summarization in privacy-sensitive settings. By combining semantic similarity, stability analysis, and human evaluation, it supports systematic model benchmarking, relative model comparison, and optimization without requiring reference summaries. These findings suggest that embedding-based metrics can provide useful signals for selecting and optimizing LLM-based post-processing models in local speech-to-text pipelines.

Keywords. Speech Recognition Software; Natural Language Processing; Medical Records; Large Language Models; Benchmarking; Artificial Intelligence

Based on Our Conference Paper

Embedding-Based Evaluation and Benchmarking Framework for Optimizing LLM Post-Processing of Medical Transcriptions from a Local Whisper System

Ahmad Wattar · Jan Christoph · Christoph Demus · Patrick Liegel · Christian Jäger

Research Group (Bio-) Medical Data Science, Martin Luther University Halle-Wittenberg, Germany

DOI: 10.3233/SHTI261001

From Clinical Conversations to Reliable Summaries

SOURCE



26 recorded clinical conversations
Mean: 18 min

TRANSCRIPTION



Local speech-to-text (Whisper)

TEXT INPUT



26 raw transcripts

From Clinical Conversations to Reliable Summaries

SOURCE	TRANSCRIPTION	TEXT INPUT	GENERATION	OUTPUT
				
26 recorded clinical conversations Mean: 18 min	Local speech-to-text (Whisper)	26 raw transcripts	4 LLMs x 4 runs	26 × 4 × 4 = 416 summaries

Example Input: Clinical Transcript (20 min 06 s)

Schönen guten Tag, mein Name ist Nina Kulett. Ich bin die Assistenzärztin hier auf der Station. Ich würde gerne das Aufnahmegespräch mit Ihnen durchführen. Sind Sie damit einverstanden? Ja, ich bin einverstanden. Prima. Kurz zum Ablauf. Ich würde Ihnen gerne ein paar personenbezogene Fragen stellen. Dann komme ich sofort zu Ihren Beschwerden. Wenn Sie etwas nicht verstehen oder Fragen haben, würde ich Sie bitten, mir ein Zeichen zu geben. Dann machen wir eine kurze Pause. Meinen Sie, das dauert lange? Nee, wir beeilen uns natürlich, damit wir Sie schnell untersuchen können. Wie heißen Sie denn? Ich heiße Maria Stettner. Frau Stettner, wann ist Ihr Geburtstag? 1. März 1960. Und wie groß sind Sie? Ich bin 1,67 m groß. Wissen Sie, wie viel Sie zurzeit wiegen? Müssten so um die 69,5 kg sein. Okay, super. Bei wem sind Sie denn in hausärztlicher Behandlung? Bei der Frau Dr. Müller. Frau Dr. Müller. Frau Stettner, was machen Sie denn vom Beruf? Ich vertanze. Und sind Sie verheiratet? Nein, geschieden, Gott sei Dank. Haben Sie Kinder, Frau Stettner? Ja, ich habe eine Tochter, die nur Ärger bringt, leider. Dann kommen wir jetzt zu Ihren Beschwerden. Was führt Sie denn zu uns? Ich habe seit gestern Probleme mit dem Magen. Ich habe ganz heftige Schmerzen und die gehen nicht weg. Ich habe ja viel zu tun und will es eigentlich nur, geben Sie mir irgendwas, damit es besser geht. Ich habe keinen Zeitdienst auch dafür. Ja, das kann ich verstehen. Aber bevor ich Ihnen etwas Falsches gebe, stelle ich Ihnen noch ein paar Fragen. Die Schmerzen, können Sie die beschreiben? Sind das Krämpfe oder ist das ein drückender Schmerz, ein stechender Schmerz? Das sind so Krämpfe. Wann sind die genau aufgetreten, gestern? Gestern Abend nach dem Abendessen. Was haben Sie denn gegessen? Ein Mettbrötchen. Mussten Sie sich auch übergeben? Ja, ich habe mich, glaube ich, dreimal übergeben, gestern Abend. Ging es Ihnen danach besser? Etwas besser. Können Sie mir etwas von dem Übergebenen, von dem Erbrochenen erzählen? Waren das Essensreste oder war das eher wässrig? Das waren Essensreste und es war etwas gelblich von der Farbe her. Die Schmerzen im Magen, von denen Sie gesprochen haben, wie stark sind die? Wenn wir von einer Schmerzskala sprechen, wobei 1 ganz leichte Schmerzen sind und 10 sehr starke Schmerzen. Wo schätzen Sie die Schmerzen ein? Einmal im Ruhezustand und einmal, wenn Sie Krämpfe haben? Im Ruhezustand sind sie bei 4, würde ich sagen. Aber wenn ich Krämpfe habe, dann gehen sie so wie 6, 7. 6 bis 7. Okay. Halten Sie die Schmerzen denn aktuell aus oder soll ich Ihnen schon etwas dagegen geben? Jetzt geht es gerade, wenn ich sitze. Aber bevor ich gehe, wäre es schon gut, wenn Sie mir etwas geben würden. Okay, alles klar. Haben Sie denn danach noch mal etwas gegessen? Heute Morgen oder so? Nein, ich habe seitdem nicht mehr gegessen. Das letzte war das Mettbrötchen gestern Abend. Sind sonst noch Beschwerden aufgetreten? Haben Sie Durchfall oder Fieber oder so was? Seit heute Morgen habe ich Durchfall. Und Fieber hatte ich auch gestern Abend schon. Wie oft waren Sie seitdem auf der Toilette, wenn Sie sagen, Sie hatten Durchfall oder haben Durchfall? Drei Mal heute Morgen schon. Und wie war da die Konsistenz? Ja, wässrig eben und rot auch von der Farbe her. War das eher helleres Rot oder dunkel? Das erste Mal war es heller, das letzte Mal war es schon dunkler. Okay, gut Frau Stettner. Sie haben gesagt, Sie haben Fieber. Haben Sie Ihr Fieber auch gemessen? Ich habe es gemessen, ja. Das lag bei 38,4. 38,4, okay, super. Haben Sie denn auch Schluckbeschwerden festgestellt seit gestern Abend? Nein, keine Schluckbeschwerden. Okay, sehr gut. Sonst ist alles okay bei Ihnen? Oder ist Ihnen sonst noch etwas aufgefallen, dass Sie in der Nacht vermehrt geschwitzt haben? Oder irgendwelche anderen Symptome? Strahlen die Schmerzen in einem anderen Körperbereich aus? Nein, ich schlafe generell sehr unruhig. Aber das ist etwas, was ich jede Nacht habe. In der Nacht ist mir nichts Besonderes aufgefallen. Frau Stettner, gibt es denn Vorerkrankungen, von denen ich wissen sollte, wie zum Beispiel erhöhter Blutdruck oder ein Herzleiden? Oder auch schon etwas im Bauchbereich, im Magenbereich? Ja, ich habe einen Reizmagen. Grundsätzlich habe ich oft Probleme mit dem Magen. Aber ich habe auch schon ein bisschen Schmerzen. Ich habe auch schon ein bisschen Schmerzen. Ich habe auch oft Kopfschmerzen. Und auch ein Ohrpensausen oft. Der Reizmagen wurde vom Arzt diagnostiziert. Waren Sie deswegen schon beim Arzt gewesen? Ja, ich bin schon mal beim Hausarzt gewesen. Und was ist mit dem Reizmagen? Das ist ein sehr schwieriger Bereich. Das ist ein sehr schwieriger Bereich. Das ist ein sehr schwieriger Bereich. Ich bin schon mal beim Hausarzt gewesen. Seit wann haben Sie das? Seit 3-4 Jahren. Seit 3-4 Jahren. Haben Sie diesbezüglich auch öfter Sodbrennen? Haben Sie diesbezüglich auch öfter Sodbrennen? Ja. Die Kopfschmerzen. Wie häufig treten die auf? Und wo haben Sie die Kopfschmerzen? Eher im vorderen Kopf oder im Hinterkopf? Oder auf der Seite? Eher im vorderen und mittig auf der Seite. Und wie oft? Schon einmal im Monat. Schon einmal im Monat. Und das Ohrensausen, von dem Sie gesprochen haben. Und das Ohrensausen, von dem Sie gesprochen haben. Ist das dauerhaft da oder nur in bestimmten Zeiträumen? Ist das dauerhaft da oder nur in bestimmten Zeiträumen? Es ist immer wieder in bestimmten Zeiträumen. Es hört immer wieder auf und kommt wieder. Wenn ich mich ärgere oder Stress habe, dann kommt es noch mehr. Wenn ich mich ärgere oder Stress habe, dann kommt es noch mehr. Stressbedingt. Wurden Sie schon einmal operiert? Ja. In 9 Jahren wurden mir Gallensteine entfernt. In 9 Jahren wurden mir Gallensteine entfernt. Und 2 Jahre später auch Nierensteine. Und 2 Jahre später auch Nierensteine. Sind die Operationen komplikationslos verlaufen? Sind die Operationen komplikationslos verlaufen? Gott sei Dank ja. Ich weiß nicht, ob das auch eine Operation ist. Aber ich hatte auch eine Sauglöckenentbindung. Das gehört schon zu den operativen Entbindungen. Das gehört schon hierher. Wann war das, Frau Stettner? Vor 25 Jahren. Vor 25 Jahren. Nehmen Sie Medikamente ein gegen Ihre Vorerkrankungen? Nehmen Sie Medikamente ein gegen Ihre Vorerkrankungen? Nein, ich nehme ab und zu mal Baitrian. Wenn ich Stress habe, um mich zu beruhigen. Und für Kopfschmerzen nehme ich Aspirin C. Und für Kopfschmerzen nehme ich Aspirin C. Sind Sie geimpft? Sind Sie geimpft? Wann wurden Sie das letzte Mal geimpft? Wann wurden Sie das letzte Mal geimpft? Vor 3 Jahren haben wir noch eine Impfung gemacht. Aber ich weiß nicht mehr, welche es war. Ihren Impfpass haben Sie nicht dabei? Nein, habe ich nicht dabei. Ist Ihnen in letzter Zeit etwas seltsames aufgefallen? Ist Ihnen in letzter Zeit etwas seltsames aufgefallen? Dass Sie z.B. nachts vermehrt geschwitzt haben? Dass Sie z.B. nachts vermehrt geschwitzt haben? Oder öfter mal einen Kallschweiß gelitten haben? Oder öfter mal einen Kallschweiß gelitten haben? Kein Schwitzen. Aber ich schlafe sehr unruhig in letzter Zeit. Ich bin müde nach der Arbeit. Ich fühle mich oft zu nichts in der Lage. Ich fühle mich oft zu nichts in der Lage. Ich kann aber trotzdem nicht schlafen. Wie sieht es mit Ihrem Stuhlgang aus? Wie sieht es mit Ihrem Stuhlgang aus? Sie haben seit heute Morgen den Durchfall. Sie haben seit heute Morgen den Durchfall. Ist Ihnen in den letzten Wochen etwas Ungewöhnliches aufgefallen? Grundsätzlich nicht. Jetzt gibt es nur noch meine Magenprobleme mit dem Reizmagen. Jetzt gibt es nur noch meine Magenprobleme mit dem Reizmagen. Aber der Stuhlgang ist eigentlich in Ordnung. Haben Sie Ihre Periode noch? Bekommen Sie die noch, wenn ja, regelmäßig? Nein, seit 4 Jahren bekomme ich sie nicht mehr. Nein, seit 4 Jahren bekomme ich sie nicht mehr. Wie sieht es mental bei Ihnen aus? Sie haben davon gesprochen, dass Sie häufig Stress haben. Sie haben davon gesprochen, dass Sie häufig Stress haben. Ich gehe davon aus, dass es auch Job bedingt ist. Hatten Sie schon mal einen Burnout? Oder davon bei Ihnen Depressionen diagnostiziert? Nein, es wurden bei mir keine Depressionen diagnostiziert. Aber ich habe schon viel Stress auf der Arbeit. Aber ich habe schon viel Stress auf der Arbeit. Es ist viel Konkurrenz da und es ist sehr stressig. Deswegen hoffe ich, dass das schnell vorbeigeht. Deswegen hoffe ich, dass das schnell vorbeigeht. Ich muss ja wieder auf die Arbeit. Persönlich habe ich auch Stress. Persönlich habe ich auch Stress. Sie haben schon gesagt, dass Sie Probleme mit Ihrer Tochter haben. Sie haben schon gesagt, dass Sie Probleme mit Ihrer Tochter haben. Darf ich fragen, was das ist? Sie hat leider ein Drogenproblem. Das ist schon heftig. Das ist schon heftig. Wir versuchen, sie herauszuholen. Wir versuchen, sie herauszuholen. Bekommt Ihre Tochter da bereits Hilfe? Bekommt Ihre Tochter da bereits Hilfe? Das bekommt sie schon. Das bekommt sie schon. Ich habe schon mal von einer Methadon-Therapie gehört. Methadon ist eine andere Art von Gra horizontaleindoende Progen flirtativ. Methadon ist eine andere Art von roter gra horizontally indoende proplagende Progen. Methadon wirkt ähnlich, außer dass dieser Rausch weg bleibt. Das wird geführt und therapiert in einer Anlaufstelle. Aber kann das nicht auch süchtig machen? Das kann auch abhängig machen, deswegen ist es eben auch wichtig, dass Ihre Tochter das nicht alleine macht, sondern da einen Betreuer hat, der sie da führt. Dass sie da auch beobachtet wird. Das wird dann auch im Endeffekt ganz langsam abgesetzt, aber eben diese Entzugserscheinungen bleiben aus. Okay, verstehe. Frau Stettner, ein paar Fragen zu Ihren Lebensgewohnheiten. Rauchen Sie? Ja, ich rauche. Wie viel rauchen Sie und seit wann? 15-20 Zigaretten am Tag. Und seit guten 20 Jahren. Okay. Trinken Sie auch Alkohol? Ja, ab und zu mal 2-3 Glas Wein in der Woche. Ab und zu ein Bier auch. Und nehmen Sie das jetzt bitte nicht persönlich, aber nehmen Sie Drogen? Nein, ich nehme keine. Gut. Gibt es denn bei Ihnen in der Familie Vorerkrankungen, von denen ich wissen sollte? Auch da irgendwie ein Herzleiden oder Diabetes oder ein Knochenleiden oder ähnliches? Ja, meine Mutter hatte Brustkrebs, ist krank gestorben. Und sie hatte auch Probleme mit den Nieren. Was heißt Probleme mit den Nieren? Nierendeintaktlizenz? Genau. Und wie alt war Ihre Mutter, als sie am Krebs gestorben ist? 65. Und Ihr Vater? Er ist noch früher gestorben, mit 45, sehr jung. An einem Herzinfarkt. Und er war auch sehr stark übergewichtig und hatte auch Diabetes. Und Ihre Tochter, ist die denn gesund, unabhängig von dem Drogenkonsum? Gibt es bei ihr auch irgendwelche Erkrankungen, auch chronische Erkrankungen, von denen ich wissen sollte? Nicht, dass ich wüsste. Grundsätzlich glaube ich nicht. Sie ist nur viel zu dünn. Gut. Herzlichen Dank, Frau Stettner. Damit habe ich soweit auch alle Fragen gestellt. Falls Ihnen doch noch etwas einfällt zu Ihren Beschwerden, würde ich mich sehr freuen, wenn Sie mir das auch jetzt noch mitteilen. Ansonsten, aufgrund der Angaben, die Sie mir jetzt gemacht haben, gehe ich hier von einem Magen-Darm-Infekt aus. Um das aber genau zu untersuchen, würde ich gerne noch mal Ihren Bauch abtasten. Ich würde auch gerne eine Ultraschallaufnahme Ihres Bauchs machen. Und ein bisschen Blut abnehmen, um da auch die Entzündungsparameter zu messen. Und wenn wir den Befund haben, komme ich natürlich sofort wieder auf Sie zu. Haben Sie an dieser Stelle noch Fragen an mich? Ja, wie lange dauert das denn alles? Kann ich dann gleich wieder nach Hause, nach diesen Untersuchungen? Ich würde Sie schon gerne ein paar Tage hier behalten, damit wir auch überprüfen können, dass es nichts Drastischeres ist als eine Magen-Darm-Entzündung. Ich würde Sie gerne ein bisschen beobachten. Sie hatten ja auch schon Probleme mit dem Magen. Und um dann auf Nummer sicher zu gehen, wäre es schön, wenn Sie ein, zwei Tage erst mal hier bleiben. Frau Doktor, wegen Magen-Darm will ich aber jetzt nicht im Krankenhaus bleiben. Ich habe schon wirklich genug zu tun und genug Probleme zu Hause. Ich muss doch nicht jetzt wegen einer Magen-Darm-Geschichte im Krankenhaus bleiben, oder? Ja, ich weiß. Das hört sich erst mal etwas salopp an, beziehungsweise etwas nichtig. So eine Magen-Darm-Geschichte, das hat man ja schon immer mal gehabt. Allerdings würde ich Sie trotzdem gerne hier im Krankenhaus behalten. Es geht schließlich um Ihre Gesundheit. Und wenn wir Sie jetzt beobachten und die Untersuchungen durchführen, dann können wir eben auch direkt eingreifen. Kann es sein, dass vielleicht etwas Schlimmeres ist? Vielleicht Krebs oder so etwas Ähnliches? Frau Stettner, alle Anzeichen, die Sie mir genannt haben, alle Beschwerden, die sprechen schon sehr für eine Magen-Darm-Infektion. Daher gehe ich jetzt nicht von Krebs aus. Um aber auch das ausschließen zu können und da auf Nummer sicher zu gehen, werden wir im Anschluss die ganzen Untersuchungen mit Ihnen durchführen. Und dann kann ich Ihnen da auch eine genauere Aussage machen. Und können Sie das nicht vielleicht auch im Ultraschall sehen, ob ich Krebs habe? Auf dem Ultraschall kann man erste Anzeichen entdecken, aber das reicht bei weitem nicht aus. Wenn wir da etwas entdecken, was eine Knotenform hat, dann wird es natürlich sofort passieren, dass wir weitere Untersuchungen durchführen, um dann eben Krebs festzustellen oder ausschließen zu können. Ich möchte Sie allerdings bitten, jetzt nicht direkt von Krebs auszugehen. Das hört sich jetzt natürlich dramatisch an, dass Sie hier bei uns im Krankenhaus bleiben sollen. Das ist eine reine Routine, dass Sie einfach gut behandelt werden und dann auch sich gut auskurieren können und dann mit voller Energie wieder in den Job starten können. Das bringt ja auch nichts, wenn Sie jetzt zwei, drei Tage zu Hause rumliegen und ganz böse vor sich hinvegetieren und das gar nicht richtig auskurieren, weil Sie ja doch noch tausend Sachen im Kopf haben und dann wahrscheinlich auch aufstehen und noch etwas erledigen. Und hier werden Sie von uns umsorgt. Sie bekommen eine Kost, die dementsprechend auch geeignet ist für so einen Reizmagen und eben auch jetzt für eine Magendarmentzündung. Und alles zusammen sorgt eben dafür, dass Sie ganz schnell wieder genesen und dann auch auf schnellstem Wege wieder gesund werden. Ja, okay. Dann bleibt mir ja nichts weiter übrig. Okay, Frau Stettner. Vielen Dank für Ihr Verständnis. Dann würde ich Sie bitten, noch einmal kurz im Wartezimmer Platz zu nehmen. Ich sage den Schwestern und den Kollegen Bescheid, dass wir mit den Untersuchungen sofort anfangen und dann geht es auch gleich los. Ja, okay. Danke. Dankeschön und bis gleich.

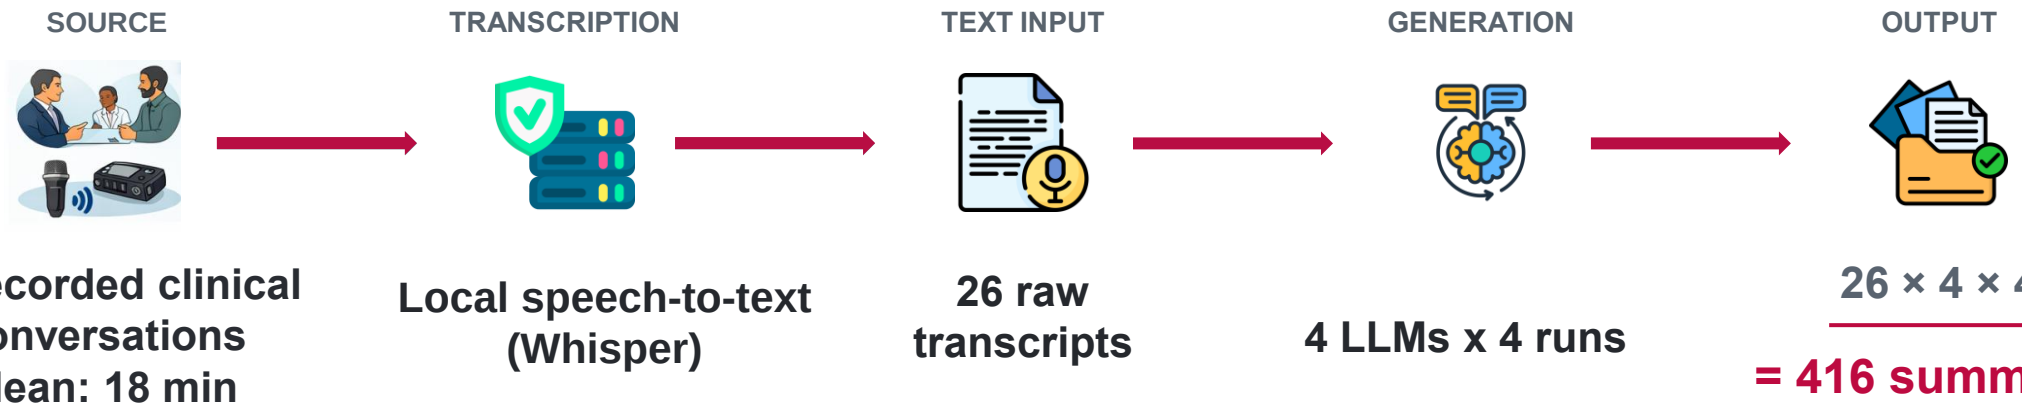
Example Output: Summary of a Clinical Transcript

Patient:
Die Patientin stellt sich als „Maria Stettner“ (geb. 01.03.1960) vor und berichtet über seit dem Vorabend bestehende, krampfartige Magenschmerzen, die nach dem Abendessen eines „Mettbrötchen[s]“ begonnen haben. Begleitsymptome sind dreimaliges Erbrechen am Abend (Essensreste, „etwas gelblich“), seit dem Morgen wässriger Durchfall (insgesamt dreimal, initial hellrot, zuletzt dunkler) sowie Fieber bis 38,4 °C. Auf einer Skala von 1–10 bewertet sie die Schmerzen in Ruhe mit 4, bei Krämpfen mit 6–7. Seit dem Vorabend hat sie nichts mehr gegessen; Schluckbeschwerden verneint sie. Anamnestisch bestehen ein ärztlich diagnostizierter „Reizmagen“ seit 3–4 Jahren mit häufigem Sodbrennen, gelegentliche Kopfschmerzen (monatlich, frontal/zentral) und intermittierendes, stressverstärktes Ohrensausen. Voroperationen: Gallenstein-OP vor 9 Jahren, Nierensteine 2 Jahre später, sowie eine Saugglockenentbindung vor 25 Jahren; komplikationslos. Medikation: „ab und zu mal Baitrian“ bei Stress, „Aspirin C“ bei Kopfschmerzen. Impfungen: vor 3 Jahren eine Impfung (unbekannt), Impfpass nicht dabei. Sozial-/Noxen-Anamnese: berufstätig („Ich vertanze“), raucht 15–20 Zigaretten/Tag seit ~20 Jahren, trinkt 2–3 Gläser Wein/Woche plus gelegentlich Bier, keine Drogen. Menstruation seit 4 Jahren erloschen. Psychosozial erheblicher Stress (beruflich, Konkurrenzdruck; familiär: Tochter mit Drogenproblem). Familienanamnese: Mutter an Brustkrebs mit 65 verstorben, zudem Nierenprobleme; Vater mit 45 an Herzinfarkt verstorben, stark übergewichtig und diabetisch; Tochter „viel zu dünn“, sonst keine bekannten Erkrankungen.

Arzt:
Die Ärztin strukturiert das Aufnahmegespräch, erhebt die Anamnese und ordnet die Beschwerden als wahrscheinlich „Magen-Darm-Infektion“ ein. Zur Abklärung/Überwachung plant sie körperliche Untersuchung (Bauch abtasten), eine „Ultraschallaufnahme“ des Abdomens sowie Blutentnahme zur Bestimmung von „Entzündungsparametern“. Sie empfiehlt stationäre Beobachtung für „ein, zwei Tage“, um sicherzugehen, „dass es nichts Drastischeres ist als eine Magen-Darm-Entzündung“, und erläutert, dass die geschilderten Zeichen nicht für Krebs sprechen; Ultraschall könne allenfalls „erste Anzeichen“ zeigen, weiterführende Diagnostik wäre bei Verdacht nötig. Sie begründet den stationären Verbleib mit besserer Versorgung, geeigneter Kost (auch im Kontext „Reizmagen“) und schnellerer Genesung.

Relevante Textstellen:
* „Ich habe seit gestern Probleme mit dem Magen. Ich habe ganz heftige Schmerzen … Das sind so Krämpfe.“
* „Gestern Abend nach dem Abendessen.“ – „Ein Mettbrötchen.“
* „Ja, ich habe mich, glaube ich, dreimal übergeben, gestern Abend.“ – „… Essensreste und es war etwas gelblich …“
* „Im Ruhezustand sind sie bei 4 … wenn ich Krämpfe habe, dann … 6, 7.“
* „Nein, ich habe seitdem nicht mehr gegessen. Das letzte war das Mettbrötchen gestern Abend.“
* „Seit heute Morgen habe ich Durchfall.“ – „Drei Mal heute Morgen schon.“ – „… wässrig eben und rot … Das erste Mal … heller, das letzte Mal … dunkler.“
* „Ich habe es [Fieber] gemessen, ja. Das lag bei 38,4.“
* „Nein, keine Schluckbeschwerden.“
* „Ja, ich habe einen Reizmagen. … Seit 3–4 Jahren.“ – „… auch öfter Sodbrennen?“ – „Ja.“
* „… Kopfschmerzen … Eher im vorderen und mittig … Schon einmal im Monat.“
* „… Ohrensausen … Es hört immer wieder auf und kommt wieder. … Wenn ich mich ärgere oder Stress habe, dann kommt es noch mehr.“
* „… Gallensteine entfernt. … Und 2 Jahre später auch Nierensteine. … komplikationslos …“
* „… eine Sauglöckenentbindung. … Vor 25 Jahren.“
* „… ab und zu mal Baitrian … Und für Kopfschmerzen … Aspirin C.“
* „Vor 3 Jahren … eine Impfung … ich weiß nicht mehr, welche … Impfpass … nicht dabei.“
* „Ja, ich rauche. … 15–20 Zigaretten am Tag. … seit guten 20 Jahren.“
* „Ja, ab und zu mal 2–3 Glas Wein in der Woche. Ab und zu ein Bier auch.“ – „Nein, ich nehme keine [Drogen].“
* „Nein, seit 4 Jahren bekomme ich sie nicht mehr.“ (Menstruation)
* „… viel Stress auf der Arbeit. … Konkurrenz … sehr stressig.“ – „Sie hat leider ein Drogenproblem.“
* „… meine Mutter hatte Brustkrebs … 65 … Nieren…“ – „… Vater … 45 … Herzinfarkt … übergewichtig … Diabetes.“
* „… gehe ich hier von einem Magen-Darm-Infekt aus. … Bauch abtasten. … Ultraschallaufnahme … Blut abnehmen … Entzündungsparameter …“
* „Ich würde Sie schon gerne ein paar Tage hier behalten … ein, zwei Tage …“
* „… gehe ich jetzt nicht von Krebs aus. … auf dem Ultraschall kann man erste Anzeichen entdecken … weitere Untersuchungen …“
* „… geeignete Kost … für so einen Reizmagen … und … Magendarmentzündung. … ganz schnell wieder genesen …“

From Clinical Conversations to Reliable Summaries



Challenge

LLM-generated summaries may omit clinically relevant information or introduce unsupported content [1,2].

Evaluation gap

There is no gold-standard reference for each summary, and conventional comparison metrics mainly capture lexical overlap [1,3,4].

Ahmad Wattar
AG (Bio-) Medical Data Science

References: [1] Asgari et al. (2025). A framework to assess clinical safety and hallucination rates of LLMs for medical text summarisation. DOI: 10.1038/s41746-025-01670-7
[2] Williams et al. (2025). Evaluating large language models for drafting emergency department encounter summaries. DOI: 10.1371/journal.pdig.0000899
[3] Croxford et al. (2025). Evaluating clinical AI summaries with large language models as judges. npj Digital Medicine, 8, 640. DOI: 10.1038/s41746-025-02005-2
[4] Novikova, J., Dušek, O., Curry, A. C., & Rieser, V. (2017). Why We Need New Evaluation Metrics for NLG. EMNLP. DOI: 10.18653/v1/D17-1238

From Clinical Conversations to Reliable Summaries

SOURCE	TRANSCRIPTION	TEXT INPUT	GENERATION	OUTPUT
				
26 recorded clinical conversations Mean: 18 min	Local speech-to-text (Whisper)	26 raw transcripts	4 LLMs x 4 runs	26 × 4 × 4 = 416 summaries

Challenge

LLM-generated summaries may omit clinically relevant information or introduce unsupported content [1,2].

Evaluation gap

There is no gold-standard reference for each summary, and conventional comparison metrics mainly capture lexical overlap [1,3,4].

How can we reliably compare models and generate high-quality summaries without reference summaries?

Ahmad Wattar
AG (Bio-) Medical Data Science

References: [1] Asgari et al. (2025). A framework to assess clinical safety and hallucination rates of LLMs for medical text summarisation. DOI: 10.1038/s41746-025-01670-7
[2] Williams et al. (2025). Evaluating large language models for drafting emergency department encounter summaries. DOI: 10.1371/journal.pdig.0000899
[3] Croxford et al. (2025). Evaluating clinical AI summaries with large language models as judges. npj Digital Medicine, 8, 640. DOI: 10.1038/s41746-025-02005-2
[4] Novikova, J., Dušek, O., Curry, A. C., & Rieser, V. (2017). Why We Need New Evaluation Metrics for NLG. EMNLP. DOI: 10.18653/v1/D17-1238

4 LLMs for Generation, 5 Embedding Models for Evaluation

MODEL SETUP

4 summary-generating LLMs

Generate the clinical summaries

- Meta Llama 3.1 8B Instruct
- SauerkrautLM 70B Instruct
- MedGemma 27B Instruct
- GPT-OSS-120B

5 embedding models

Convert texts into vector embeddings

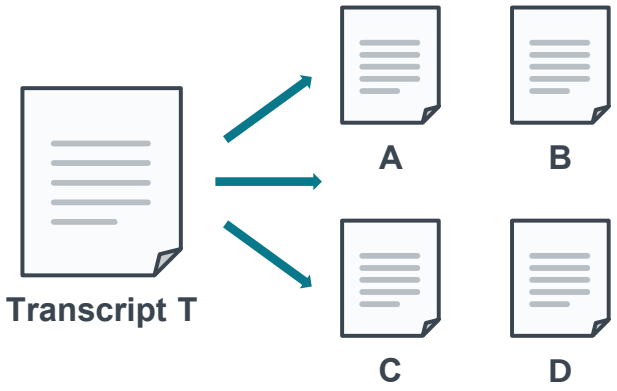
- Jina Embeddings v3
- GTE Multilingual Base
- BGE-M3
- AARI German Semantic V3b
- Llama 3.1 8B Instruct (LlamaEmb)

Experiments

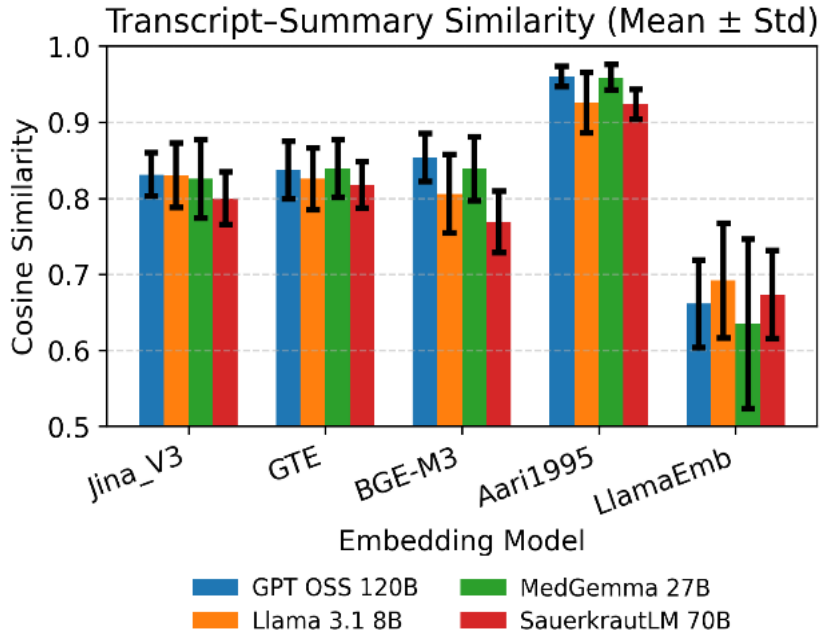
1 Transcript–Summary Similarity

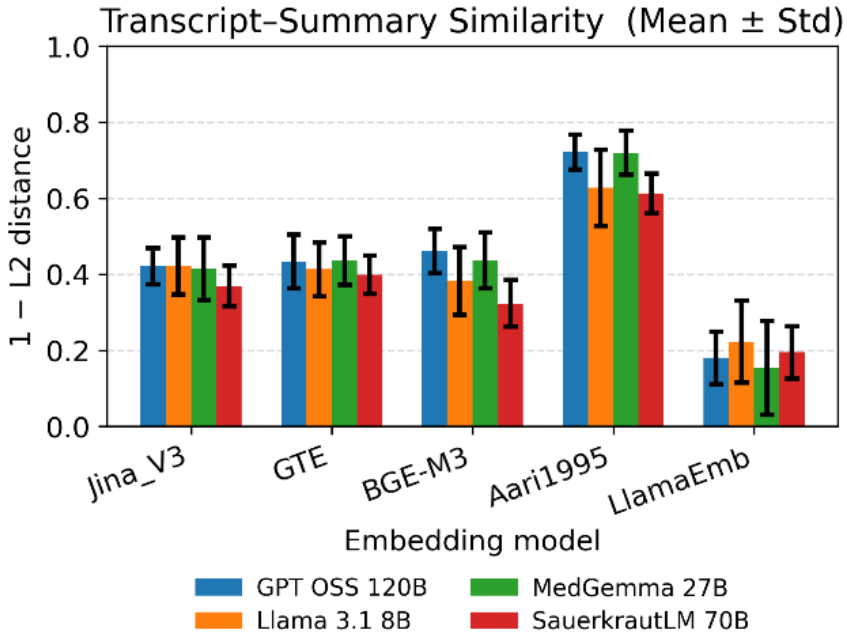
Transcript + summary
⬇
Embeddings
⬇
Cosine similarity & L2 distance
⬇
Mean per LLM

Same transcript, four runs



1. Transcript–Summary Similarity





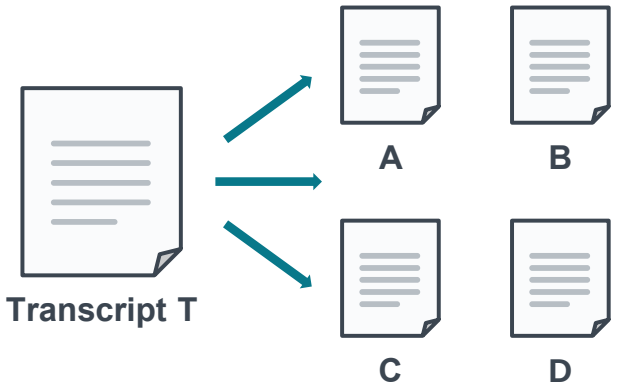
- GPT-OSS-120B and MedGemma 27B achieve the highest similarity scores across most embedding models.
- The embedding model affects the absolute scale more than the relative ranking.
- Cosine similarity and L2 distance show qualitatively similar trends.

Experiments

1 Transcript–Summary Similarity

Transcript + summary
↓
Embeddings
↓
Cosine similarity & L2 distance
↓
Mean per LLM

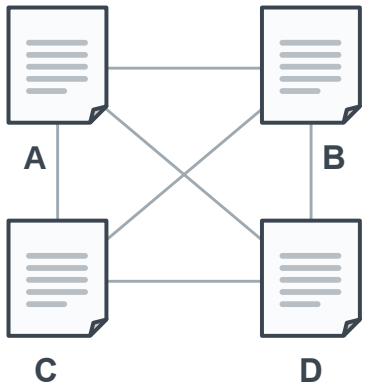
Same transcript, four runs



2 Repeated Generations

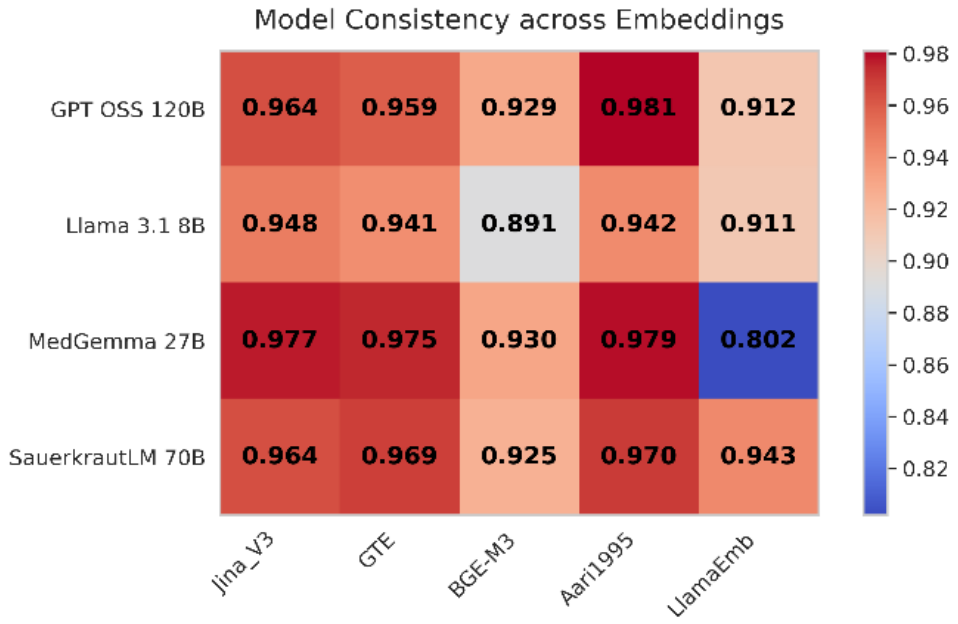
Summary pairs
↓
Embeddings
↓
Cosine similarity
↓
Mean per LLM

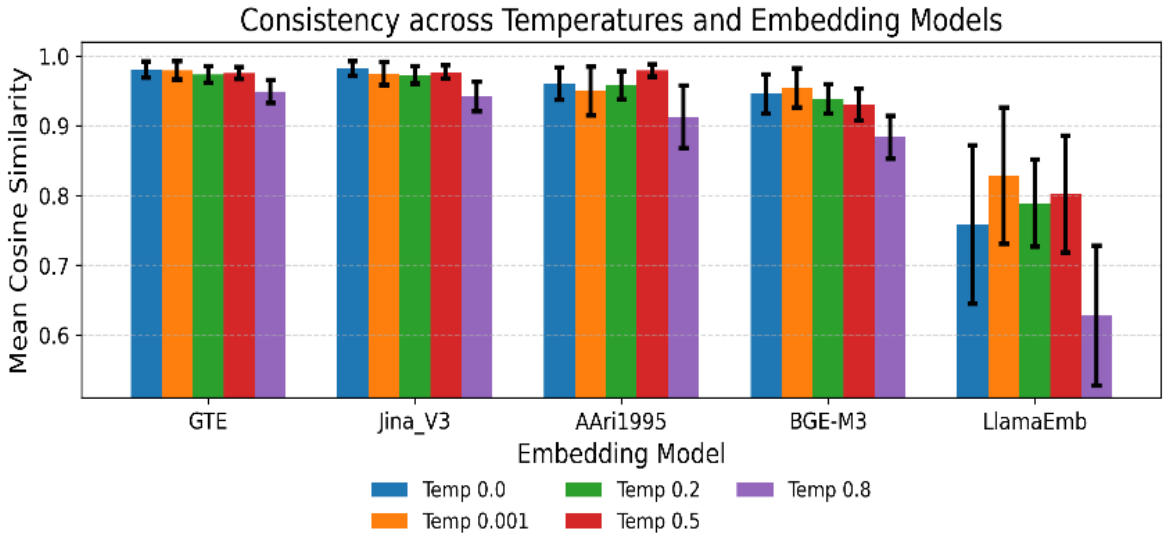
All 6 summary pairs



- All summaries used the same prompt and decoding settings.
- MedGemma was also tested at different temperatures.

2. Repeated Generations: Repeated Runs Remain Largely Consistent





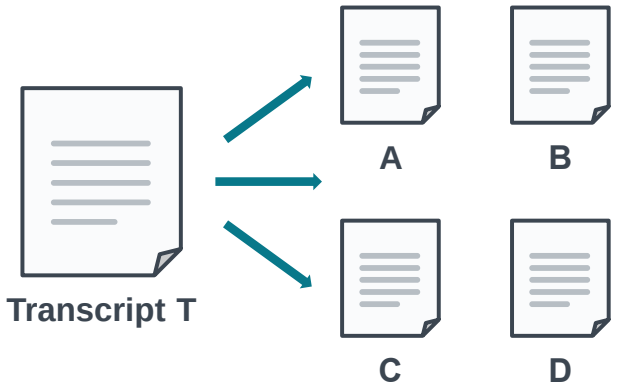
- Most consistency scores > 0.90
- LlamaEmb shows the largest variation
- Low temperatures: high consistency

Experiments

1 Transcript–Summary Similarity

Transcript + summary
↓
Embeddings
↓
Cosine similarity & L2 distance
↓
Mean per LLM

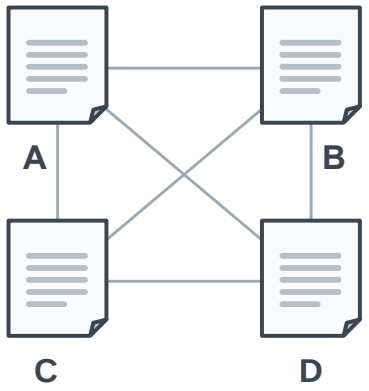
Same transcript, four runs



2 Repeated Generations

Summary pairs
↓
Embeddings
↓
Cosine similarity
↓
Mean per LLM

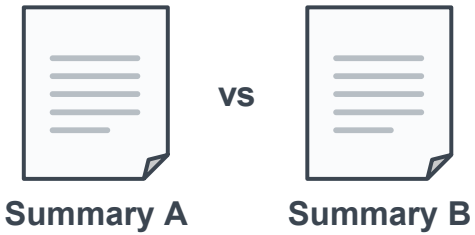
All 6 summary pairs



3 Human Evaluation

6 A/B summaries
↓
3 raters
↓
Quality scores
↓
Agreement with Cosine similarity & L2 distance

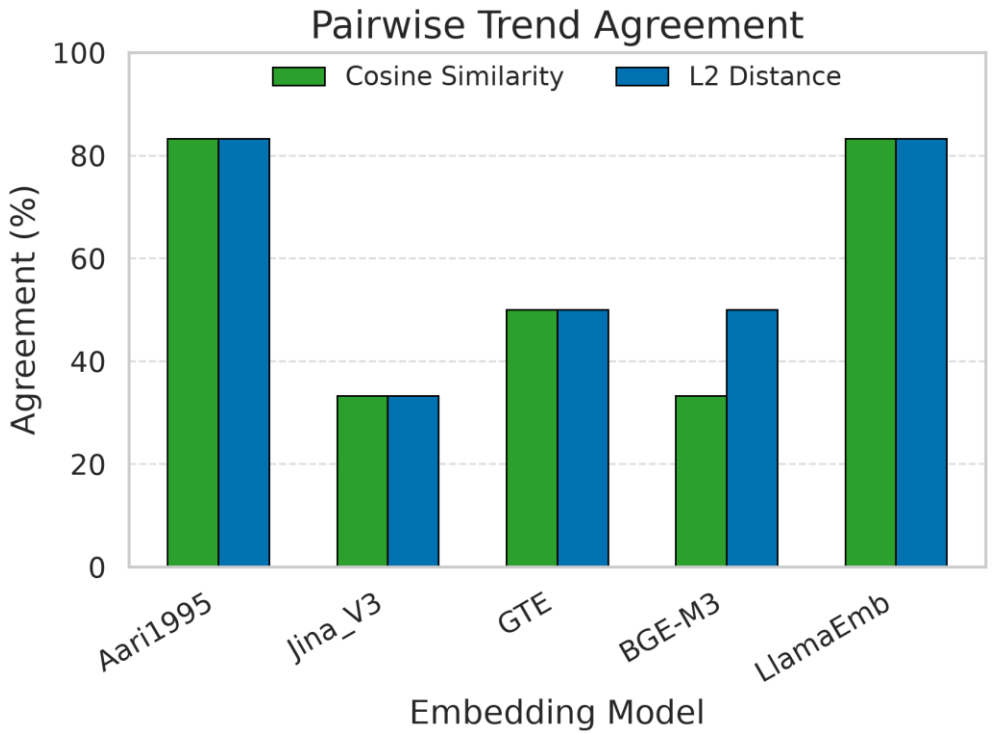
3 raters compare the pair A/B



Human preference ⟷ Cosine/L2 preference

- All summaries used the same prompt and decoding settings.
- MedGemma was also tested at different temperatures.

3. Exploratory Human Evaluation: Partial Agreement with Metrics



- LlamaEmb and AARI both 83.3%, GTE 50%.
- partial agreement with metrics

Key Findings

1

Embedding-based similarity supports reference-free summary comparison

Transcript–summary similarity can be assessed without reference summaries.

Key Findings

1

Embedding-based similarity supports reference-free summary comparison

Transcript–summary similarity can be assessed without reference summaries.

2

Scores depend on the embedding model

Relative model rankings were consistent across embeddings, but absolute scores varied.
The embedding model must always be reported with the metric.

Key Findings

1 Embedding-based similarity supports reference-free summary comparison

Transcript–summary similarity can be assessed without reference summaries.

2 Scores depend on the embedding model

Relative model rankings were consistent across embeddings, but absolute scores varied.
The embedding model must always be reported with the metric.

3 Automatic metrics matched humans only partly

Similarity is useful, but it does not fully reflect human preference.

Key Findings

1 Embedding-based similarity supports reference-free summary comparison

Transcript–summary similarity can be assessed without reference summaries.

2 Scores depend on the embedding model

Relative model rankings were consistent across embeddings, but absolute scores varied.
The embedding model must always be reported with the metric.

3 Automatic metrics matched humans only partly

Similarity is useful, but it does not fully reflect human preference.

Outlook

1 Further validation is needed

Further research with larger datasets and more extensive human evaluation is needed to confirm these findings.

Key Findings

1 Embedding-based similarity supports reference-free summary comparison

Transcript–summary similarity can be assessed without reference summaries.

2 Scores depend on the embedding model

Relative model rankings were consistent across embeddings, but absolute scores varied.
The embedding model must always be reported with the metric.

3 Automatic metrics matched humans only partly

Similarity is useful, but it does not fully reflect human preference.

Outlook

1 Further validation is needed

Further research with larger datasets and more extensive human evaluation is needed to confirm these findings.

2 Combined evaluation approaches

Evaluate combinations of embedding metrics, human ratings, and LLM-as-a-judge [1,2].

References: [1] Croxford et al. (2025). Evaluating clinical AI summaries with large language models as judges. npj Digital Medicine, 8, 640. DOI: 10.1038/s41746-025-02005-2
[2] Liu et al. (2023). G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment. EMNLP. DOI: 10.18653/v1/2023.emnlp-main.153

Key Findings

1 Embedding-based similarity supports reference-free summary comparison

Transcript–summary similarity can be assessed without reference summaries.

2 Scores depend on the embedding model

Relative model rankings were consistent across embeddings, but absolute scores varied.
The embedding model must always be reported with the metric.

3 Automatic metrics matched humans only partly

Similarity is useful, but it does not fully reflect human preference.

Outlook

1 Further validation is needed

Further research with larger datasets and more extensive human evaluation is needed to confirm these findings.

2 Combined evaluation approaches

Evaluate combinations of embedding metrics, human ratings, and LLM-as-a-judge [1,2].

3 Integration into the local Whisper system

Integrate embedding-based evaluation as a summary-check feature for automatically generated clinical summaries.

References: [1] Croxford et al. (2025). Evaluating clinical AI summaries with large language models as judges. npj Digital Medicine, 8, 640. DOI: 10.1038/s41746-025-02005-2
[2] Liu et al. (2023). G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment. EMNLP. DOI: 10.18653/v1/2023.emnlp-main.153

Thank You for Your Attention

QUESTIONS & DISCUSSION

Questions?

Reference-Free LLM Benchmarking for Local Medical Speech-to-Text Pipelines

Funding: This work received funding from the Saxony-Anhalt Ministry of Infrastructure and Digital Affairs under the “Saxony-Anhalt Digital 2030” guideline.

Ahmad Wattar · Jan Christoph · Christoph Demus · Patrick Liegel · Christian Jäger

Research Group (Bio-) Medical Data Science · Martin Luther University Halle-Wittenberg

Ahmad.wattar@uk-halle.de

Meet us at our posters: 30-P1-15 & 30-P1-16